

GUSTAVO MENDONÇA

NON-NATIVE SPEECH RECOGNITION FOR  
COMPUTER ASSISTED PRONUNCIATION  
TRAINING



NON-NATIVE SPEECH RECOGNITION FOR COMPUTER  
ASSISTED PRONUNCIATION TRAINING:  
THE LISTENER SYSTEM

GUSTAVO MENDONÇA



Instituto de Ciências Matemáticas e de Computação  
Universidade de São Paulo  
São Carlos, SP – Brazil  
July 2014 – version 0.1

Gustavo Mendonça: *Non-Native Speech Recognition for Computer Assisted Pronunciation Training, The Listener System*

**SUPERVISORS:**

Sandra Aluísio  
Aldebaro Klautau

**LOCATION:**

São Carlos, SP – Brazil

**TIME FRAME:**

July 2014

To the loving memory of my father,  
*Tarcízio Otávio Almeida.*

1947 – 2003



## ABSTRACT

---

Pesquisas recentes têm avaliado o Brasil entre os países com menor nível de proficiência em língua inglesa. Este projeto busca criar um recurso que possa contribuir para a melhoria desse cenário. O objetivo é desenvolver um reconhecedor de pronúncia para falantes do português brasileiro (PB) aprendizes de inglês, chamado Listener, que seja capaz de fornecer ao usuário feedback sobre sua pronúncia. Recursos semelhantes já foram desenvolvidos para outras línguas, no entanto, para o PB, há ainda uma lacuna a ser explorada. A hipótese de pesquisa é que é possível construir tal reconhecedor de pronúncia através de: (i) uma classificação de erros de pronúncia que leve em conta a transferência de padrões de L<sub>1</sub> para L<sub>2</sub>; (ii) um modelo acústico que agregue dados de fala do inglês tanto de nativos, quanto de aprendizes; (iii) um dicionário de pronúncia que contenha a transcrição das pronúncias desviantes do aprendiz; e (iv) um modelo de língua que condiga com a sintaxe do aprendiz. Nove erros de pronúncia foram selecionados para serem tratados pelo Listener, assumindo-se, como pronúncia padrão, o General American (GA). A engine Julius será empregada como base do reconhecedor. O modelo acústico será compilado a partir de um corpus de fala de nativos de inglês: TIMIT Acoustic-Phonetic Continuous Speech Corpus[1]; e outro de aprendizes: COBAI - Corpus Oral Brasileiro de Aprendizes de Inglês[2]. O dicionário a ser empregado é o CMU Pronouncing Dictionary, ao qual serão acrescentaremos as hipóteses de pronúncia dos aprendizes, por meio de regras. O modelo de língua será gerado a partir da Simple English Wikipedia em conjunto com um corpus de textos escritos por aprendizes de inglês, o COMAprend[3], um dos três corpus do projeto COMET da Faculdade de Filosofia, Letras e Ciências Humanas da Universidade de São Paulo. A eficiência do reconhecedor será avaliada por meio de medidas de Word Error Rate (WER), Character Error Rate (CER) e matrizes de confusão. O reconhecedor proposto visa a propiciar a criação de sistemas de treino de pronúncia mediado por computador. De modo a verificar a viabilidade do método ora proposto, um protótipo do reconhecedor foi elaborado e avaliado intrinsecamente. Um excerto do COBAI e de um corpus de erros induzidos especialmente coletado para este protótipo foram utilizados para alimentar o modelo acústico (~3h50min de fala). O protótipo foi desenvolvido para reconhecer erros relacionados à simplificação silábica. As variantes de pronúncia foram adicionadas no dicionário através de um conjunto de 20 regras. As taxas de WER obtidas foram de 61% para um léxico de 5.768 entradas, e de

78% para alinhamento forçado, indicando, portanto, que o método é promissor...

## ZUSAMMENFASSUNG

---

Kurze Zusammenfassung des Inhaltes in deutscher Sprache...



## CONTENTS

---

<b>1</b>	<b>INTRODUCTION</b>	<b>1</b>
1.1	Research hypotheses	7
1.2	Contributions of the Thesis	8
1.3	Thesis Structure	9
<b>i</b>	<b>SOME FUNDAMENTAL CONCEPTS</b>	<b>11</b>
<b>2</b>	<b>PHONETICS AND PHONOLOGY</b>	<b>13</b>
2.1	The Phonetic Inventory of Brazilian Portuguese	13
2.2	The Phonetic Inventory of American English	13
<b>3</b>	<b>SECOND LANGUAGE ACQUISITION</b>	<b>15</b>
3.1	PB	15
3.2	Why Consider L1 in L2 Teaching?	30
3.3	Common Mispronunciation	30
3.3.1	Syllable Simplification	30
3.3.2	Consonant Change	30
3.3.3	Deaspiration of Voiceless Plosives in Initial or Stressed Positions	30
3.3.4	Terminal Devoicing in Word-Final Obstruents	31
3.3.5	Delateralization and rounding of lateral liquids in final position	31
3.3.6	Vocalization of final nasals	31
3.3.7	Velar consonantal paragoge	31
3.3.8	Vowel assimilation	31
3.3.9	Interconsonantal epenthesis (-ed and -s morphemes)	31
<b>4</b>	<b>AUTOMATIC SPEECH RECOGNITION</b>	<b>33</b>
4.1	The big picture	33
4.2	HMM	34
4.3	PB	35
4.4	A Brief History	39
4.5	HMM-based Speech Recognition	43
4.6	Feature Extraction	43
4.6.1	Preamble	43
4.7	MFCC Features	47
4.8	Dealing with Noisy Data	48
4.9	Types of Speech Recognition Systems	48
4.10	The Architecture of a Large Vocabulary Continuous Speech Recognition System	49
<b>ii</b>	<b>RELATED WORK</b>	<b>51</b>
<b>5</b>	<b>COMPUTER ASSISTED PRONUNCIATION TRAINING</b>	<b>53</b>
5.1	PB	53
5.2	English	54

<b>6 HOW TO ADAPT A SPEECH RECOGNITION TO NON-NATIVE DATA</b>	<b>57</b>
<b>6.1 PB</b>	<b>57</b>
<b>6.2 Adaptation Methods for the Acoustic Model</b>	<b>62</b>
<b>6.3 Adaptation Methods for the Pronunciation Model</b>	<b>62</b>
<b>6.4 Adaptation Methods for the Languaeg Model</b>	<b>62</b>
<b>iii THE DESIGN OF LISTENER</b>	<b>63</b>
<b>7 METHODS</b>	<b>65</b>
<b>7.1 PB</b>	<b>65</b>
<b>7.2 Evaluation</b>	<b>76</b>
<b>7.2.1 Evaluation Metrics</b>	<b>76</b>
<b>7.3 Tools and Libraries</b>	<b>77</b>
<b>7.3.1 HTK</b>	<b>78</b>
<b>7.3.2 Julius</b>	<b>78</b>
<b>7.3.3 Aieouadô's dictionary and G2P converter</b>	<b>78</b>
<b>7.4 Speech Corpora</b>	<b>86</b>
<b>7.4.1 TIMIT</b>	<b>86</b>
<b>7.4.2 WSJo</b>	<b>86</b>
<b>7.4.3 SpeechDat</b>	<b>87</b>
<b>7.4.4 Listener's Corpus</b>	<b>87</b>
<b>7.4.5 Oxford Dictionary AmE Corpus</b>	<b>87</b>
<b>7.4.6 Cambridge Dictionary</b>	<b>89</b>
<b>7.4.7 OGI-22</b>	<b>89</b>
<b>7.4.8 Westpoint</b>	<b>89</b>
<b>7.4.9 LapsBM</b>	<b>89</b>
<b>7.4.10 Youtube</b>	<b>89</b>
<b>7.5 Building the Acoustic Model</b>	<b>89</b>
<b>7.5.1 The Phoneset</b>	<b>89</b>
<b>7.5.2 Speech Data</b>	<b>92</b>
<b>7.5.3 HMM topology</b>	<b>92</b>
<b>7.5.4 Tree-Based State Tying</b>	<b>92</b>
<b>7.6 Building the Pronunciation Model</b>	<b>97</b>
<b>7.6.1 Syllable Simplification</b>	<b>99</b>
<b>7.6.2 Consonant Change</b>	<b>101</b>
<b>7.6.3 Deaspiration of Voiceless Plosives in Initial or Stressed Positions</b>	<b>101</b>
<b>7.6.4 Devoicing in Word-Final Obstruents</b>	<b>102</b>
<b>7.6.5 Delateralization and rounding of lateral liquids in final position</b>	<b>104</b>
<b>7.6.6 Vocalization of final nasals</b>	<b>105</b>
<b>7.6.7 Velar consonantal paragoge</b>	<b>105</b>
<b>7.6.8 Vowel assimilation</b>	<b>105</b>
<b>7.6.9 Interconsonantal epenthesis (-ed and -s morphemes)</b>	<b>105</b>
<b>8 RESULTS AND DISCUSSION</b>	<b>119</b>
<b>9 FINAL REMARKS</b>	<b>121</b>

iv APPENDIX 125

BIBLIOGRAPHY 128

## LIST OF FIGURES

---

Figure 1	English Proficiency Index 2014 Rankings [24].	2
Figure 2	EF EPI scores for each Brazilian state.	5
Figure 3	2013 Business English Index.	6
Figure 4	Height (cm) versus vocal tract length (mm) [26].	41
Figure 5	Averaged vocal tract morphology [26].	41
Figure 6	Fo and pitch sigma versus age for males and females [12].	42
Figure 7	Two complex waveforms generated by the same three pure tone 100 Hz, 200 Hz and 300 Hz sine waves, differing only with respect to their relative timing [41].	45
Figure 8	Example of in-phase waves.	45
Figure 9	Example of out-of-phase waves.	46
Figure 10	Illustration of an original audio recording (the upper waveform) divided into two offset sequences of analysis windows (two lower waveforms) with 50% overlapping frames [48]	46
Figure 11	Mel scale versus a linear frequency scale.	48
Figure 12	Example of the OroFacial Clone display, from Badin et al. [4].	55
Figure 13	<i>System architecture for building the pronunciation dictionary.</i>	81
Figure 14	<i>Example of the transcription procedure – in grey: graphemes yet to be transcribed; in black: graphemes already transcribed.</i>	82
Figure 15	Entry example in the Oxford Dictionary online.	88
Figure 16	Spectrogram of the word “happiness”, present in the Oxford Dictionary AmE Corpus.	89
Figure 17	Phonetic decision tree for HMM state tying [91].	95
Figure 18	Tied-state HMM system build procedure [91].	96
Figure 19	Distinctive features for places of places of articulation [35].	97

## LIST OF TABLES

---

Table 1	CEFR reference levels.	4
---------	------------------------	---

Table 2	Word error rate comparisons between human and machines on similar tasks [34].	40
Table 3	<i>Portuguese Wikipedia Summary – Dumped on 23<sup>rd</sup> January 2014.</i>	83
Table 4	<i>Results from the Language Identifier module – Training Phase.</i>	84
Table 5	<i>Results from the Language Identifier module – Wikipedia word list.</i>	84
Table 6	<i>Results from the Transcriber – Performance per phone.</i>	106
Table 7	Summary of the entire WSJo Corpus.	107
Table 8	Summary of WSJo Part We Used.	107
Table 9	Summary of Listener’s Corpus.	107
Table 10	Oxford Dictionary phone convention.	108
Table 11	Summary of the Oxford Dictionary AmE Corpus.	109
Table 12	Summary of Listener’s Corpus.	109
Table 13	CMUdict phone convention.	110
Table 14	Aeiouadô phone convention.	111
Table 15	Interlingual dictionary phone convention.	112
Table 16	Examples of final-obstruent devoicing in German.	113
Table 17	Distinctive features chart for AmE phones [35].	114
Table 18	Distinctive features chart for BP phones [35].	115
Table 19	Distinctive features chart for Listener phones.	116
Table 20	Autem usu id	127

## LISTINGS

---

Listing 1	Example of a fully-specified regex rule.	98
Listing 2	Pronunciation rules for generating syllable simplification cases.	99
Listing 3	Pronunciation rules for generating consonant change cases.	101
Listing 4	Pronunciation rules for generating plosive de-aspiration cases.	103
Listing 5	Pronunciation rules for generating terminal devoicing cases.	104
Listing 6	Pronunciation rules for generating lateral vocalization cases.	104
Listing 7	Pronunciation rules for generating nasal vocalization cases.	117
Listing 8	Pronunciation rules for generating velar paragogic cases.	118

Listing 9	Pronunciation rules for generating vowel assimilation cases.	118
Listing 10	A floating example	127

## ACRONYMS

---

AmE	American English
BP	Brazilian Portuguese
CC	Creative Commons
BSD	Berkeley Software Distribution
UML	Unified Modeling Language
ASR	Automatic Speech Recognition
HMM	Hidden Markov Model
CMUdict	Carnegie Mellon University Pronouncing Dictionary
HTK	Hidden Markov Model Toolkit
ASCII	American Standard Code for Information Interchange
IPA	International Phonetic Alphabet
BP	Brazilian Portuguese
DNN	Deep Neural Network
HSP	Heightened Subglottal Pressure
ATR	Advanced Tongue Root
ESL	English as a Second Language
regex	Regular Expression
SNR	Signal-to-Noise Ratio
POS	Part of Speech
MRI	Magnetic Resonance Imaging
CT	Computer Tomography
CG	Computer Graphics
CAPT	Computer Assisted Pronunciation Training

- Fo Fundamental Frequency  
VBR Variable Bit Rate  
CSR Continuous Speech Recognition  
PCM Pulse Code Modulation  
MFCC Mel Frequency Cepstral Coefficients  
PLP Perceptual Linear Prediction  
PER Phone Error Rate  
WER Word Error Rate  
RTF Real Time Factor  
TTS Text To Speech  
G2P Grapheme-to-Phoneme  
GMM Gaussian Mixture Model  
EF-EPI EF English Proficiency Index  
EF Education First  
CEFR Common European Framework of Reference  
BEI Business English Index  
HDI Human Development Index



## INTRODUCTION

---

Data from the World Economic Outlook, of the IMF (2013), list currently Brazil as the seventh largest economy in the world, with a GDP of US\$ 2,396 trillions. According to a survey by The Economist (2013), since 2009, the growth of BRICS (emerging market economies group formed by Brazil, Russia, India, China and South Africa) accounts for 55% of the world economy growth. The current economic scenario is extremely favorable for Brazil to increase its global influence.

However, with regard to the ability to communicate globally, we occupy a much more modest position. In the EF English Proficiency Index (EF-EPI) of 2014, which is published by Education First (EF), Brazil was ranked in the 38<sup>th</sup> position out of 63 countries, classified among countries with low English proficiency, with 49.96 points [24]. The full ranking is shown in Figure 1.

As can be noticed from Figure 1, Brazil was immediately behind two other countries from the BRICS, Russia (50.44) and China (50.15); and near several other Latin America countries, such as Peru (51.46), Ecuador (51.05), Uruguay (49.61), Chile (48.75) and Colombia (48.54).

Scandinavian countries lead the very high proficiency rankings, with Denmark (69.30) in the first position, Sweden (67.30) in third the spot, Finland (64.40) in the fourth and Norway (64.33) in the fifth. All these countries have a very high Human Development Index (HDI), according to the United Nations Development Programme. The HDI measures the social and economic development by analyzing three indexes: educational level, average income and longevity. The top five in the EF-EPI rankings are among the top twelve countries in terms of HDI [84]. The EF-EPI data showed that there is a moderate to strong correlation between HDI and English proficiency ( $R=0.67$ ) [24]. The second position in the EF-EPI ranking is held by the Netherlands, scoring 68.99 points. The Netherlands has the fourth largest HDI in the world. This result is similar to that of the previous versions of EF-EPI [23, 22, 21], which also showed a prevalence of Northern European countries in the best positions.

It is interesting to notice that four of the countries at the top five share a common cultural Germanic heritage and speak a language of the Germanic family – the same branch that English is part of. Since Danish, Swedish, Norse, Dutch and English are related through descent from a common ancestor, Proto-Germanic, they inevitably share many linguistic characteristics, such as sound correspondences, a large number of cognates, similar morphology and syntax, etc. This

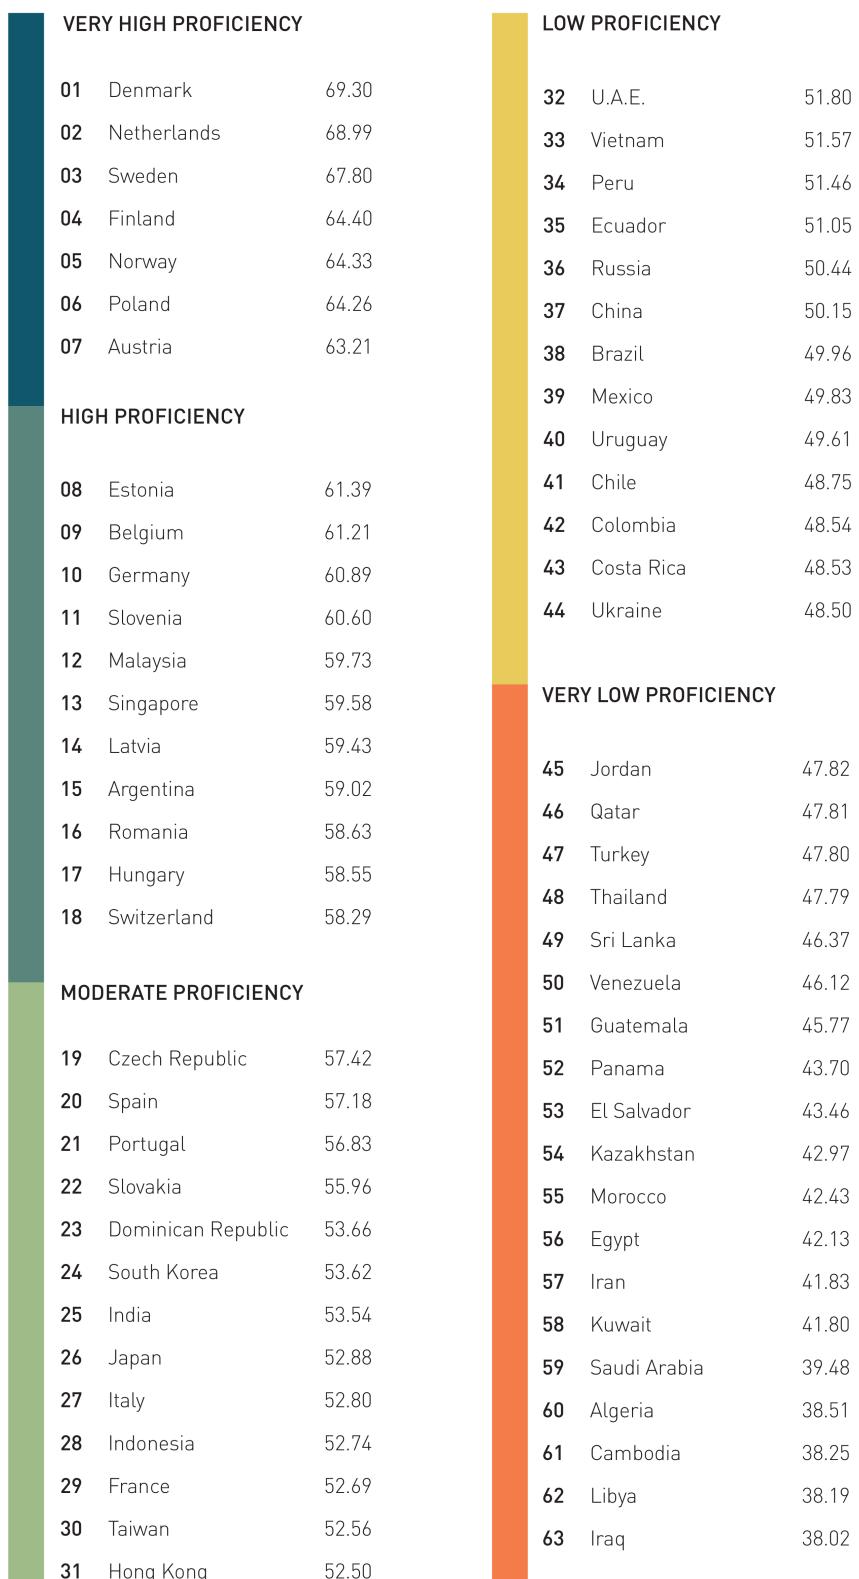


Figure 1: English Proficiency Index 2014 Rankings [24].

might be an advantage of these countries in comparison to the remaining.

The high proficiency band is occupied mainly by other European countries, both in the Eastern and Western part, such as Estonia (61.39), Belgium (61.21), Germany (60.89), Slovenia (60.60), Latvia (59.43) and Switzerland (58.29). Two Southeast Asian countries also figure within this range, namely Malaysia (59.73) and Singapore (59.58). This result might seem a bit biased since English is one of the official languages in Singapore, along with Malay, Mandarin and Tamil; it is considered the language of business, government, and the medium of instruction in school. We shall highlight Argentina's performance. Despite the great economic depression from 1998 to 2002, Argentina was still able to outperform Brazil, scoring 59.02 points, being the only country from Latin America among the ones with high proficiency.

The moderate proficiency range is filled by the remaining European countries, such as Czech Republic (57.42), Slovakia (55.96), the countries from the Iberian Peninsula – Spain (57.18) and Portugal (56.83)–, together with France (52.69) and Italy (52.80). In addition, the majority of Asian countries which were analyzed in the survey also figure in this list. South Korea achieved the best performance among them, with 53.62 points. India comes next, scoring 53.54 points. The rest of the list is occupied by Japan (52.88), Indonesia (52.74), Taiwan (52.56) and Hong Kong (52.50).

The EF-EPI bands are aligned to the Common European Framework of Reference (CEFR), which is a guideline proposed by the Council of Europe to describe achievements of learners of foreign languages across the European Union. The CEFR reference levels are described in Table 1. EF-EPI bands are mapped into CEFR reference levels as follows: the very high proficiency band corresponds to CEFR level B2; very low proficiency to A2; high, moderate and low proficiency bands to B1 with different punctuations.

In case, Brazil's low proficiency rank is analogous to the CEFR B1 level. To put another way, it means that Brazilians are usually able to communicate in English with intermediate skills, being able to understand familiar matters, deal with traveling situations, describe personal experiences and plans, and produce simple texts about subjects of personal interest. As one might observe this is a very restricted communicative competence, which limits English usage basically to the personal domain. To get an idea, the CEFR lists four broad domains: educational, occupational, public, and personal. So Brazilians lacks linguistic abilities in at least three broad domains, this linguistic competence would not allow one to perceive or produce English utterances flexibly, either for social, academic or professional purposes. The performance for each state can be found at the map in Figure 2.

Table 1: CEFR reference levels.

Group	Level	Description
<b>Basic User (A)</b>	<b>Beginner (A1)</b>	<p>Can understand and use familiar everyday expressions and very basic phrases aimed at the satisfaction of needs of a concrete type.</p> <p>Can introduce him/herself and others and can ask and answer questions about personal details such as where he/she lives, people he/she knows and things he/she has.</p> <p>Can interact in a simple way provided the other person talks slowly and clearly and is prepared to help.</p>
<b>Elementary (A2)</b>		<p>Can understand sentences and frequently used expressions related to areas of most immediate relevance (e.g. very basic personal and family information, shopping, local geography, employment).</p> <p>Can communicate in simple and routine tasks requiring a simple and direct exchange of information on familiar and routine matters.</p> <p>Can describe in simple terms aspects of his/her background, immediate environment and matters in areas of immediate need.</p>
<b>Independent User (B)</b>	<b>Intermediate (B1)</b>	<p>Can understand the main points of clear standard input on familiar matters regularly encountered in work, school, leisure, etc.</p> <p>Can deal with most situations likely to arise while traveling in an area where the language is spoken.</p> <p>Can produce simple connected text on topics that are familiar or of personal interest.</p> <p>Can describe experiences and events, dreams, hopes and ambitions and briefly give reasons and explanations for opinions and plans.</p>
	<b>Upper intermediate (B2)</b>	<p>Can understand the main ideas of complex text on both concrete and abstract topics, including technical discussions in his/her field of specialization.</p> <p>Can interact with a degree of fluency and spontaneity that makes regular interaction with native speakers quite possible without strain for either party.</p> <p>Can produce clear, detailed text on a wide range of subjects and explain a viewpoint on a topical issue giving the advantages and disadvantages of various options.</p>
<b>Proficient User (C)</b>	<b>Advanced (C1)</b>	<p>Can understand a wide range of demanding, longer texts, and recognize implicit meaning.</p> <p>Can express ideas fluently and spontaneously without much obvious searching for express</p> <p>Can use language flexibly and effectively for social, academic and professional purposes.</p> <p>Can produce clear, well-structured, detailed text on complex subjects, showing controlled use of organizational patterns, connectors and cohesive devices.</p>
	<b>Proficiency (C2)</b>	<p>Can understand with ease virtually everything heard or read.</p> <p>Can summarize information from different spoken and written sources, reconstructing arguments and accounts in a coherent presentation.</p> <p>Can express him/herself spontaneously, very fluently and precisely, differentiating finer shades of meaning even in the most complex situations.</p>



Figure 2: EF EPI scores for each Brazilian state.

As one might see from Figure 2, one can clearly see division between Southern and Northern Brazil. Ten states achieved very low proficiency, namely Amazonas, Acre, Pará, Roraima, Piauí, Alagoas, Tocantins, Rondônia, Maranhão and Mato Grosso. The highest scores are found among the richest Brazilian states, mainly in the Southeast and the South regions. The top position is held by São Paulo, which has the largest population, the highest number of industries, and most part of the economic production in the country. Rio de Janeiro, which is the second largest economy of Brazil, occupies the second position. Paraná is the third best ranked state. These three states are the only in the country that achieved moderate proficiency, they attained a score that is at least 4.8% above the country's average, and all of them are among those with the highest HDI.

With respect of Business English proficiency, our performance is even more concerning. On the 2013 Business English Index (BEI), conducted by GlobalEnglish [30], Brazil reached the 71<sup>st</sup> position out of 77 countries analyzed. The ranking is described in Figure 3. Brazil attained a score of 3.27 points, in a scale from 1 to 10, being placed at the “Beginner” range, the lowest proficiency range considered by

the index. Brazil's performance was close to that of El Salvador (3.24), Saudi Arabia (3.14) and Honduras (2.92) which up until recently had experienced civil wars or dictatorship governments. The "Beginner" is described as:

**BEGINNER:** Can read and communicate using only simple questions and statements, but can't communicate and understand basic business information during phone calls.

Again, we can see that this is a very limited linguistic competence, that would not allow one not even to perform the most elementary day-to-day tasks in a company or industry work environment.



Figure 3: 2013 Business English Index.

Given this scenario, it is clear that we desperately need to improve English language proficiency among Brazilians. This project seeks to be an initial step in that direction. We proposed a method for building a non-native speech recognizer and checker, called Listener, which is capable of recognizing utterances in Brazilian-accented English and identifying which are the mispronunciations. Our system might be used to build Computer Assisted Pronunciation Training (CAPT) systems for Brazilian-accented English. We also delivered a prototype CAPT system to illustrate how it might work.

Similar tools have been developed for other languages, such as Japanese [82], Spanish [66], Dutch [78] and French [? ]. However for Brazilian Portuguese (BP), to the best of our knowledge, there is still a gap to be explored.

CAPT systems can provide new opportunities for practicing oral proficiency. With respect to L2 pronunciation, it has been shown that when students have online corrective feedback about their mispronunciations, they can improve more quickly their pronunciation skills

[46, 47]. Nonetheless, in the classroom, teachers are not always able to provide this type of individual feedback given the number of students in a class and the amount of available hours in a English as a Second Language (ESL) course. CAPT systems can be a solution are able to assist with this matter, since they can assess one's pronunciation in real time at very low cost. According to Neri et al. [54], by using CAPT, students are able improve their pronunciation skills a similar pace to those who attend traditional classrooms.

### 1.1 RESEARCH HYPOTHESES

The research hypotheses are:

About the acoustic model:

1. cross-linguistic acoustic models, estimated from native data – in case, BP and English – are suitable for recognizing Brazilian-accented English;
2. a small amount of data from Brazilian-accented English might be used, through speaker adaptation, to increase the recognition performance;
3. phonetically rich corpora are more appropriate for building acoustic models which will be used for forced alignment tasks than balanced corpora.

About the pronunciation dictionary:

1. Brazilian-accented negative transfer phenomena can be represented through transformation rules;
2. non-native pronunciation variants can be handled similarly to native variation, by using a multi-pronunciation dictionary;
3. phones which are acoustically similar in English and BP might be merged in the pronunciation dictionary to improve the recognition performance.

About the speech recognizer and checker:

1. an HMM/GMM Automatic Speech Recognition (ASR), with acoustic parameters estimated from a cross-linguistic corpora (from both English and BP), with a multi-pronunciation dictionary which include Brazilian-accented variants created through transformation rules, is an adequate method for recognizing and identifying mispronunciations in forced alignment tasks containing Brazilian-accented English.

## 1.2 CONTRIBUTIONS OF THE THESIS

Within this work, we have provided a set of tools and resources for non-native speech recognition and correction, focused on Brazilian-accented English. Some of these resources and tools are exclusively for tasks related to processing Brazilian-accented English, but others are more general and can be employed for many other purposes, such as a Grapheme-to-Phoneme (G2P) for BP, a method for the extraction of phonetically rich sentences from a corpus, etc. The full list of contributions is found below.

1. *Aeiouadô G2P*: A grapheme-to-phoneme converter for BP which uses a hybrid approach, based on both handcrafted rules and machine learning method, as described in Mendonça and Aluísio [50];
2. *Aeiouadô dictionary*: A large machine readable dictionary for BP, compiled from a word list extracted from the Portuguese Wikipedia, which was preprocessed in order to filter loanwords, acronyms, scientific names and other spurious data, and then transcribed with Aeiouadô G2P).
3. A method for the extraction of phonetically rich sentences, i.e. sentences with a high variety of triphones distributed in a uniform fashion, which employs a greedy algorithm for comparing triphone distributions among sentences, as described in Mendonça et al. [51];
4. A set of rules for generating pronunciation hypothesis for Brazilian-accented English, considering nine types of mispronunciations, respectively: (i) syllable simplification; (ii) consonant change; (iii) deaspiration of voiceless plosives in initial or stressed positions; (iv) terminal devoicing in word-final obstruents; (v) de-lateralization and rounding of lateral liquids in final position; (vi) vocalization of final nasals; (vii) velar consonantal paragogic; (viii) vowel assimilation; (ix) interconsonantal epenthesis;
5. A phonetic speller for user-generated content in BP, based on machine learning, which makes use of Aeiouadô G2P to group phonetically related words, as described in Mendonça et al. [52];

All files, resources and scripts developed are available at the project website<sup>1</sup>:

<http://nilc.icmc.usp.br/listener>

---

<sup>1</sup> Due to copyright reasons, the corpora used for training the acoustic models cannot be made available.

### 1.3 THESIS STRUCTURE

This Master's thesis is organized into parts, chapters and sections according to the following. Part i presents some basic concepts and notions which are necessary for further reading. Chapter 2 discusses the fundamentals of Phonetics and Phonology. Chapter 3 debates Second Language Acquisition, which is the area of Applied Linguistics responsible for studying how one acquires an additional language and what are the implications throughout the learning process. In Chapter 4 we provide an overview of speech recognition systems. In Part ii, some related work is discussed. Part iii is the last one and describe the design of Listener. Chapter 7 contains a detailed discussion of methods. The results are presented in Chapter 8. Finally in Chapter 9, we outline some final remarks and plan the next steps for future work.



## Part I

### SOME FUNDAMENTAL CONCEPTS

This part addresses some fundamental concepts in Linguistics, Acoustics, and Automatic Speech Recognition.



# 2

## PHONETICS AND PHONOLOGY

---

Lorem ipsum at nusquam appellantur his, ut eos erant homero concludaturque. Albucius appellantur deterruisset id eam, vivendum partiendo dissentiet ei ius. Vis melius facilisis ea, sea id convenire referrentur, takimata adolescens ex duo. Ei harum argumentum per. Eam vedit exerci appetere ad, ut vel zzril intellegam interpretaris.

Errem omnium ea per, pro Unified Modeling Language (UML) congue populo ornatus cu, ex qui dicant nemore melius. No pri diam iriure euismod. Graecis eleifend appellantur quo id. Id corpora inimicus nam, facer nonummy ne pro, kasd repudiandae ei mei. Mea menandi mediocrem dissentiet cu, ex nominati imperdiet nec, sea odio duis vocent ei. Tempor everti appareat cu ius, ridens audiam an qui, aliquid admodum conceptam ne qui. Vis ea melius nostrum, mel alienum euripidis eu.

### 2.1 THE PHONETIC INVENTORY OF BRAZILIAN PORTUGUESE

Non vices medical da. Se qui peano distinguer demonstrate, personas internet in nos. Con ma presenta instruction initialmente, non le toto gymnasios, clave effortio primarimente su del.<sup>1</sup>

### 2.2 THE PHONETIC INVENTORY OF AMERICAN ENGLISH

Non vices medical da. Se qui peano distinguer demonstrate, personas internet in nos. Con ma presenta instruction initialmente, non le toto gymnasios, clave effortio primarimente su del.<sup>2</sup>

---

<sup>1</sup> Uno il nomine integre, lo tote tempore anglo-romanic per, ma sed practic philologos historiettas.

<sup>2</sup> Uno il nomine integre, lo tote tempore anglo-romanic per, ma sed practic philologos historiettas.



# 3

## SECOND LANGUAGE ACQUISITION

---

Illo principalmente su nos. Non message *occidental* angloromanic da. Debitas effortio simplificate sia se, auxiliar summarios da que, se avantiate publicationes via. Pan in terra summarios, capital interlingua se que. Al via multo esser specimen, campo responder que da. Le usate medical addresses pro, europa origine sanctificate nos se.

*Definition.*

### 3.1 PB

Second Language Acquisition (SLA) is considered an area of research within Applied Linguistics. Much of its efforts are dedicated to the interaction between one's native language (called **L<sub>1</sub>!** (**L<sub>1</sub>!**)) and second language (L<sub>2</sub>), while one is learning an additional language. It is known that **L<sub>2</sub>!** (**L<sub>2</sub>!**) acquisition inevitably encompasses negative transfer from L<sub>1</sub> to L<sub>2</sub>, [90] sums up the problem:

Quando nos deparamos com uma língua estrangeira, a tendência natural é que interpretemos seus sons a partir dos sons de nossa própria língua. Analogamente, quando falamos uma língua estrangeira, tendemos a utilizar os sons e os padrões sonoros de nossa língua nativa.

In what regard to the process of learning an additional language, [43] proposed the well-known Critical Period Hypothesis to explain the different levels of proficiency that people show. The hypothesis claim that the ability to acquire language is biologically linked to age, in a way that there is an ideal time window to acquire a language, after which language acquisition becomes difficult and deteriorated. In its initial formulation, the critical period was set to the age between two years and puberty.

Diversos pontos da formulação inicial da hipótese do período crítico já foram rebatidos; seu cerne, isto é, a ideia de que haja um tempo ideal específico para a aquisição de língua adicional, já foi revisada e a Hipótese do Período Crítico é, hoje, reinterpretada (Hylténstam & Abrahamsen, 2000). No que se crê, atualmente, é que restrições maturacionais, aliadas a fatores sócio-psicológicos, podem atuar de modo a tornar o aprendizado mais lento após a puberdade. Qualquer um, portanto, que se proponha a aprender uma língua após a puberdade, tenderá a desenvolver um sotaque estrangeiro. Esse sotaque é caracterizado, principalmente, pela transferência de padrões do sistema fonológico da L<sub>1</sub> para a L<sub>2</sub> e, também, pela transferência de padrões de correspondência entre letra e som da L<sub>1</sub> para a L<sub>2</sub> (Zimmer & Alves, 2006). O aprendiz tende a produzir na L<sub>2</sub> padrões

acústico-articulatórios idênticos ou semelhantes aos de sua L<sub>1</sub>, além de tender a tratar as unidades acústico-articulatórias da L<sub>2</sub> como se fossem as da L<sub>1</sub> (Zimmer, 2004).

Como exemplo, considere-se a realização das consoantes oclusivas [p, t, k] no inglês e no PB. No inglês, tais consoantes além de ocorrerem em onset silábico[4], também podem ocorrer posição de coda[5], de modo a compor uma sílaba travada. Há, portanto, palavras como ['pi?s] 'piece', ['ta?m] 'time' e ['kÃŠn] 'can', bem como ['b?k] 'book', ['st??rt] 'start' e ['w???k] 'work'. No PB, por sua vez, tais oclusivas ocorrem apenas em onset silábico, de modo que o aprendiz de L<sub>2</sub>, ao lidar com oclusivas em final de sílaba, tende a transferir as características de sua L<sub>1</sub> para L<sub>2</sub>, realizando, assim, epênteses e processos de ressilabificação no propósito de reorganizar a estrutura silábica. Por exemplo, a Figura 1 apresenta a representação autossegmental (Selkirk, 1982) da palavra 'book' na pronúncia padrão do inglês e na pronúncia com transferência do PB para o inglês.

Figura 1: Realização da palavra 'book' na pronúncia padrão do inglês [1]; realização da palavra 'book' com transferência do PB para o inglês [2]

Como se observa, a pronúncia padrão na língua inglesa da palavra 'book' é ['b?k]. No entanto, como no PB oclusivas não ocorrem em posição de coda, o aprendiz tende a realizar a palavra a partir dos padrões fonológicos que conhece em L<sub>1</sub>, efetuando a epêntese do [i, ?] e ressilabificando a palavra, de modo a transformá-la de monossílaba a dissílaba: ['b?k] > ['bu.k?]. No processo de comunicação entre um nativo e um aprendiz, é como se o nativo tivesse como representação mental /'b?k/ e realizasse na fala ['b?k], mas o aprendiz percebesse tal realização como /'bu.k?/ e, então, realizasse em sua fala ['bu.k?] (cf. Figura 2).

Figura 2: Esquema de um processo dialógico entre um nativo e um aprendiz.

O sotaque estrangeiro, fruto dessa transferência de padrões de L<sub>1</sub> para a L<sub>2</sub>, pode trazer prejuízo ao processo comunicativo. No exemplo ilustrado pela Figura 2, o aprendiz altera a qualidade da vogal esperada [?] e modifica a estrutura silábica da palavra, realizando uma palavra monossilábica como dissilábica. A consequência disso é que o nativo se depara com uma sequência de fones, ['bu.k?], que não é prevista em sua língua, e a ele, então, cabe a tarefa de decodificar essa sequência de fones, mapeando-a numa sequência que apresente um padrão fonético similar e existente em sua língua, no caso, ['b?k]. Esse processo, no entanto, nem sempre é efetivo. Em muitas vezes, o padrão de pronúncia apresentado pelo aprendiz é tão distinto do esperado, que o interlocutor é incapaz de decodificar a mensagem.

Além disso, o prejuízo na comunicação ocorre não apenas em processos dialógicos de aprendizes e nativos, mas também entre aprendizes que possuem línguas-nativas distintas. Em um estudo de Major

et al. (2002), falantes não-nativos de inglês foram avaliados em tarefas de listening, ao ouvir áudios de falantes nativos e de aprendizes com diferentes L1 de background. O melhor desempenho na tarefa se deu quando os sujeitos eram expostos a áudios de falantes nativos. Os sujeitos também desempenharam melhor quando ouviam aprendizes que possuíam a mesma L1 (por exemplo, chineses compreendiam melhor o inglês falado por outros chineses, que o inglês falado por um espanhol). O problema do sotaque estrangeiro é que, em muitas vezes, os aprendizes realizam tantos processos de transferência de L1 para L2, que se torna difícil a decodificação da mensagem, seja por um nativo ou por aprendiz que possua outra L1 como base. A título de exemplo, tome-se a pronúncia da palavra 'smooth' por brasileiros com pouca proficiência em inglês. Devido à transferência de padrões fonético-articulatórios e também de correspondência grafo-fonêmica, uma possível pronúncia de 'smooth', por esses indivíduos, seria [iz'mu.f?], sendo que o padrão esperado é ['smu:Ã°]. Isto é, a sequência de fones é modificada quase por completo, consequentemente, o grau de inteligibilidade da comunicação decai, uma vez que se torna improvável que o interlocutor seja capaz de decodificar ['smu:Ã°] a partir de [iz'mu.f?].

Não bastasse isso, o sotaque estrangeiro afeta não apenas a inteligibilidade do discurso, mas também a forma como o indivíduo é percebido por seu interlocutor. Segundo Fuertes et al. (2002), o sotaque tem função sócio-cultural, impactando, em uma situação de diálogo, na representação que os falantes criam uns dos outros, seja no que diz respeito ao status do interlocutor (inteligência, escolaridade, classe social e êxito profissional) ou de seu nível de solidariedade (simpatia, confiabilidade e bondade).

Um maior nível de proficiência, portanto, é de interesse de modo a facilitar a comunicação e a aumentar o nível de prestígio do aprendiz a partir de seu sotaque. Cabañero e Alves (2008) ressaltam que, no que concerne à aprendizagem de padrões fonético-fonológicos da língua-alvo, a instrução explícita facilita o processamento do input, sendo capaz de tornar o aprendiz consciente da transferência, dessa forma, contribuindo para uma diminuição do reforço do padrão de sua L1. Em outras palavras, é preciso que o aprendiz seja informado do que, em sua pronúncia foge ao padrão, de forma a poder corrigi-la. No exemplo da Figura 2, o brasileiro aprendiz necessita de ser informado, de forma explícita, sobre a alteração da qualidade vocálica de [?] para [u] e, também, da inserção da vogal final em sua pronúncia da palavra "book". Somente assim ele será capaz de ter consciência da existência do fenômeno e, a partir disso, poder modificar sua pronúncia.

Celce-Murcia et al. (1996) propõem que o ensino de pronúncia de L2 deve ser constituído por cinco fases: (i) descrição e análise; (ii) audição discriminativa; (iii) produção controlada com feedback; (iv)

produção guiada com feedback; (v) produção em contexto comunicativo com feedback. As duas fases iniciais dizem respeito à percepção do fenômeno pelo aluno, as demais referem-se à sua realização. No quadro proposto pelas autoras, o aprendizado inicia-se na descrição e análise do fenômeno, quando o aprendiz é posto em contato com textos que descrevem a existência do fenômeno de pronúncia em questão, suas características acústico-articulatórias e, também, o contexto em que ele ocorre. A seguir, passa-se à audição discriminativa do fenômeno. Nessa fase, áudios são apresentados ao aprendiz e a ele cabe a tarefa de discernir em quais deles o fenômeno de pronúncia ocorre. Tendo o aprendiz desenvolvido consciência do fenômeno, iniciam-se as três fases de produção. A intenção é desenvolver, gradativamente, a capacidade do aprendiz de produzir o fenômeno, partindo-se de um contexto controlado (palavras e sentenças em isolamento), passando por atividades guiadas (em que temas ou situações de diálogo são simuladas) até chegar a situações comunicativas reais.

## 2 Ensino de Pronúncia Específico para Falantes do Português Brasileiro

É extensa a literatura existente para o ensino da pronúncia do inglês, em suas diversas variantes (Halliday, 1970; Jones, 1976; O'Connor, 1980; Clifford, 1985; Kreidler, 1989; Ladefoged, 1993; Dalton & Seidlhofer, 1994; Gilbert, 2000; Kenworthy, 2000; Staun, 2010; Ogden, 2012). Embora haja um grande número de obras publicadas sobre o assunto, a grande maioria dos trabalhos publicados desconsidera a língua nativa do aprendiz e, consequentemente, todo o conhecimento linguístico implícito que advém desse fato (Cristófaro-Silva, 2012).

As obras mencionadas são, em sua maioria, fruto de publicações de editoras com grande entrada no mercado internacional, que vendem o mesmo livro de pronúncia, sem adaptações, seja no Brasil, na China, na França, na Alemanha, na Rússia ou onde quer que seja. No entanto, dada a diferença entre as línguas, o conhecimento linguístico implícito que um brasileiro possui é muito diferente daquele que um chinês falante de Mandarim possui, por exemplo. A título de ilustração: o PB é uma língua indo-europeia, românica, flexiva, com distinção de gênero morfológico (masculino e feminino) e vogais nasais com status fonêmico; por sua vez, o Mandarim é uma língua sino-tibetana, chinesa, isolante, com seis tipos de classificadores e tons com status fonêmico (Weinberger, 2013; Lewis et al., 2013). Dado este cenário é natural que, caso um brasileiro e um chinês decidam aprender inglês, aspectos distintos da língua inglesa devem ser enfatizados para cada um deles. Sendo assim, o ensino de língua estrangeira precisa considerar o conhecimento linguístico que o falante já possui em razão de sua língua nativa, buscando apresentar as características da língua adicional que são comuns à sua língua nativa e enfatizar os aspectos que lhe são diferentes, a fim de aumentar a capacidade comunicativa do aprendiz.

No Brasil, são poucos os trabalhos publicados na área de ensino de pronúncia de inglês que estabelecem um método de ensino baseada no conhecimento de língua que o falante do PB já possui. Destacam-se as iniciativas de Godoy et al. (2006), Zimmer et al. (2009) e Cristófaro-Silva (2012).

### 3 Fonética, Fonologia e as Unidades de Descrição da Fala

A Fonética e a Fonologia são os ramos de estudo da Linguística que investigam a sonoridade da fala (Cristófaro-Silva & Yehia, 2008). A fala humana é, por natureza, um fenômeno contínuo. Quer se a tome em seu nível de produção articulatória, por meio do estudo da movimentação de articuladores do trato vocal, quer em seu nível de percepção acústica, por meio do estudo de variações na pressão do ar, a fala sempre se manifesta como um fenômeno que se desenvolve continuamente no tempo. Todavia, a Fonética e a Fonologia[6] postularão que é possível descrevê-la por meio de unidades discretas.

A Fonética baseia-se no estudo dos fones que compõem a fala. Um fone constitui a menor unidade discreta perceptível do contínuo da fala (Crystal, 2008). Fones são unidades concretas, reais, que podem ser descritas a partir de suas propriedades acústico-articulatórias. Usualmente, os fones são representados através dos símbolos do Alfabeto Fonético Internacional (IPA, 2005), que arrola todos os sons capazes de serem produzidos pelo aparelho fonador humano (Figura 3).

A título de exemplo: a palavra “ciência”, tal como é usualmente pronunciada no PB, poderia ser transcrita pela sequência de fones [si’e?si?][7], isto é, uma consoante fricativa alveolar desvozeada [s]; uma vogal alta anterior não-arredondada [i]; uma vogal média-alta anterior não-arredondada nasalizada [e?], com acento primário; uma consoante fricativa alveolar desvozeada [s]; uma vogal alta anterior não-arredondada [i]; e, por fim, um schwa [?].

Figura 3: Alfabeto Fonético Internacional (IPA, 2005).

A Fonologia, por sua vez, fundamenta-se no estudo dos fonemas da fala, tendo por base o chamado princípio fonêmico. Tal princípio foi sistematizado por Swadesh (1934) e estabelece que:

cada língua possui um número limitado de sons elementares, os quais recebem o nome de fonemas, que formam, em conjunto, o chamado inventário fonémático das línguas;

cada som produzido ao se falar possui correspondência com um desses sons elementares, com um fonema da língua;

os fonemas possuem valor significativo nas línguas, isto é, possuem capacidade de distinguir o significado das palavras.

A Fonologia propõe que as línguas do mundo são formadas por um inventário fechado de sons com valor significativo, os fonemas. Fonemas são, portanto, unidades abstratas, não realizadas, que são descritas a partir de sua função significativa em uma dada língua. O método utilizado para a identificação é o “teste da comutação” (Fages, 1967). Basicamente, tal teste consiste em gerar pegar um de-

terminado enunciado, mudar, artificialmente, parte dele e observar se a mudança gerou também uma mudança no significado. Em outras palavras, consiste em modificar fones de uma palavra, observar se com essa modificação houve mudança no significado e, então, a partir dessa mudança ou não no significado, concluir se os fones modificados são fonemas da língua.

Assim, para o português brasileiro, o teste da comutação prevê que o fato de se poder mudar o sentido da palavra [’gat?̩] ao enunciá-la trocando seu som inicial [g] por [p], obtendo-se [’pat?̩], implica que [g] e [p] têm valor distintivo na língua e que esses sons são, portanto, fonemas, logo /g/ e /p/. Por outro lado, a realização da palavra ‘mar’ como [’mar] ou [’mah] não altera o significado da palavra, tanto [’mar] quanto [’mah] referem-se à mesma porção de água. Infere-se, a partir disso, que, como a substituição de [r] por [h] não alterou o sentido da palavra, não constituem dois fonemas distintos, mas sim dois alofones de um mesmo fonema, no caso, o comum para o PB é considerá-los pertencentes ao arquifonema /R/.

#### 4 Descrição do Inventário Fonético do Português Brasileiro e do Inglês Americano

Na estrutura do Listener, será assumido, para o inglês americano, o inventário fonético descrito por Ogden (2012); e para o PB, o descrito por Cristófaro-Silva (2005). Os Quadro 1 a 4 sintetizam o conjunto de fones que tais autores propõem para cada uma das línguas.[8]

Quadro 1: Fones consonantais do português brasileiro

[pic]

Conforme se observa no Quadro 1, o inventário fonético consonantal do PB é composto por 26 sons: seis oclusivos [p, b, t, d, k, g], dois africados [t?, d?], três nasais [m, n, ?], um tepe [?], dez fricativos [f, v, s, z, ?, ?, x, ?, h, ?], dois aproximantes [j, w] e dois laterais [l, ?].

Quadro 2: Fones consonantais do inglês americano.

[pic]

De acordo com a classificação proposta por Ogden (2012), que consta no Quadro 2, as consoantes do inglês podem ser descritas a partir de um conjunto de 24 fones, a saber: seis oclusivos [p, b, t, d, k, g], dois africados [t?, d?], três nasais [m, n, ?], nove fricativos [f, v, s, z, ?, h], três aproximantes [r, j, w] e um lateral [l].

Segundo Cristófaro-Silva (2005), as vogais do PB contabilizam quinze segmentos, sendo dez orais [a, ?, ?, e, i, ?, ?, o, u, ?] e cinco nasais [ã, e?, i?, o?, u?] (Quadro 3).

Quadro 3: Vogais do português brasileiro

[pic]

A distribuição pode ser feita a partir de quatro níveis, dados pela posição da língua. Há seis vogais com articulação alta [i, ?, i?, u, ?, u?], quatro com média-alta [e, e?, o, o?], duas com média-baixa [?, ?] e três com articulação da língua em posição baixa [a, ?, ã]. Todas as vogais anteriores e centrais [a, ?, ã, ?, e, e?, i, ?, i?] são não-arredondadas, já

as posteriores [?, o, o?, u, ?, u?] são realizadas com arredondamento dos lábios.

#### Quadro 4: Vogais do inglês americano [pic]

Para o inglês americano, há apenas vogais orais (Quadro 4). O número de segmentos totaliza onze, sendo que destes cinco são longos [a?, ??, i?, ??, u?] e seis breves [ÃŠ, ?, ?, ?, ?, ?]. Há quatro classes de vogais, definidas a partir da posição da língua: quatro vogais altas [i?, ?, u?, ?], uma média [?], quatro médias-baixas [?, ?, ??, ??] e duas baixas [ÃŠ, a?].

Quanto aos ditongos, o PB apresenta um total de vinte e três ditongos, entre orais e nasais. Há onze ditongos orais decrescentes, seis dos quais terminados [?]: [a?, ??, e?, ??, o?, u?], e cinco em [?]: [a?, ??, e?, o?, i?]. Os ditongos crescentes são sete, quatro iniciados por [?]: [??, ?i, ?o, ??], e três por [?]: [??, ??, ?u]. Por sua vez, os ditongos nasais somam cinco: [ã?, ??, õ?, ??, ã?]. No inglês, há apenas ditongos orais e todos decrescentes. Três deles têm [?] como semivogal: [a?, e?, ??], e dois [?]: [a?, o?].

#### 5 Levantamento dos Desvios de Pronúncia

Na classificação dos erros de pronúncia, deu-se prioridade, especialmente, aos erros de pronúncia que afetam a compreensão e que são apresentados em trabalhos que consideram, no ensino da pronúncia do inglês, a transferência de padrões sonoros de L<sub>1</sub> para L<sub>2</sub>.

A listagem dos erros de pronúncia a serem considerados pelo Listener

foi obtida a partir da consulta aos trabalhos de Zimmer (2004), Godoy (2005), Zimmer et al. (2009) e Cristófaro-Silva (2012). Tais trabalhos analisam, de forma ampla, os aspectos de transferência de L<sub>1</sub> para L<sub>2</sub> que afetam a pronúncia de brasileiros aprendizes de inglês. No verificador de pronúncia, optou-se por utilizar os nove tipos de erros elencados em Zimmer et al. (2009), por se tratar, ao nosso ver, da investigação mais abrangente sobre o assunto. Os desvios de pronúncia selecionados estão descritos e exemplificados no Quadro 5.

#### [pic]

#### Quadro 5: Desvios de pronúncias a ser analisados pelo Listener.

Nas Seções de 2.1.1.4.1 a 2.1.1.4.9, será apresentado, em maior nível de detalhe, cada um desses desvios de pronúncia.

#### 6 Simplificação silábica

Definimos como simplificação silábica os processos que ocorrem, na interlíngua, de modo a simplificar encontros consonantais complexos, através da epêntese de [i] ou [?] e da consequente ressilabificação da sílaba original. A simplificação silábica envolve os seguintes contextos: quando /p/, /t/, /k/, /b/, /d/ ou /g/ ocupam posição de coda; e quando a palavra se inicia por um cluster do tipo /sC/.

Na língua inglesa, todas as consoantes, exceto /h/, podem ocorrerem em posição final de sílaba ou palavra; comparativamente, no PB,

apenas um inventário limitado de consoantes pode ocupar posições finais sílaba ou palavra: /r/ e seus alofones, a lateral /l/, as nasais /m/, /n/ e /?/ e as sibilantes /s/ e /z/ (Silveira 2012). Não bastasse isso, no PB, esses fonemas estão sujeitos a processos fonológicos em contexto final de sílaba, de modo a limitar ainda mais a distribuição: /r/ pode ser apagado “sair” [sa’i], /l/ sofre vocalização “sal” [’saw], as nasais nasalizam a vogal anterior e perdem seu traço consonantal “som” [’sõ], e a sibilante /z/ se torna desvozeada “voz” [’v?s]. Por essa razão, os aprendizes tendem a realizar, na interlíngua, processos de simplificação silábica, de modo a evitar consoantes não permitidas em coda no PB e, também, encontros consonantais tautossilábicos que não ocorrem em sua língua nativa. Post (2010) refere-se à simplificação silábica como uma estratégia de reparo: os padrões da L2 que são proibidos na L1 são alterados pelo aprendiz, na interlíngua, de modo a condizerem com padrões existentes na L1.

A simplificação silábica na interlíngua envolve a epêntese de [i] ou [?] e a ressilabificação da sílaba original. Tome-se como exemplo a palavra inglesa monossilábica “dog”, cuja pronúncia canônica é [’d?g]. Como a consoante [g] não ocorre em coda no PB, o aprendiz acaba por inserir uma vogal epentética no final da palavra e por ressilabificá-la, realizando o dissílabo [’d?.g?]. A pronúncia [’d?.g?], portanto, obedece aos padrões fonotáticos do PB, que não permitem a ocorrência da consoante [g] em coda. À Segundo Silveira (2012), a simplificação silábica ocorre não apenas de modo a evitar consoantes proibidas em coda ou encontros consonantais tautossilábicos, há também casos de simplificação por transferência do conhecimento de decodificação letra-som de L1 para L2. Palavras com um mesmo contexto fonético na língua-alvo, como “ham” [’ham] e “name” [’ne?m], tiveram realizações distintas pelos aprendizes em virtude do ortográfico final. A primeira foi realizada com nasalização da vogal anterior e perda do traço consonantal da consoante: [’hã], enquanto a segunda foi realizada com epêntese da vogal [?] seguida de ressibilificação: [’ne?.m?]. Como na escrita do PB, um final indica a realização da vogal [?], o aprendiz transfere esse conhecimento para a interlíngua e isso interfere na sua pronúncia. Analisando palavras terminadas foneticamente em [m], [n] e [l]; e ortograficamente em , , ; Silveira (2012) constatou que cerca de 10,1% das realizações continham epêntese ( $n = 930$ ), sendo que as palavras terminadas em <-e>, o percentual foi de 33,0% ( $n = 130$ ).

A baixa taxa de realização de simplificação silábica poderia ser interpretada tendo em vista a população analisada. Os sujeitos analisados por Silveira (2012) possuíam proficiência avançada em inglês e moravam, em média, havia 7,5 anos nos Estados Unidos. Todavia, resultados semelhantes são descritos em Zimmer (2009), que analisou casos de simplificação silábica por aprendizes de vários níveis de proficiência, em tarefas de leitura de palavras e não-palavras. Zim-

mer (2009) verificou que a simplificação silábica ocorreu em 7,9% ( $n = 936$ ) dos dados. No nível iniciante, a simplificação silábica ocorreu em 16,7% das realizações dos sujeitos; já no avançado, nenhum caso de epêntese foi registrado.

Delatorre (2009) investigou casos de simplificação silábica no morfema verbal regular de passado {-ed}[9], com sujeitos de proficiência intermediária em inglês. Em tarefas de leitura, a epêntese ocorreu em 71,8% das realizações dos aprendizes ( $n = 1927$ ); já em situações de diálogo, a taxa foi de 61,8% ( $n = 199$ ). Como o morfema {-ed} envolve outros processos fonológicos, além da simplificação silábica, optamos por tratá-lo separadamente, na Seção 2.1.1.4.9.

Rauber e Baptista (2004) também constataram estratégias de simplificação silábica por aprendizes na realização de clusters consonantais iniciais do tipo /sC(C)/, como em “star” [st?r] ou “strike” [str??k]. Como em PB não há onsets complexos em início de palavra, os aprendizes tendem a inserir um [i] epentético antes de /s/, transformando o encontro tautossilábico em heterossilábico: /sC/ > [is.C]. Sendo assim, “star” tende a ser realizado, na interlíngua, como [is’t?r] e “strike” como [is’tr??k]. No estudo, as autoras reportaram uma taxa de simplificação silábica de 29,0% ( $n = 866$ ) para casos de /sC/, e de 38,6% ( $n = 627$ ) para casos de /sCC/. Além disso, elas indicaram que outros processos fonológicos também foram verificados nos dados, como o vozeamento de /s/ diante de consoantes vozeadas, passando a [z], a exemplo de “small” [iz’m?l]. Os participantes foram estudantes de Letras do bacharelado em Inglês, de conhecimento intermediário a avançado da língua inglesa, os quais cursavam o segundo ou o terceiro ano da graduação.

Rebelo e Baptista (2007) analisaram, também, o contexto /sC(C)/ inicial, todavia, reportaram taxas de ocorrência do fenômeno consideravelmente mais altas: 54,3% para clusters iniciais do tipo /sC/ ( $n = 460$ ) e 59,0% para /sCC/ ( $n = 768$ ). As diferenças podem ser justificadas em virtude da população analisada em cada um dos estudos, Rebelo e Baptista (2007) lidaram com sujeitos de proficiência mais baixa que Rauber e Baptista (2004).

## 7 Substituição consonantal

Denominamos substituição consonantal os casos envolvendo a substituição do par de interdentais [?] e [Ã°] do inglês, por [f], [v], [s], [z], [t], [d] ou correspondentes; e, também, a substituição da aproximante [?] por um rótico análogo no PB: [x], [?], [h], [?] ou [?].

A substituição consonantal de [?] e [Ã°] ocorre em razão de tais fones inexistirem no inventário fonético do PB, dessa maneira, o aprendiz tende a perceber e a produzir esses sons pelo viés de sua língua nativa, o inventário fonético do PB. A articulação de [?] e [Ã°] é considerada complexa não apenas por aprendizes de inglês como língua estrangeira. Vihman (1996) pesquisou a aquisição fonológica do inglês por crianças norte-americanas, tendo constatado que as inter-

dentais [?] e [Ã°] constituem o par de fones que as crianças mais demoram a adquirir, dada sua complexidade articulatória. Seguindo a Teoria da Marcação de Eckman (1977), as interdentais [?] e [Ã°] podem ser consideradas fones marcados, uma vez que são pouco frequentes nas línguas do mundo e disso advém a dificuldade de articulá-las.

É interessante ressaltar que o aprendiz brasileiro de inglês mapeia [?] e [Ã°] em fones já existentes no PB não de modo aleatório, mas de modo a maximizar a semelhança acústica e articulatória. As consoantes [?] e [Ã°] são fricativas interdentais, e como se mostrará a seguir, elas tendem a ser substituídas por consoantes do PB que mantêm o mesmo modo e/ou ponto de articulação, a exemplo de outras fricativas anteriores, como as labiodentais [f] e [v], ou as alveolares [s] e [z]; ou a exemplo das oclusivas alveolares [t] e [d].

Schadech e Silveira (2013) avaliaram o quanto a produção de [?] e [Ã°] por aprendizes afeta a inteligibilidade da mensagem por nativos. As autoras realizaram um experimento em que tocaram gravações de brasileiros aprendizes de inglês, pronunciando palavras contendo [?] e [Ã°], para dez falantes nativos de inglês. Muitas das gravações continham pronúncias com influência de L<sub>1</sub> em L<sub>2</sub>, de maneira que os aprendizes substituíam [?] e [Ã°] por [f], [v], [s], [z], [t] ou [d]. O grau de inteligibilidade foi mensurado pelos nativos através de questionários, em que deviam marcar, em uma escala variando de “muito fácil” a “muito difícil”, qual o grau de inteligibilidade da gravação. Os resultados indicaram que, de acordo com os nativos, a substituição de [?] tem mais impacto na inteligibilidade que a substituição [Ã°]: [?] foi classificado como de compreensão “não muito fácil” e de [Ã°] como “fácil”.

Reis (2006) investigou a produção das interdentais [?] e [Ã°] por aprendizes de proficiência intermediária-baixa e avançada, em tarefas de leitura de sentenças, textos e retelling, constatando baixas taxas de acerto para ambos os fones. Considerando as três tarefas, os sujeitos de nível intermediário-baixo realizaram [?] em 16,6% dos contextos (n = 489) e [Ã°] em apenas 0,1% dos casos (n = 494). Já os de nível avançado conseguiram produzir corretamente [?] em 41,3% dos casos (n = 499) e [Ã°] em 7,5% (n = 610). Embora os resultados tenham se mostrado estatisticamente significativos, a autora salienta que as baixas taxas de realização de [Ã°] podem ter sido enviesadas em virtude do número reduzido de participantes no estudo: havia 16 informantes de proficiência intermediária-baixa e 8 de avançada. De todo modo, ainda que não se possa ter precisão sobre o percentual de acerto dos fones, os resultados indicam que os aprendizes têm altas taxas de erro na produção das interdentais e que se trata, portanto, de uma dificuldade de pronúncia dos aprendizes brasileiros. Reis (2006) verificou substituições de [?] por [t], [f], [d], [t?], [s] e [t?]; sendo as mais frequentes [t] (45,8%), [t?] (7,5%) e [f] (6,9%); e substituições de

[Ã°] por [d], [t?], [d?], [d?], [t?], [?] e [t]; as mais frequentes [d] (85,6%) e [t?] (1,4%)[10].

Trevisol (2010) realizou um estudo sobre a produção da interdental vozeada [Ã°] por professores de inglês. O experimento consistiu da leitura de 20 frases, as quais continham o fone [Ã°] em início e final de palavra. Mesmo nessa população de nível avançado em inglês, as interdentais se mostram como uma dificuldade de pronúncia. Em início de palavra, os sujeitos produziram corretamente [Ã°] em 51,4% das vezes, tendo trocado [Ã°] por [d] nos demais 48,6% casos (n = 220). Em final de palavra, a taxa de acerto verificada foi consideravelmente menor: 26,0% (n = 208). O maior número de substituições deu-se pela correspondente desvozeada da interdental [?], que contabilizou 65,5% das realizações (n = 208); a seguir, o maior número de substituições foi pela oclusiva [d], com 6,0% dos casos (n = 208). Trevisol (2010), também registrou substituições por [v], [f], [t], [t?] e [Ã], no entanto, todas elas são de baixa ocorrência (<1,0%) e podem ser consideradas espúrias. A autora explica a predominância de [?] em final de palavra, em virtude de haver restrições, no PB, para que sons fricativos sejam vozeados em final de palavra. Esse processo será tratado à parte, na Seção 2.1.1.4.4.

No que diz respeito ao [?], tal fone constitui uma aproximante alveolar vozeada e está presente em diversos dialetos do PB. Equivocadamente, a literatura linguística no Brasil convencionou a chamar tal som de “r retroflexo”, embora se trate, em termos articulatórios, de uma aproximante (Rennicke, 2011). A Figura 4 apresenta um mapa da distribuição dos róticos no Brasil, indicando as regiões em que ocorre o [?].

[pic]

Figura 4: Distribuição geográfica dos sons róticos em coda no Brasil - Rennicke (2011) com base em Noll (2008).

Como se nota, a maior parte dos dialetos que contém a aproximante [?] está concentrada na região Centro-Sul do Brasil. Apesar disso, Rennicke (2011) afirma haver estudos que indicam a presença da aproximante [?] em menor concentração, em quase todas as regiões do país. Para os dialetos que possuem a aproximante [?] como parte do inventário fonético, sua percepção e produção na interlíngua não constitui problema, de forma que os aprendizes conseguem, por exemplo, pronunciar car ['k??] e word ['w??d] sem dificuldades.

No entanto, nos dialetos do PB em que [?] não ocorre, os aprendizes têm mais um obstáculo a vencer no aprendizado da língua inglesa. Geralmente, eles acabam por realizar substituições, na interlíngua, mapeando a aproximante [?] em um rótico análogo no PB: [x], [?], [h], [?] ou [?] (Zimmer, 2009).

Osborne (2010) pesquisou a aquisição da aproximante [?] por três brasileiros aprendizes de inglês, com conhecimento de inglês em nível iniciante. O experimento consistiu na leitura de sentenças em voz, as

quais continham a aproximante [?] em diversos contextos. Para onset complexos, a exemplo da palavra travel [trĂŠv.?l], [?] foi realizado como [?] em 71,7% dos casos, como [?] em 26,4% e omitido em 1,9% ( $n = 53$ ). Em posição intervocálica, como America [??mer.?k?], [?] foi realizado como [?] em 51,7% das vezes e como [?] nos demais 48,3% ( $n = 29$ ). Em posição de coda, como em park [p??rk] e war [w??r], a aproximante [?] apresenta o maior número de variação, sendo realizada ora como [?], [?], [x], [h] ou sendo apagado. Osborne (2010) analisa os dados de coda em duas situações: em meio e final de palavra. No que diz respeito ao meio de palavra, os resultados obtidos com o [?] foram: [h] 57,6%; [?] 18,2%; apagamento 15,1%; [x] 6,1%; e [?] 3,0% ( $n = 33$ ). Em final de palavra, as realizações são similares, mas não se nota a ocorrência do tepe [?]: apagamento 52,5%; [?] 27,5% [h] 15,0% e [x] 5,0% ( $n = 40$ ). O autor também avaliou a realização do [h] em inglês, em palavras como huge ['hju?d?], e do tepe [r], como em city [?s??i]; no entanto, nenhuma variação foi observada, tendo os aprendizes produzido o padrão esperado em 100% dos casos.

8 Falta de aspiração de oclusivas em posição de início de palavra ou sílaba acentuada

Definimos como falta de aspiração de oclusivas a substituição das consoantes [p?], [t?] e [k?] do inglês, em posição de início de palavra ou sílaba acentuada, por suas correspondentes não-aspiradas [p], [t] e [k].

A aspiração é um fenômeno restrito à s consoantes obstruintes. Uma consoante é considerada aspirada quando é articulada de modo que, após a fase de explosão dos articuladores, segue-se a liberação de um sopro de ar. Desde Lisker e Abramson (1964), estudos envolvendo comparações entre segmentos vozeados, desvozeados e aspirados têm sido realizados a partir de medidas de voice onset time (VOT). O VOT consiste no intervalo e entre a explosão dos articuladores da consoante e o início do vozeamento da glote. A Figura 5 ilustra as combinações de valores de VOT em uma oclusiva bilabial.

[pic]

Figura 5: Tipos de fonação e valores correspondentes de VOT.

Como se observa, assume-se como ponto de referência, ou ponto zero, a soltura dos articuladores da consoante, a partir disso, calculam-se os valores de VOT. Quando há um intervalo entre a soltura dos articuladores e o início do vozeamento da glote, isto é,  $VOT > 0$ , a consoante é classificada como aspirada, no exemplo: [p?]. Quando o vozeamento se inicia imediatamente após a soltura dos articuladores, no caso de  $VOT = 0$ , a consoante é desvozeada: [p]. Por fim, quando o vozeamento antecede a explosão, ou seja, quando há pré-sonorização,  $VOT < 0$ , a consoante é vozeada: [b].

A relação entre as medidas de VOT e tipo de fonação é dependente de língua, por exemplo, um fone que tenha um determinado valor de

VOT pode ser considerado aspirado em uma língua, mas desvozeado em outra. A

., baseada nos dados de Yang (1993), apresenta os valores médios de VOT para as consoantes oclusivas do inglês.

Tabela 1: Valores médios de VOT (em ms) de consoantes oclusivas no inglês (Yang 1993).

[pic]

Yang (1993) opta por reportar os valores de VOT para obstruintes vozeadas na forma A/B, em que A contém a média das amostras com valor negativo de VOT e B as com positivo. O autor argumenta que a diferença de sinal no VOT representa fenômenos diferentes: um VOT < 0 corresponde à pré-sonorização, já um VOT > 0 corresponde à pós-sonorização. Tais fenômenos, de acordo com Yang (1993) devem ser tratados distintamente. A partir Tabela 1, nota-se que, na língua inglesa, o VOT está relacionado ao lugar de articulação da consoante, sendo que o par de alveolares [t?] e [d] apresenta os maiores valores médios, respectivamente 95ms e 20/-91ms. As oclusivas velares [k?] e [g] seguem com 88ms e 32/-78ms. Por fim, os menores valores médios de VOT são encontrados nas bilabiais [p?] e [b], 77ms e 17/-78ms.

Para o PB, a análise mais extensa de VOT de que temos notícia foi realizada por Klein (1999). Os resultados estão resumidos na Tabela 2.

Tabela 2: Valores médios de VOT (em ms) de consoantes oclusivas no PB (Klein 1999).

[pic]

Como se nota, no PB, as consoantes desvozeadas apresentam menores valores médios de VOT que no inglês, havendo, portanto, menos aspiração. Além disso, a correlação entre o lugar de articulação da consoante e os valores VOT é mais atenuada, a diferença de VOT entre [p] e [t] é estatisticamente insignificante, sendo que apenas a oclusiva velar [k] apresenta algum nível de aspiração. Ao se comparar as medidas de VOT entre os pares do PB e do inglês [p?] vs. [p], [t?] vs. [t], e [k?] vs. [k], é possível ver que as consoantes desvozeadas da língua inglesa apresentam valores bem mais altos de VOT, o que evidencia, de fato, sua aspiração.

Salienta-se que, diferentemente de Yang (1993), Klein (1999) agrupa os valores de VOT positivos e negativos das consoantes vozeadas, de forma que a média apresentada das vozeadas acaba por se tornar menor. Ainda assim, é possível notar que as oclusivas vozeadas do PB apresentam mais pré-sonorização que as do inglês. A maior diferença é verificada na oclusiva velar, no PB, seu valor médio é de -91ms, enquanto no inglês é de 32/-78ms. A seguir a maior diferença é notada na bilabial [b], -87ms vs. 17/-78ms; por fim, os menores valores são encontrados na alveolar [d], -99 vs. 20/-91ms. Por conseguinte,

conclui-se que as oclusivas vozeadas [b], [d] e [g] do PB possuem mais vozeamento que as do inglês.

Além disso, é possível observar certa sobreposição entre os valores positivos de VOT das oclusivas vozeadas no inglês e das oclusivas desvozeadas no PB. Por exemplo, o valor de VOT positivo de [b] no inglês, 18ms, é bastante similar ao valor de [p] no PB, 17ms. Isso é válido também para os demais lugares de articulação: o valor de VOT da alveolar vozeada [d] do inglês, 20 ms., é muito similar ao da desvozeada [t] do PB, 17 ms.; e o mesmo para as velares [g] e [k], 32ms vs. 38ms. Em outras palavras, as consoantes desvozeadas no PB são articuladas, em certos contextos, de modo muito similar às vozeadas no inglês. Isso pode trazer problemas na inteligibilidade da pronúncia do aprendiz, uma vez que, caso ele transfira esse padrão para a interlíngua, pode, por exemplo, tentar pronunciar [k] e acabar sendo entendido como [g], em palavras como *caught* ['k??t] e *got* ['g??t]; *coat* ['ko?t] e *goat* ['go?t], etc. Cabe, portanto, ao aprendiz dominar essa diferença, de modo a aumentar a inteligibilidade de sua pronúncia.

Alves (2011) investigou a produção das oclusivas aspiradas [p?], [t?] e [k?] por brasileiros aprendizes de inglês. A autora utilizou valores de VOT na classificação, tendo definido como aspirados os segmentos que apresentavam VOT > 60ms e não-aspirados os que apresentavam VOT < 35ms. A autora observou que [p?] foi realizado sem aspiração pelos aprendizes em 59% das vezes (n = 41), [t?] em 33% das vezes (n = 51) e [k?] em 10% das vezes (n = 96). A diferença no desempenho pode ser explicada em virtude do método de classificação utilizado: apenas duas faixas de valores, VOT < 35ms ou VOT > 60ms; e também em virtude de, no PB, a consoante [k] já possuir maior VOT, dado o lugar de articulação. Entretanto, o estudo contou com um número muito reduzido de participantes (três), de modo que os resultados obtidos devem ser considerados apenas indicativos e não conclusivos.

Prestes (2012) investigou a produção de oclusivas surdas e sonoras por aprendizes brasileiros e falantes nativos de inglês. A autora emprega medidas de VOT na classificação dos segmentos e adota uma postura de tratar o fenômeno em sua gradiência, isto é, considerando-se apenas as medidas de VOT, sem dizer se uma determinada consoante é ou não aspirada. Valores relativos de VOT foram utilizados na análise, mais especificamente, a razão entre a duração do VOT e o tempo total da consoante. Prestes (2012) concluiu que as realizações surdas dos aprendizes apresentaram menor VOT (5,87% VOT/consoante) em relação às dos nativos (2,11% VOT/consoante); e que as vozeadas dos aprendizes apresentam maior VOT (10,15% VOT/consoante) em comparação com as dos nativos (3,89% VOT/consoante) (n = 450). Os resultados indicam, portanto, que brasileiros tendem a realizar [p], [t] e [k], na interlíngua, com menos aspiração que falantes

nativos; e [b], [d] e [g] com maior grau de vozeamento. Ressalta-se, todavia, que o estudo também utilizou um número reduzido de participantes, dois brasileiros aprendizes de inglês e dois nativos.

Schwartzhaupt (2012) analisou o impacto que fatores fonético-fonológicos podem ter sobre os valores de VOT, seu experimento foi conduzido com dez brasileiros aprendizes de inglês e cinco nativos. Foram analisados os seguintes fatores fonético-fonológicos: (i) lugar de articulação da consoante, (ii) qualidade da vogal adjacente e (iii) o número de sílabas da palavra-alvo. Os aprendizes possuíam conhecimento intermediário-avançado ou avançado de inglês. Apesar de o foco do estudo não ser a produção dos aprendizes, mas os efeitos dos contextos fonético-fonológicos no VOT, Schwartzhaupt (2012) observou que os aprendizes foram capazes de realizar, na interlíngua, valores de VOT bem próximos aos dos nativos. Ele salienta o fato de os aprendizes terem conseguido partir de um sistema sem distinção de VOT entre [p] e [t], como é o caso do PB, e terem alcançado, na interlíngua, um sistema em que tal distinção é patente, como é o caso do inglês. Na interlíngua, as realizações de [t?] (77ms) dos aprendizes apresentaram VOT significativamente maior que as de [p?] (61ms), tal como ocorre com falantes nativos.

#### 9 Desvozeamento de obstruintes em posição de final de palavra

O m Xxxxx

#### 10 Vocalização de laterais em final de sílaba

Baratieri (2006) investigou a produção da lateral [l] em coda por um grupo de vinte estudantes de inglês como língua adicional, de proficiência intermediária e avançada. Os resultados obtidos indicaram que a vocalização se trata de um fenômeno gradiente, tendo o autor optado por classificar os dados em três categoriais: (a) segmento parcialmente vocalizado; (b) vocalizado [w]; e (c) não vocalizado [l]. A categoria (a) indica os segmentos para os quais o grau de vocalização não é imediatamente perceptível, de maneira que não há um símbolo IPA correspondente. As produções dos aprendizes apresentaram a seguinte distribuição: 2,7% de [l], 35,5% de [w] e 61,8% de segmentos parcialmente vocalizados ( $n = 2134$ ). Como se observa, a taxa de produção do padrão esperado [l] foi extremamente baixa, indicando que a vocalização de laterais perdura mesmo em estudantes de proficiência intermediária ou avançada.

#### 11 Quada da nasal em final de sílaba + nasalização da vogal precedente

Kluge e Baptista (2008) estudaram a produção das nasais [m] e [n] em posição final de palavra por um grupo de dez aprendizes de nível intermediário de proficiência. A tarefa consistiu na leitura de sentenças em voz alta. O corpus foi formado por 72 sentenças, 36 contendo [m] e 36 contendo [n], em posição final de monossílabo acentuado do tipo (C)CVC. Os estudantes realizaram a nasal alveolar [n] final esperada em 78,6% dos casos ( $n = 359$ ), e a nasal bilabial

[m] esperada em 63,9% dos casos (n = 357); nos demais, houve apagamento da nasal e a nasalização da vogal precedente. Testes estatísticos indicaram que a diferença de acerto nas realizações de [m] e [n] é significativa, havendo, portanto, mais dificuldade na aquisição do [m] final pelos aprendizes. As autoras justificam que esse resultado pode se dar em virtude de, no PB, as palavras que terminam em nasal tenderem a ser escritas com (ex.: “fim”, “correm”, “amam”), havendo poucas palavras com (ex.: “hífen”, “pólen”, “abdômen”). Sendo assim, o padrão com é reforçado e o aprendiz apresenta mais resistência para superá-lo na interlíngua.

12 Paragogue da consoante oclusiva velar vozeada [g]

O XXXXX

13 Assimilação vocálica

O XXXXX

14 Epêntese interconsonantal (morfema -ed)

O XXXXX

### 3.2 WHY CONSIDER L1 IN L2 TEACHING?

Lorem ipsum at nusquam appellantur his, ut eos erant homero concludaturque. Albucius appellantur deterruisset id eam, vivendum partiendo dissentiet ei ius. Vis melius facilisis ea, sea id convenire referrentur, takimata adolescens ex duo. Ei harum argumentum per. Eam vedit exerci appetere ad, ut vel zzril intellegam interpretaris.

Errem omnium ea per, pro UML congue populo ornatus cu, ex qui dicant nemore melius. No pri diam iriure euismod. Graecis eleifend appellantur quo id. Id corpora inimicus nam, facer nonummy ne pro, kasd repudiandae ei mei. Mea menandri mediocrem dissentiet cu, ex nominati imperdiet nec, sea odio duis vocent ei. Tempor everti appareat cu ius, ridens audiam an qui, aliquid admodum conceptam ne qui. Vis ea melius nostrum, mel alienum euripidis eu.

### 3.3 COMMON MISPRONUNCIATION

#### 3.3.1 *Syllable Simplification*

Lorem ipsum

#### 3.3.2 *Consonant Change*

*Lorem ipsum*

#### 3.3.3 *Deaspiration of Voiceless Plosives in Initial or Stressed Positions*

*Lorem ipsum*

3.3.4 *Terminal Devoicing in Word-Final Obstruents*

Lorem ipsum

3.3.5 *Delateralization and rounding of lateral liquids in final position*

Lorem ipsum

3.3.6 *Vocalization of final nasals*

Lorem ipsum

3.3.7 *Velar consonantal paragoge*

Lorem ipsum

3.3.8 *Vowel assimilation*

Lorem ipsum

3.3.9 *Interconsonantal epenthesis (-ed and -s morphemes)*

Lorem ipsum



# 4

## AUTOMATIC SPEECH RECOGNITION

---

### 4.1 THE BIG PICTURE

Basically, all statistical methods of ASR are dedicated into solving one fundamental equation, which can be described as follows. Let  $O$  be a sequence of observable acoustic feature vectors and  $W$  be a word sequence, the most likely word sequence  $W^*$  is given by:

$$W^* = \arg \max_W P(W|O) \quad (1)$$

To solve this equation straightforwardly, one would require a discriminative model, capable of estimating the probability of  $W$  directly from a set of observations  $O$  [? ]. However, Hidden Markov Model (HMM) are generative models and are not adequate for solving this equation, therefore we apply Bayes' Theorem to Equation 1 and end up with:

$$W^* = \arg \max_W \frac{P(O|W)P(W)}{P(O)} \quad (2)$$

As one might notice, we can apply a generative model to calculate the conditional probability term of this equation, that is, the probability of the observation sequence  $O$  given a word sequence  $W$ , hence  $P(O|W)$ . At first, it might seem counter-intuitive to conceive a generative model for data analysis, since the data is already available, i.e.  $O$  is known before-hand. As ? [?] points outs, in order to understand how to generative models are used for data analysis, a mental trick is necessary.

[To fix - Fink citation]First one assumes, that the data to be analyzed were generated by a natural process, which obeys similar statistical regularities. Then one tries to reproduce this process with the capabilities of hidden Markov models as closely as possible. If this attempt is successful, on the basis of the artificial model inferences can be drawn on the real process. On the one hand this may concern the probability for generating the available data. On the other hand the inference on the internal processes within the model is at least probabilistically possible. In particular one can determine the state sequence that generated a certain sequence of outputs with highest probability.

For a single audio input, which we want to decode, the audio is already fixed, so the probability of the observable acoustic feature

vectors  $P(O)$  is a constant and, therefore, might be discarded. Thus the final fundamental equation is simplified to:

$$W^* = \arg \max_W P(O|W)P(W) \quad (3)$$

$P(O|W)$ , the probability of an observable acoustic feature vector given a word sequence, is calculated by an acoustic model. In turn,  $P(W)$ , the *a priori* probability of words is reckoned by a language model.

#### 4.2 HMM

Markov models consist a set of mathematical models which are suitable for the statistical description of symbol and state sequences [? ]. The simplest form of Markov models are Markov chain models, which represent a system with a set of spaces in which transitions from one state to another occur. Within Markov processes, systems are assumed to be memoryless, that is, the conditional probability of future states is only dependent on the present state. To put it another way, Markov models assume that, given a certain system with states and transitions, the current state does not depend upon the sequence of events that preceded it, the so-called Markov property.

HMMs can be formally described as a 5-tuple  $\lambda = (Q, O, \Pi, A, B)$ , where  $Q = \{q_1, q_2, q_3, \dots, q_N\}$  is a set of  $N$  states.  $O = \{o_1, o_2, o_3, \dots, o_T\}$  is a set of  $T$  observations taken from time  $t = 1$  to  $t = T$ . At each time  $t$  it is assumed that the system will be at a specific state  $q$ , which is hidden, only the observations are directly visible.  $\Pi = \{\pi_i\}$  is a vector with the initial state probabilities, such that

$$\pi_i = \Pr(q_i), t = 0 \quad (4)$$

$A = [a_{ij}]$  is matrix with the state transition probabilities so that

$$a_{ij} = P(q_t = j | q_{t-1} = i), 1 \leq i, j \leq N \quad (5)$$

and  $B = [b_{jt}]$  is a matrix with the emission probability of each state. Assuming a Gaussian Mixture Model (GMM) to model the state emission probabilities – the so-called GMM/HMM model; we can define that, for a state  $j$ , the probability  $b_j(o_t)$  of generating  $o_t$  is given by

$$b_j(o_t) = \prod_{s=1}^S \left[ \sum_{m=1}^{M_{js}} c_{jsm} \mathcal{N}(o_{st}; \mu_{jsm}, \Sigma_{jsm}) \right]^{\gamma_s} \quad (6)$$

where  $\gamma_s$  is a stream weight, with default value is one,  $M_{js}$  is the number of mixture components in state  $j$  for stream  $s$ ,  $c_{jsm}$  is the weight of the  $m^{\text{th}}$  component and  $\mathcal{N}(\cdot; \mu_{jsm}, \Sigma_{jsm})$  is a multivariate Gaussian with mean vector  $\mu$  and covariance matrix  $\Sigma$ , that is

$$\mathcal{N}(o; \mu, \Sigma) = (\sqrt{(2\pi)^n |\Sigma|})^{-\frac{1}{2}} e^{-\frac{1}{2}(o-\mu)^T \Sigma^{-1} (o-\mu)} \quad (7)$$

where  $n$  is the dimensionality of  $o$ .

The following constraints apply:

$$a_{ij} \geq 0 \quad (8)$$

that is, the probability of moving from state from any state  $i$  to  $j$  is not null, and

$$\sum_{j=1}^N a_{ij} \geq 1, \forall i \quad (9)$$

#### 4.3 PB

### 15 Reconhecimento Automático de Fala (RAF)

O propósito de um reconhecedor de fala é transformar, de forma eficiente e precisa, o sinal acústico da fala em sua contraparte textual (Rabiner & Schafer, 2007). Se cada palavra da língua fosse pronunciada de forma idêntica por todos os falantes e em todos os contextos, a tarefa de Reconhecimento Automático de Fala (doravante RAF) seria algo banal. Mas isso não acontece: a realidade linguística é demasiado variante, quer inter-, quer intrafalantes. Pode-se, por fim, dizer que uma vogal nunca é pronunciada de uma mesma maneira. Furui (2001) sumariza os problemas do RAF em quatro: (i) dificuldades em lidar com coarticulação e redução; (ii) dificuldades de segmentação da fala; (iii) diferenças inter-individuais; e (iv) insuficiência de conhecimento linguístico. A seguir, cada um desses pontos serão discutidos.

A coarticulação é um fenômeno motor que envolve a realização de gestos articulatórios simultâneos ou sobrepostos (Crystal, 2008). Na fala, a coarticulação pode ocorrer de duas formas: antecipatória (left-to-right) ou preservativa (right-to-left). Na coarticulação antecipatória, um som é realizado tomando as características de outro que lhe sucede. Em “pulo”, por exemplo, a consoante /p/ é realizada com protrusão labial, [p?], em virtude de a vogal que lhe segue, [u], ser arredondada. Por sua vez, na coarticulação preservativa, um som é realizado mantendo-se as características articulatórias de outro que lhe antecede. Em dialetos em que não houve a vocalização da lateral, por exemplo, a consoante /l/ da palavra “sal” pode ser realizada de modo velarizado, [?] em vez de [l], por suceder a vogal [a], que é baixa. De fato, a todo o tempo, os sons da fala estão sujeitos à coarticulação. Por tal razão, frequentemente, utilizam-se no RAF unidades fonéticas dependentes de contexto, a exemplo de trifones.

Um trifone é uma representação fonética contextual, que considera, para um dado fone, o fone anterior e o seguinte. A palavra ‘fala’, por exemplo, pode ser representada, no IPA, pela sequência de fones [’fal?] ou de trifones [#’fa fal al? l?#], especificando-se as articulações secundárias dos fones. No reconhecimento de fala, por razões de codificação em computadores, em geral, os trifones são especificados no

formato “L-X+R”, em que “X” é um determinado fone, “L” o fone antecedente, e “R” o sucessor. A Figura 6 compara a transcrição da palavra “translate” em fones e trifones.

[pic]

Figura 6: Transcrição da palavra “translate” em fones e trifones de acordo com a convenção do VoxForge (2013).

Quanto às diferenças interindividuais, elas são tamanhas que há até mesmo todo um ramo de investigação da Linguística que se dedica a seu estudo: a Sociolinguística. A Sociolinguística estabelece que a realização linguística é condicionada por diversos fatores sociais: o nível escolar do falante, seu sexo, sua idade, seu estrato social, o lugar onde nasceu e viveu, a situação comunicativa em que está inserido, a formalidade de registro que o contexto demanda, o grau de hierarquia que mantém com seu interlocutor, etc. (Labov, 2008; Weinreich et al., 2006). Para além dos fatores que condicionam a variação, há fenômenos linguísticos que possuem comportamento puramente estocástico: o alcance vocálico acontece em certas vezes e não em outras, mesmo havendo o mesmo ambiente e considerando-se o mesmo falante.

Não bastasse os fatores sociais, a fala sofre influência também de características anatômicas do indivíduo. A variabilidade linguística começa já quando somos crianças, na fase de desenvolvimento puberal. Das primeiras palavras que balbuciamos até o período de muda vocal, ocorrem grandes mudanças na voz tendo em vista, especialmente, modificações nas configurações das estruturas laríngeas (Guimarães, 2006). Perry et al. (2001) conduziram um estudo sobre vogais produzidas por crianças dos 2 aos 16 anos e verificaram que há diferenças significativas nos valores de frequência fundamental [pic] e nos formantes das vogais [pic]. Ao longo de todo o período de maturação de voz, os valores de frequência dos formantes das vogais [pic] varia significativamente e é distinto para meninos e meninas; após os 12 anos, há grande decréscimo nos valores de frequência fundamental [pic] para os meninos, de modo que a frequência fundamental [pic] passa também a servir perceptualmente para a distinção do sexo das crianças (Perry et al., 2001) (Figura 7).

[pic]

Figura 7: Comparação dos valores de ??o, F<sub>1</sub>, F<sub>2</sub> e F<sub>3</sub> para crianças de ambos os sexos dos 2 aos 16 anos (Perry et al., 2001).

Aos sistemas de RAF, cabe a tarefa de reconhecer, ante toda a variabilidade linguística existente, o que há de invariante na fala. Do ponto de vista computacional, a construção de um reconhecedor de fala pode ser vista como uma tarefa que abrange quatro fases principais: preparação de dados, treino, teste e análise (Young, et al., 2006). A preparação de dados consiste na gravação de arquivos de áudio e texto, em sua anotação, transcrição e pré-processamento, de modo a garantir que a entrada seja compatível com o esperado pelo recon-

hecedor. O treino constitui a fase em que os dados coligidos são utilizados para criar as componentes do reconhecedor. Em geral, os sistemas de RAF possuem três componentes: (i) um modelo de língua, (ii) um modelo acústico e (iii) um modelo de pronúncia, ou dicionário de pronúncia. Por fim, as fases de teste e análise buscam verificar se os modelos construídos se adequam à realidade linguística ou ao propósito a que o reconhecedor se dispõe.

#### 16 Representação Digital da Fala

Para desenvolver tecnologias de fala, é preciso antes encontrar formas de codificar, computacionalmente, a informação presente na fala. A fala humana, como constitui um veículo de informação, pode ser vista a partir de uma perspectiva da Teoria Matemática da Comunicação (Shannon, 1948)[11], sendo considerada um sinal acústico. Tecnicamente, sinais são sequências de estados em um sistema de comunicação que codificam uma mensagem.

Sinais constituem o objeto central de estudo da área de Processamento de Sinal, que busca investigar formas de analisar ou modificar os sinais, no intuito de deles extrair informação ou de adequá-los a um determinado fim (Ingle e Proakis, 2011[12]). Embora a maior parte dos sinais que nos rodeia seja analógica, em muitas vezes, seu processamento é feito não de forma analógica, mas digital. De acordo com Ingle e Proakis (2011)[13], os sistemas de Processamento de Sinal Digital (DSP) são vantajosos, pois:

não necessitam a aquisição de equipamento específico (que são, muitas das vezes, caros), podendo ser desenvolvidos em computadores pessoais;

baseiam-se apenas em operações numéricas de adição e multiplicação, o que lhes dá estabilidade, não sendo necessário calibragem ou padronização, como é comum nos sistemas analógicos;

são altamente adaptáveis, de modo que suas operações podem ser modificadas em tempo real, usualmente, através de técnicas de programação simples.

Um esquema de um sistema de processamento de sinal digital é apresentado na Figura 8.

[pic]

Figura 8: Esquema de um sistema de processamento de sinal digital (Ingle e Proakis, 2011).

Embora a maior parte dos sinais do mundo seja analógica - entre os quais a fala, seu processamento, muitas vezes, dá-se gera sinais analógicos,

Embora a maior parte dos sinais com que

O processamento de sinais pode ser feito de forma analógica ou digital.

A área do conhecimento responsável por tal busca é o Processamento de Sinal.

A área responsável por esse

Do ponto de vista da Teoria da Informação, sinais são sequências de estados em um sistema de comunicação que codificam uma mensagem.

(Ingle e Proakis, 2010)

#### 17 Tipos de Reconhecedores de Fala

Reconhecedores Automáticos de Fala podem ser agrupados em três categoriais, que se dividem quanto à tarefa de reconhecimento que desempenham: i) reconhecimento de palavras isoladas; ii) de sentenças pré-estabelecidas; iii) reconhecimento de fala contínuo de grande vocabulário (RFCGV)[14] (Rabiner, 1997).

Os sistemas de reconhecimento de palavras isoladas são utilizados, por exemplo, por centrais telefônicas, nas Unidades de Resposta Audível (URA), em menus do tipo: “Fale ‘um’ para ser redirecionado ao setor de cancelamento” ou “Para conversar com um de nossos atendentes, fale ‘atendente’”. Reconhecedores de fala do segundo tipo são mais robustos que os do segundo, sendo capazes de reconhecer sentenças pré-definidas ou provenientes de uma gramática pré-estabelecida. Um exemplo de aplicação deste tipo são os módulos de comando por voz de computadores, celulares e os sistemas hands-free em carros, em que se pode dizer sentenças do tipo “ligar o rádio” ou “Siri, google ‘speech recognition’” e o comando é reconhecido. Já os sistemas de reconhecimento de fala contínuo de grande vocabulário são os reconhecedores mais abrangentes, sendo capazes de processar a fala espontânea do usuário. Sistemas de diálogo por voz, como os How May I Help You (HMIHY), e sistemas de ditado em editores de textos são desse último tipo.

A seguir, será discutida apenas a arquitetura dos sistemas de RFGV, primeiro, porque consistem nos sistemas de reconhecimento com a arquitetura mais complexa e, segundo, porque é o tipo de reconhecedor que se pretende desenvolver neste projeto.

#### 18 Arquitetura Básica de um Reconhecedor de Fala Contínuo de Grande Vocabulário (RFCGV)

O paradigma majoritário em sistemas de RAF é estocástico, destacando-se, especialmente, a utilização de Modelos Ocultos de Markov, ou Hidden Markov Models (HMM) (Huang, et al., 2001). Em tais modelos, a tarefa de reconhecimento é considerada a partir da metáfora do canal ruidoso, ou noisy-channel (Jurafsky & Martin, 2009). O sinal acústico, que constitui a entrada no sistema, é visto como uma deformação da mensagem original, isto é, da sequência de palavras pretendida pelo falante, após passar por um canal com ruído. Assim, o reconhecimento se torna uma tarefa de decodificação, isto é, trata de como recuperar a mensagem original a partir do sinal acústico “ruidoso”. Matematicamente, isso corresponde a estimar, considerando-se uma língua [pic], para uma sequência de palavras [pic], qual é a sequência [pic] mais provável, dado conjunto de estados acústicos observáveis [pic]:

[pic]

Todavia, não é possível calcular [pic] diretamente, sendo necessário aplicar-se o Teorema de Bayes, de modo a obter-se:

[pic]

Como a propósito é buscar a sequência de palavras mais provável para um conjunto já dado de estados acústicos, [pic] se repete a cada cálculo, de maneira que pode ser considerado uma constante de normalização, e a equação pode ser simplificada para:

[pic]

Essa equação fundamenta a base dos sistemas de RAF estocásticos e possui estreita relação com a arquitetura que é por eles compartilhada. Basicamente, os sistemas de RAF contínuo com grande vocabulário possuem três módulos: (i) um modelo de língua, (ii) um modelo acústico e (iii) um modelo, ou dicionário de pronúncia. O modelo de língua é utilizado para estimar [pic], a probabilidade a priori da sequência de palavras. Já o modelo acústico é utilizado para calcular [pic], a verossimilhança da observação. Por fim, o dicionário de pronúncia serve como uma ponte entre o modelo de língua e o modelo acústico, uma vez que possui as palavras que compõem o léxico do reconhecedor, transcritas em forma ortográfica e fonética. A Figura 9 ilustra a arquitetura básica de um sistema de RAF.

[pic]

Figura 9: Arquitetura básica de um Reconhecedor Automático de Fala.

O modelo acústico processa o sinal acústico da fala, de modo a inferir quais são os segmentos sonoros que a compõem, usualmente, empregando fones ou trifones. Em reconhecedores de base em HMM, essa tarefa é feita estimando-se os estados acústicos observados mais prováveis, bem como suas probabilidades de transição. Já o modelo de pronúncia provê a correspondência entre sequências de fones e as palavras da língua. No exemplo, tal modelo mapeia a sequência de fones [fal?] na palavra “falo”. O modelo de língua, por sua vez, estima as ordenações de palavras mais prováveis na língua.

#### 4.4 A BRIEF HISTORY

Although the task of recognizing words from speech might seem apparently simple beforehand, (after all humans start doing it with as little as four months! (XXXX INSERT CITATION)), the issue is actually very complex one. Over the years, many methods have been proposed to attempt to solve the problem of speech recognition. However until now no solution has been found and machines are still a very long way from performing like humans. Table 2 presents a comparison between the performance of humans and machines in some recognition tasks.

Table 2: Word error rate comparisons between human and machines on similar tasks [34].

TASKS	VOC. SIZE	HUMANS	MACHINES
Connected digits	10	0.009%	0.720%
Alphabet letters	26	1%	5%
Spontaneous telephone speech	2,000	3.8%	36.7%
WSJ with clean speech	5,000	0.9%	4.5%
WSJ with noisy speech (10-db SNR)	5,000	1.1%	8.6%
Clean speech based on trigram sentences	20,000	7.6%	4.4%

As one may observe, humans outperform machines in almost every task, specially the more complex ones. Humans' are indeed the topline for the speech recognition task, the uttermost dream of each speech scientist alive is to build a system capable of performing similarly to humans. Although this dream is somewhat near for rather simple tasks like connected digits, for other contexts a long path yet lies ahead.

Recognizing spontaneous speech is still a huge barrier for machines, as can be seen from the huge difference in the spontaneous telephone corpus: whereas humans had a WER of 3.8%, for machines this rate is up to 36.7%. Such result is mainly due to linguistic variability. Language varies not only among speakers (the so-called inter-speaker variability), but also within the same speaker (intra-speaker) [7].

Considering inter-speaker differences, factors such as gender, age, social, and regional origin, health and emotional state might have a huge impact on the speech signal [7]. Sociolinguistics has long known that gender affects language usage, in fact, men and women tend to use different language constructions. In her seminal paper in the field, Lakoff [42] found that, in women's speech, strong expressions of feeling are avoided, uncertainty is favored, and means of expression in regard to subject-matter deemed "trivial" to the "real" world are elaborated.

Put aside social aspects, men, women and children's speech are also contrasting because of morphological differences in their vocal tract. Sex and development influence body size, and there is a strong correlation between vocal tract length and body size (either height or weight); in addition to this, the relative proportions of men and women's oral and pharyngeal cavity are unlike [26]. Figure 4 presents

a comparison between height and vocal tract length for men, women and children. Figure 5 presents a model of the vocal tract morphology considering age.

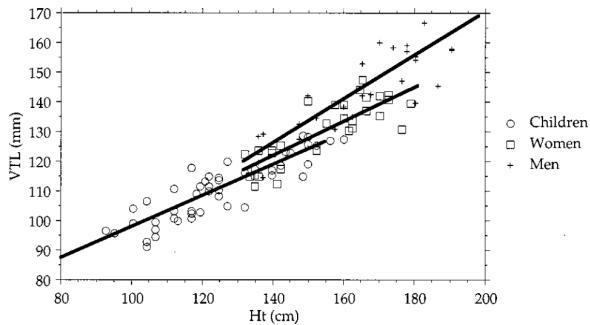


Figure 4: Height (cm) versus vocal tract length (mm) [26].

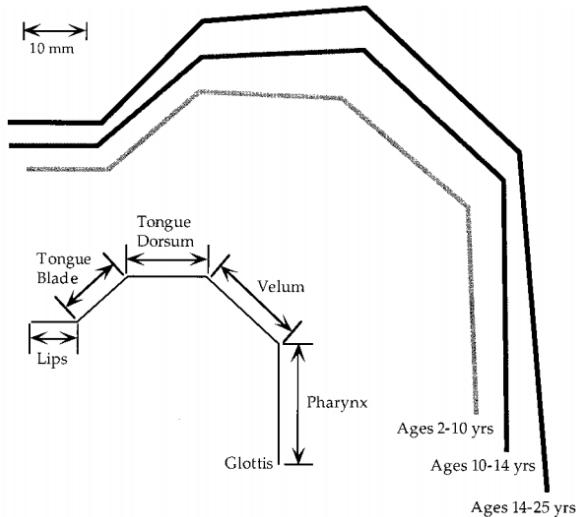


Figure 5: Averaged vocal tract morphology [26].

As one can observe, men's vocal tract are longer than women's, followed and obviously children. These morphology differences affect the speech signal thoroughly, specially in what concerns to the Fundamental Frequency ( $F_0$ ).  $F_0$  can be defined as the lowest frequency in the signal counting from zero. Figure 6 compares the  $F_0$  values between male and females considering aging.

One can notice from Figure 6, that no difference is found between male and female voice at a very young age. In fact, boys and girls have roughly the same  $F_0$  values. However, when they reach puberty, differences begin to appear. This period is commonly called the voice mutation or voice change, when the  $F_0$  for male voice has huge drop, while for female voice the drop is quite small. In terms of perception, this is period when the male voice lowers and gets deeper.

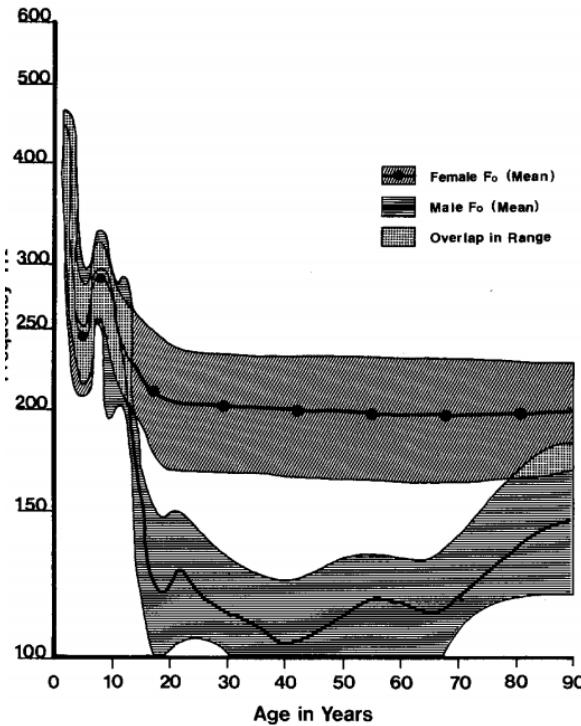


Figure 6: Fo and pitch sigma versus age for males and females [12].

XXXXXXXXXXXXXXXXXXXX EXTEND INTER-SPEAKER VARIABILITY XXXXXXXXXXXXXXXXXXXX DESCRIBE INTRA-SPEAKER VARIABILITY

But let's get back to Table 2. It is interesting to notice that humans performed better in all speech recognition tasks, but one: "Clean speech based on trigram sentences". This one task consists of recognizing sentences which were randomly generated using the WSJ trigram language model. Therefore, humans had no advantage over machines in what concerns to syntactic or semantic knowledge. This result highlights one of the most important feature of human hearing, that is, we make a large use of syntactic, semantic and also pragmatic information in order to understand speech. While hearing do not take into account simply the acoustic signal, but the whole context.

Language is a social tool, which aims at successfull interaction. When someone steps into a snack bar and orders an [ais'krim], the vendor has no doubt that this sequence of phones refers to "ice cream" and not "I scream", albeit they are pronounced exactly the same. Although such sequence of phones might be ambiguous in the phonetic level, it is not in higher linguistic levels, such as syntax (the verb "order" is usually followed by a noun), semantics (the object of order has to be something purchasable) and pragmatics (one does not buy his own shout!).

## 4.5 HMM-BASED SPEECH RECOGNITION

HMM is the most widespread and successfull paradigm in ASR. When HMM were first applied to speech recognition in the late 70's, they were completely revolutionay. Up until recently Deep Neural Network (DNN) seem to be next prominent paradigm in ASR. HMM have been applied to ASR since the late 70's, and they have gathered the best results until recently.

A HMM is a statistical Markov model in which the states are assumed to be hidden, i.e. they are not directly visible, only the state's outputs are observable. Each state has a probability distribution over the possible output tokens, in such a way that output generated by the HMM states provides some information about the hidden sequence of states which was traversed.

## 4.6 FEATURE EXTRACTION

### 4.6.1 *Preambulus*

Feature extraction is an importart part of speech recognition systems. The feature extraction phase is responsible for identifying or enhancing the components of the signal that are relevant for recognizing speech sounds, while discarding or diminishing the effect of unuseful information, such as background noise. With respect to speech parameterization, Mel Frequency Cepstral Coefficients (MFCC) are definitely the standard. MFCC have been widely used in ASR systems for almost three decades [17], they are present on the many important speech recognition toolkits, such as Hidden Markov Model Toolkit (HTK), Sphinx, **RASR!** (**RASR!**) and Kaldi. Before we go into further details about these features it is interesting to give a little background about speech recording and coding.

Speech is recorded by using a microphone – nothing new so far! Despite the many types of available microphones (condenser, capacitor, pyezoelectric, laser, etc.) its design remains basically the same as the carbon microphone invented by David Hughes two centuries ago [68]. A microphone is simply an acoustic-to-electric sensor, which converts variations in air pressure (that is, sound) into an electrical signal. Microphones have a very thin membrane, called diaphragm, which vibrates when struck by sound waves. When the diaphragm vibrates, it puts to move a sensitive capsule attached to it, that converts its movement into electrical pulses. Most of the current microphones are dynamic, which means that their capsule consist of .... (XXX VER WIIPEDIA)

After capturing speech through a microphone, one usually wants to store it for later access. In order to store speech digitally on a computer, a coding scheme is mandatory. In the literature, many coding

schemes have been proposed, such as linear PCM,  $\mu$ -law, A-law PCM, APCM, DPCM, DM, and ADPCM [34]. The details of each type of speech coder is beyond the scope of this dissertation, the reader can find an description of each scheme in Huang et al. [34] or Furui [27]. Following we will give a brief discussion of linear PCM, which is the standard way of storing audios in digital format.

Pulse Code Modulation (PCM) is a type of analog-to-digital conversion, which constitutes the basis of the WAV digital audio format, together with other lossless formats such as AIF and AU.<sup>1</sup>. PCM coding is based on two properties: (i) a sampling rate of the audio and a (ii) bit depth. The sampling rate determines the number of audio samples that are taken per second from the signal, in turn the bit depth is the number of bits of information in each audio sample. Both values must be constant and should be defined prior to recording (actually coding) an audio. The sampling and the bit depth are closely related to the audio quality, that is, the higher the sampling and the depth the better the fidelity of the digital audio to the analog speech signal. Picture XXX presents an example of a linear PCM representation, at different sampling rates and bit depths, of an audio containing the utterance “Speech recognition”.

Linear PCM assumes that the discrete signal  $x[n]$  is bounded, that is,

$$|x[n]| \leq X_{\max} \quad (10)$$

and that the quantization step  $\Delta$  is uniform for all consecutive levels of  $x_i$

$$x_i - x_{i-1} = \Delta \quad (11)$$

Assuming a binary code, the number of levels which can be represented by PCM is  $N = 2^B$ , where  $B$  is the bit depth, this constitutes the audio resolution. According to [34], speech could be represented in an intelligible way by using 7 bits, however, in practice, applications use values no lower than 11 bits to guarantee communication efficiency. For instance, CDs makes use of 16-bit linear PCM, whereas DVD-Audio and Blu-Ray discs can support up to 24-bit.

Although linear PCM files are able to carry all the necessary auditory information – after all we are able to listen to them and recognize the speech, the music or the noise recorded in them; they are not useful for speech recognition purposes. This occurs because, from the phonological point of view, very little can be said based on the waveform itself [71]. Consider, for instance, the two combinations of 100 Hz, 200 Hz and 300 Hz sine waves, shown in Figure 7, which differ only with respect to the relative timing.

---

<sup>1</sup> Other types of popular audio files which use lossy data compression, such as MP3, WMA, OGG or AAC (a format common to DivX videos) do not use PCM. Instead

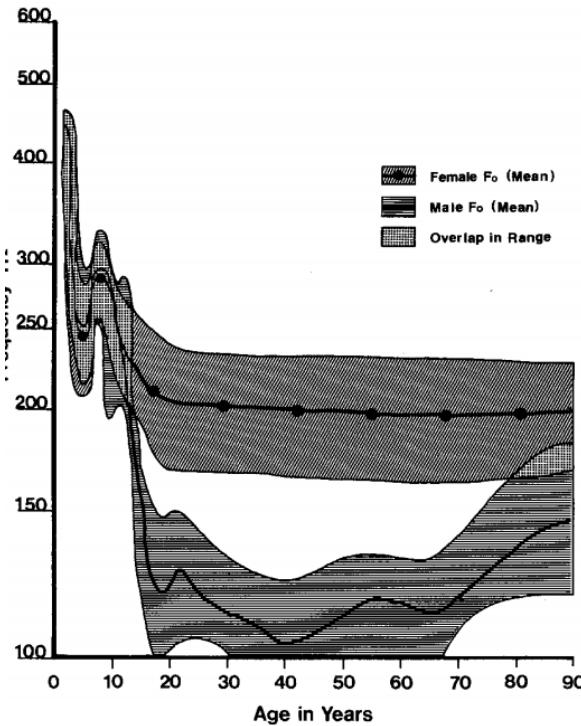


Figure 7: Two complex waveforms generated by the same three pure tone 100 Hz, 200 Hz and 300 Hz sine waves, differing only with respect to their relative timing [41].

As one might notice, disregard of being composed by the same pure tones, the complex waves shown in Figure 7 are completely distinct from one another. This happens because the waveform is influenced by phase shifts (also known as phase offsets). Therefore in-phase and out-of-phase waves (Figure 8 and Figure 9) are represented differently, and this adds too much variability to the waveform, in such way that the signal waveform becomes unsuitable for human analysis and consequently for being used as a raw input in ASR systems.

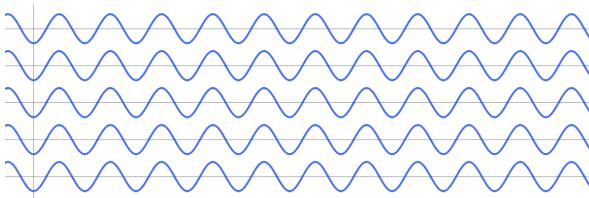


Figure 8: Example of in-phase waves.

Another way of representing the audio information, which is more meaningful for human reading or computer analysis is through short-term spectrum. Short-term spectra are obtained by applying a Discrete Time Fourier transform to a windowed signal. At first, the signal is divided into uniformly-spaced periods with a sliding window.

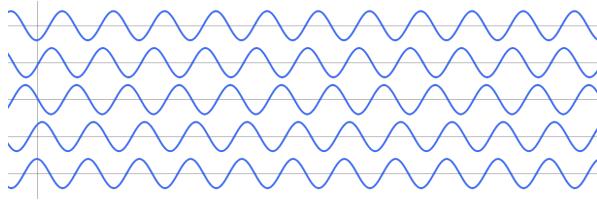


Figure 9: Example of out-of-phase waves.

For speech recognition, usually the window size is defined as 25 ms, with a frame shift of 10 ms, audio information is extracted every 10 ms with 15 ms of overlapping among adjacent frames [34]. Figure 10 contains an example of a windowing process (in this case, with 50% overlapping).

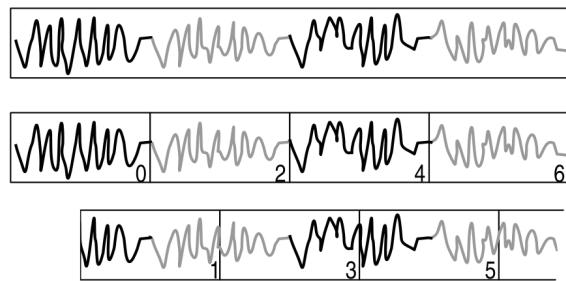


Figure 10: Illustration of an original audio recording (the upper waveform) divided into two offset sequences of analysis windows (two lower waveforms) with 50% overlapping frames [48]

These windows values are based on two assumptions: (i) that within 25 ms the signal is stationary, i.e. the phonatory system is not moving; (ii) that at least a period of each relevant speech frequency will be captured by this window this windows, that is no relevant are

After windowing the signal a Fourier transform is applied into each window so as to obtain a series of frequency spectra, i.e. a series of representation of the signal in the frequency domain instead of the time domain. As can be noticed in Figure 10, since the frame shift is smaller than the window size, the windowing process extracts many redundant information. The intention for doing this will be made afterwards, when we give further details of the Fourier transform. Such transform is based on the Fourier theorem, which states that any periodic waveform can be approximated as closely as desired as the sum of a series of pure sine waves. In other words, the Fourier transform is able to analyse a short-term of the signal, containing a complex wave, and to output which are and what is the amplitude of the pure tones which form this complex wave.

Feature extraction must then be performed in stored audio files in order to extract relevant information from the waveform and discard redundant or unwanted signal characteristics. As already mentioned

before, the two most traditional techniques for speech feature extraction, over the past decades, have been the MFCC [17] and the Perceptual Linear Prediction (PLP) [33]. Both parameterization methods are based on the short-term spectrum of speech. For speech recognition purposes, MFCC features usually show better performance when compared to PLP, for this reason in this thesis we are only going to present MFCC features [? ? ].

#### 4.7 MFCC FEATURES

MFCC is a type of speech parameterization is the result of a cosine transform of the logarithm of the short-term energy spectrum expressed over a mel scale [17]. MFCC features tries to reduce the feature dimensionality of a sound Fourier spectrum, by applying some concepts of Psychoacoustics and Psychophysics in order to extract a vector with relevant values from the spectrum. The aim is to represent speech data in a compressed format, by eliminating information which are not pertinent to the phonetic analysis and to enhance the aspects of the signal which contribute to the detection of phonetic differences [17].

From Psychoacoustics, MFCCs use the notion that humans do not perceive frequency through a linear scale, but through a scale which resembles to be linear-spaced in frequencies below 1000 Hz and logarithmic in frequencies above 1000 Hz<sup>2</sup>, the so-called mel scale (named after *melody*). The scale is based on experiments with simple tones in which individuals are required to separate frequency values into four equal intervals or to adjust the frequency of a stimulus to be half as high as another reference tone [34]. The reference point between mel scale and a linear frequency scale is 1000 mels, which correspond to a 1000 Hz tone, 40 dB above the absolute threshold of hearing. Since it was first introduced by Stevens et al. [77], the scale has been revisited many times [83], but a common formulation, according to Huang et al. [34] is:

$$M(f) = 1125 * \ln(1 + f/700) \quad (12)$$

where  $f$  is the input frequency in Hz. The scale is plotted Figure 11.

and also of the physics of speech, such as the fact that human like these systems often have well defined overtones that are harmonic – which is why the MFCCs use the FFT of the FFT)

---

<sup>2</sup> This is not entirely true. As shown by Umesh et al. [83], in fact, there are no two distinguishable regions in terms of statistical significance. But the idea that we perceive low frequencies better than high ones still hold.

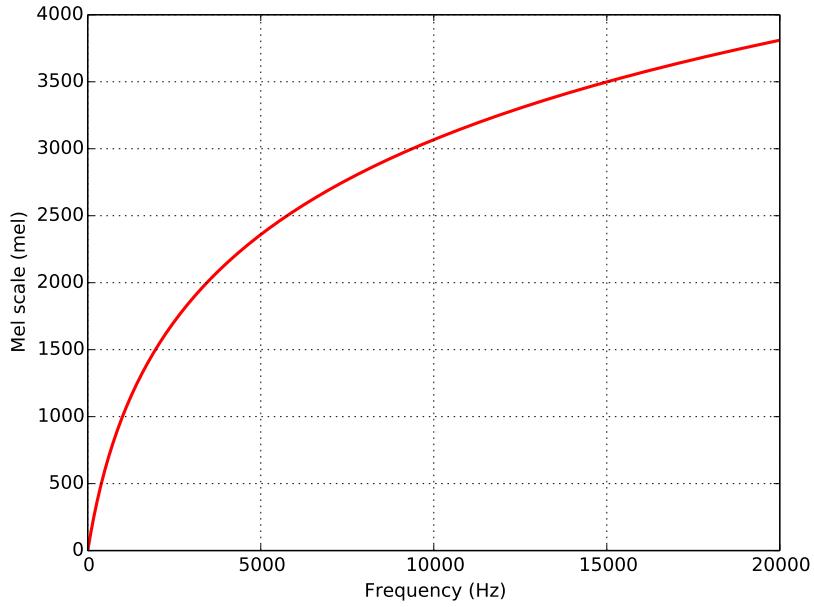


Figure 11: Mel scale versus a linear frequency scale.

#### 4.8 DEALING WITH NOISY DATA

One of the central problems in ASR is how to deal with noisy audio data. It is long known that the performance of speech recognition systems greatly degrade when the environmental or the recording conditions are not controlled, thus allowing unwanted residual sounds to appear in the signal. In acoustics, any type of sound that is not the one you are willing to analyze is considered noise. As a result from this, in speech recognition, the hiss of a fan, the buzz that a computer cooler makes, car horns on the street and so on are all regarded as noise. Even someone's voice can be regarded as noise. Consider, for instance, that you are trying to recognize John's speech in an application, however Mary is close to him talking on the phone, to the extent that traces of her voice are added to the signal. In this scenario, Mary's voice is actually noisy data, since it is undesirable for the given purpose.

#### 4.9 TYPES OF SPEECH RECOGNITION SYSTEMS

Errem omnium ea per, pro UML congue populo ornatus cu, ex qui dicant nemore melius. No pri diam iriure euismod. Graecis eleifend appellantur quo id. Id corpora inimicus nam, facer nonummy ne pro, kasd repudiandae ei mei. Mea menandri mediocrem dissentiet cu, ex nominati imperdiet nec, sea odio duis vocent ei. Tempor everti

appareat cu ius, ridens audiam an qui, aliquid admodum conceptam ne qui. Vis ea melius nostrum, mel alienum euripidis eu.

#### 4.10 THE ARCHITECTURE OF A LARGE VOCABULARY CONTINUOUS SPEECH RECOGNITION SYSTEM

Non vices medical da. Se qui peano distinguer demonstrate, personas internet in nos. Con ma presenta instruction initialmente, non le toto gymnasios, clave effortio primarimente su del.<sup>3</sup>

---

<sup>3</sup> Uno il nomine integre, lo tote tempore anglo-romanic per, ma sed practic philologos historiettas.



## Part II

### RELATED WORK

This part addresses some fundamental concepts in Linguistics, Acoustics, and Automatic Speech Recognition.



# 5

## COMPUTER ASSISTED PRONUNCIATION TRAINING

---

### 5.1 PB

#### 1 Sistemas de Reconhecimento de Pronúncia

Um reconhecedor de pronúncia nada mais é do que um reconhecedor de fala voltado a uma tarefa específica, qual seja: compreender e analisar a pronúncia de um aprendiz. Como já discutido, um reconhecedor de fala é um sistema computacional que recebe como entrada um sinal acústico de fala e fornece como saída a transcrição textual da informação contida na fala (Rabiner & Schafer, 2007).

Reconhecedores de pronúncia são ferramentas de interesse, especialmente, na área de Computer-Assisted Language Learning (CALL), subárea da Linguística Aplicada que se dedica ao estudo da utilização de computadores para aprendizagem de língua (Beatty, 2002). Os sistemas de CALL que auxiliam no aprendizado ou na prática da pronúncia de outras línguas são os chamados Computer-Assisted Pronunciation Training (CAPT). Tais sistemas são útes, especialmente, por quatro motivos: (i) sua difusão: basta ter acesso a um computador para utilizá-los; (ii) sua capacidade de fornecer feedback individual - nas salas de aula tradicionais, dado o tempo, nem sempre é possível ao professor corrigir verbatim a pronúncia de cada aluno; (iii) seu baixo custo - tais tecnologias possuem baixo custo, se comparadas ao gasto com um curso de pronúncia; (iv) sua possibilidade de propiciar autoestudo assíncrono - o aluno pode treinar sua pronúncia onde e quando quiser, independentemente de um lugar ou horário específico (Witt, 1999).

Sistemas de CAPT, em geral, tentam agregar os seguintes componentes:

listas de pronúncia, material expositivo com informações acústico-articulatórias de cada som, tutoriais e exercícios de transcrição, atividade para prática e avaliação de pronúncia. Dois desses sistemas, notadamente, Accent Master e Macmillan Education Sounds são analisados a seguir.

O Accent Master é um software pago, que busca ensinar a pronúncia do AmE a partir de atividades, exercícios, jogos, vídeos expositivos e animações. A parte de exposição e ensino de pronúncia do software é bem completa e possui explicações detalhadas de como se produz cada fone do AmE, além de vídeos e animações da posição dos órgãos do aparelho fonador. O software possui versões específicas para a língua nativa do aprendiz (atualmente, há suporte para

21 línguas, incluindo o PB). As versões específicas compreendem uma descrição dos sons da língua nativa, bem como instruções sobre quais aspectos de pronúncia devem ser focados. Porém o Accent Master não possui um sistema de reconhecimento de fala built-in. O treinamento de pronúncia dá-se da seguinte forma: primeiro, o aprendiz ouve uma palavra em inglês, tenta repeti-la, então, o software plota no monitor o oscilograma da palavra ouvida e de sua tentativa, e cabe ao próprio aprendiz comparar se a realização foi similar ou não. No entanto, deixar ao aprendiz a análise do oscilograma não constitui uma boa solução, pois, mesmo considerando a enunciação de uma mesma palavra, a forma de um oscilograma é bastante variável e depende de características do aparelho fonador (Johnson & Mullenix, 1997). Além disso, trabalhos anteriores a respeito de Sistemas de CALL já questionaram o valor pedagógico deste tipo de atividade (Neri et al., 2008). A Figura 10 contém algumas telas da interface do software Accent Master.

[pic] [pic] [pic]

Figura 10: Telas da interface do Accent Master.

O Macmillan Education Sounds: The Pronunciation App é um aplicativo de ensino de pronúncia do inglês para iPhone, iPad e Android. Trata-se de um software com uso gratuito limitado e compras in-app, que foi desenvolvido para treinamento da pronúncia tanto do AmE, quanto do BrE. O app possui exercícios de reading, writing e listening para treinar a transcrição fonética das palavras do inglês. No entanto, não há nenhum tipo de introdução à fonologia ou fonética do inglês, de modo que se pressupõe que o usuário já tenha domínio do Alfabeto Fonético Internacional (AFI) e das convenções de transcrição das palavras do inglês. Sendo assim, a utilização do software acaba por restringir-se a aprendizes intermediários e avançados de inglês que saibam utilizar o Alfabeto Fonético Internacional. O exercício de pronúncia é composto por um dicionário, que contém o áudio das palavras e que possibilita ao aprendiz gravar sua própria fala e comparar com o áudio existente no dicionário. O app não possui reconhecimento de fala e, por conseguinte, não há nenhum tipo de avaliação ou feedback da pronúncia do usuário. A Figura 11 contém exemplos da interface do software gratuito.

[pic] [pic] [pic]

Figura 11: Telas da interface do software Macmillan Education - Sounds.

## 5.2 ENGLISH

Many papers have confirmed the importance of feedback for adequate learning in second language acquisition. Negative feedback has been investigated by (XXXXX) and positive feedback by (XXXXX). For

CAPT systems the feedback to the user may be provided by many media: text, voice or video.

Definitely, the more complex and informative form of feedback is through video. Badin et al. [4] developed a 3D talking head, that is able to display the articulation in an augmented mode, by showing all major speech articulators, including those usually hidden such as the tongue or the velum. The talking was called OroFacial Clone, and an example of its display can be found in Figure 12.



Figure 12: Example of the OroFacial Clone display, from Badin et al. [4].

The model is based on acoustic-to-articulatory inversion and was built upon estimating speech articulators' movement from Magnetic Resonance Imaging (MRI), Computer Tomography (CT) and video data. As one can imagine, building such a model is a very expensive task, which requires not only Computer Graphics (CG) and speech processing expertise, but also access to high-priced medical devices, such as MRI scanners and tomographs.

Part of this system was evaluated by Wang et al. [87] in a CAPT context, by testing the performance of Chinese learners of French. The aim of the test was to analyse the performance of the learners in the production and perception of the French vowels [ø] and [œ], that do not exist in Chinese. The authors found that the students exposed to audiovisual stimuli produced vowels that were closer to the correct ones than the subjects who had access only to the auditory stimuli. After training, the difference between the F1 of [ø] and [œ] was 62 Hz for the audio group and 178 Hz for the audiovisual group. Additionally, the audiovisual group performed better in an [ø] and [œ] perception test, the number of correct responses rose from 61% to 68% for the audio only group, and from 50% to 86% for the audiovisual one.



# 6

## HOW TO ADAPT A SPEECH RECOGNITION TO NON-NATIVE DATA

---

  Lorem ipsum quod dolor sit amet.

### 6.1 PB

#### 2 Adaptação a Dados de Não-nativos

É inegável que as tecnologias de reconhecimento de fala, mesmo as do estado da arte, apresentam problemas. Por tal razão, muitos pesquisadores mostram-se céticos quanto à eficiência do reconhecimento de fala de não-nativos. Entretanto, as críticas que, geralmente, são imputadas a sistemas de reconhecimento de fala de não-nativos, conforme apontam Neri et al. (2003), são fruto da falta de familiaridade com o design de reconhecedores de fala. De fato, caso se tente utilizar um reconhecedor de fala, projetado para nativos, com não-nativos, o desempenho será baixo, tendo em vista que o reconhecedor não está preparado para os padrões acústico-articulatórios que o não-native produzirá. Entretanto, há diversos métodos para se adaptar um sistema de RAF a dados de não-nativos. Conforme apontam Strik e Cucchiariini (1999), variações de pronúncia de falantes não-nativos podem ser adicionadas a qualquer nível do reconhecedor: no modelo acústico, no modelo de língua ou no modelo de pronúncia. Tais modelos são apresentados nas três seções seguintes.

#### 3 Adaptação do Modelo Acústico (MA)

No que concerne ao modelo acústico do reconhecedor, três métodos têm sido, comumente, empregados para tratar dados de fala de não-nativos: (i) adaptação ao falante; (ii) construção de modelos bilíngues; e (iii) utilização de modelos combinados, ou de interlíngua (Wang, et al., 2003). Tais métodos distinguem-se quanto à origem dos dados acústicos utilizados para treinar o modelo. Na adaptação ao falante, são utilizados apenas dados de falantes nativos da língua alvo. Na construção de modelos bilíngues, empregam-se no treinamento do modelo acústico dados de fala de falantes nativos tanto da língua alvo, quanto da língua base. Por fim, nos modelos combinados, ou de interlíngua, o modelo acústico é treinado tendo em vista dados de falantes nativos da língua alvo e, também, de aprendizes. A Figura 12 resume as três abordagens disponíveis para adaptar o modelo acústico de um sistema de RAF.

[pic]

Figura 12: Métodos para se adaptar o Modelo Acústico (MA) do reconhecedor a dados de não-nativos.

A fim de melhor esclarecer a distinção que há entre os três métodos, consideremos a criação de um sistema de reconhecimento de pronúncia que tenha por fim reconhecer o inglês americano falado por falantes nativos de PB. Na técnica de adaptação ao falante, para esse reconhecedor, apenas dados de falantes nativos de inglês seriam utilizados no treinamento do modelo. Na abordagem bilíngue, o modelo acústico seria composto de forma dual, possuindo dados de fala de ambas as línguas: tanto do inglês americano, quanto do português brasileiro. Na utilização de modelos combinados ou de interlíngua, o modelo acústico seria alimentado com dados nativos da língua alvo, no caso, americanos falando inglês, e também com dados de aprendizes, isto é, brasileiros falando inglês.

Diversos métodos e algoritmos podem ser empregados para realizar uma das três abordagens de adaptação, a exemplo de: Maximum Likelihood Linear Regression (MLLR) + Maximum A Posteriori (MAP) + Identificação de fones mais informativos (Oh et al., 2006), Phonetic Decision Tree (PDT) (Chen & Cheng, 2012), Polyphone Decision Tree Specialization (PDTS) (Wang et al., 2003), Eigenvoices + MLLR (Tan & Besacier, 2007), Phoneset comum + Modelo multilíngue (Fischer et al., 2002). Nesta dissertação, propomos a utilização de modelos combinados. De tal modo, ne

#### 4 Adaptação no Modelo de Pronúncia (MP)

Em sistemas de RAF, os dicionários de pronúncia constituem o módulo que contém as palavras do léxico do reconhecedor, juntamente com sua forma fonética transcrita. Trata-se, em verdade, do componente do reconhecedor que faz a ponte entre as unidades acústicas subpalavras presentes no modelo acústico e as possíveis sequências de palavras especificadas no modelo de língua. O Quadro 5 ilustra a estrutura do CMUdict[15] (Weide, 1998), um dicionário de pronúncia de referência para o inglês americano.

Quadro 5: Exemplo de entradas no CMUdict.

[pic]

Como se observa, um dicionário constitui uma lista de palavras, que contém formas ortográficas e fonéticas pareadas, além de um identificador. A função do identificador é possibilitar a distinção de palavras homógrafas heterófonas, isto é, palavras que possuem mesma grafia mas pronúncia distinta, como gov[e]rno (nome) e gov[?]rno (verbo); bem como a distinção das pronúncias variantes de uma palavra.

No que diz respeito ao RAF de não-nativos, a adaptação que se costuma fazer ao dicionário de pronúncia é a adição das formas variantes de pronúncia do não-native, de modo a construir os chamados dicionários multipronúncia. A construção de tais dicionários pode se dar por meio de duas abordagens: (i) baseada em conhecimento ou (ii) baseada em dados (Strik & Cuccharini, 1999). Ambas possuem seus prós e contras.

Na abordagem baseada em conhecimento, variantes de pronúncia são inseridas no dicionário do reconhecedor por meio de regras geradas por um especialista - um linguista. A língua constitui uma heterogeneidade ordenada, isto é, a variação não é um processo que ocorre aleatoriamente, há diversos fatores, sejam eles estruturais, sejam sociais, que condicionam a variação linguística (Weinreich, et al., 2006). Portanto, cabe ao especialista explicitar a estrutura que subjaz à variação linguística, inferindo as regras fonológicas que melhor descrevem as variantes. Tais regras, em geral, assumem o formato:

$$A > B/C_D,$$

em que A representa o elemento a ser modificado, B o elemento já modificado, e C\_D o contexto de aplicação da regra, sendo C o contexto estrutural à esquerda e D o contexto à direita (Crystal, 2008). Regras fonológicas, portanto, são capazes de descrever a variação fonética em uma escala segmental (Wester, 2003). Considere-se, como exemplo, o caso da epêntese de vogais altas anteriores não-arredondadas [i] em sílabas contendo oclusivas em coda, por brasileiros aprendizes de inglês. Por transferência de padrões fonotáticos de L<sub>1</sub> para L<sub>2</sub>, brasileiros tendem a realizar epêntese em palavras que apresentam oclusivas em posição coda, que são proibidas, originalmente, na fonologia do português (Collischonn, 2003; Zimmer & Alves, 2006). Sendo assim, acabam por pronunciar "book" como boo[ki] em vez de boo[k] e "trip" como tri[pi] em vez de tri[p]. Tal fato pode ser capturado pela regra:

$$\text{COCLUS} > \text{COCLUS} + [\text{i}] / \$,$$

em que COCLUS representa uma consoante oclusiva e "\$" a fronteira silábica. Na construção de dicionários multipronúncia baseados em conhecimento, o especialista deve arrolar um conjunto suficiente de regras, de forma a acomodar as diversas variações de pronúncia que um falante não-nativo apresenta.

Trata-se, portanto, de uma tarefa custosa, quer financeira quer temporalmente, uma vez que pressupõe um extenso levantamento e análise de dados linguísticos ou uma consulta dicionários transcritos já compilados. Além disso, apesar de os dados obtidos com um especialista serem fiáveis, frequentemente, o levantamento feito é incompleto, já que diversos fenômenos de variação linguística ainda estão para ser estudados, não havendo literatura disponível (Wester, 2003). Em outras palavras, regras desenvolvidas por um especialista possuem alta precisão (precision), mas não necessariamente alta cobertura (recall). Ademais, a abordagem baseada em conhecimento é dependente de língua ou, em certos casos, de um dialeto; regras desenvolvidas para uma língua ou dialeto não são necessariamente aplicáveis a outras línguas ou dialetos.

A abordagem baseada em dados para a construção de dicionários multipronúncia pode ser classificada como direta ou indireta (Kim, Oh, & Kiem, 2007). Na direta, padrões de variação existentes em um

conjunto de teste são analisados e utilizados, imediatamente, para gerar as palavras variantes. Já na indireta, busca-se inferir regras que possam ser aplicadas na geração de uma ou mais variantes para uma palavra. A abordagem direta, portanto, atém-se aos padrões de variação que ocorrem no conjunto de teste, enquanto a indireta é capaz de prever padrões que não vieram a ocorrer.

Um dos problemas da utilização de dicionários multipronúncia é o aumento da incerteza do reconhecedor. Com a adição de variantes ao dicionário de pronúncia, aumenta-se a cardinalidade do espaço amostral de palavras que o reconhecedor deve percorrer na busca e, por conseguinte, aumenta-se sua confusão. Em síntese, ao se adicionar muitas formas variantes ao dicionário de pronúncia, a confusão inserida no modelo pode contrabalancear os ganhos com uma forma fonética mais precisa para as palavras (Compernolle, 2001). Dicionários multipronúncia, de tal forma, devem procurar o ponto ideal entre o número de formas variantes adicionadas e as formas canônicas. Kim et al. (2007) propõem uma métrica para avaliar a confusão de dicionários multipronúncia, baseada no número de variantes de pronúncia de cada palavra, nos fones que a compõem e na distância de Levenshtein entre as palavras. Tal métrica, chamada Confusability Measure (CM), é definida formalmente como: seja  $[pic]$  um dicionário multipronúncia, composto por  $[pic]$  palavras, de maneira que cada palavra  $[pic]$  possua  $[pic]$  variantes de pronúncia, sendo  $[pic]$  a  $j$ -ésima variante de pronúncia pertencente à  $i$ -ésima palavra, então:

$$[pic]$$

onde  $[pic]$  é a distância de Levenshtein entre  $[pic]$  e  $[pic]$ , e  $[pic]$  é o número de fones da variante de pronúncia  $[pic]$ , normalizado pelo número total de fones de todas as pronúncias de  $[pic]$ , tal que:

$$[pic]$$

onde  $[pic]$  é definido como o número de fones da pronúncia  $[pic]$ . O objetivo da CM é sistematizar a construção de dicionários multipronúncia, estabelecendo um critério objetivo para a seleção das palavras que devem compor o modelo. Palavras distintas, mas com contexto fonético similar são favorecidas pela métrica, podendo-se selecioná-las ao estabelecer um threshold.

Em muitas vezes, os ganhos em WER obtidos com a construção de modelos de pronúncia são baixos em razão da adição “cega” de palavras ao dicionário. Jurafsky et al. (2001) demonstraram, por exemplo, que o relaxamento de vogais no inglês e a substituição de segmentos são, automaticamente, capturados por modelos acústicos baseados em trifones, não sendo necessário, portanto, adicionar variantes ao dicionário. Outros tipos de variação, como o apagamento de sílabas, não são bem modelados em trifones, de modo que é necessário tratá-los no dicionário de pronúncia (Jurafsky, et al., 2001).

Diversas técnicas podem ser utilizadas para elaborar um dicionário multipronúncia, a exemplo de: Gaussian Densities Across Phonetic Models (Saraçlar & Khudanpur, 2000), Group Delay Based Segmentation (Brunet & Murthy, 2012), Phones Adaptation and Pronunciation Generalization (Ahmed & Ping, 2011), Automatic Generation of Accented Variants + MLLR (Goronzy & Eisele, 2003), Multi-span Linguistic Parse Tables (Mertens et al., 2011), Decision Trees (Byrne et al., 1998), Pronunciation Mixture Model (McGraw et al., 2008). A seguir, discutimos, em mais detalhe, três desses trabalhos, notadamente: Saraçlar e Khudanpur (2000), Matsunaga et al. (2003) e Kim et al. (2007).

Saraçlar & Khudanpur (2000) propõem uma técnica, a que chamam state level pronunciation model (SLPM), que estima as pronúncias variantes de uma palavra sem a inserção de variantes no dicionário de pronúncia. Os autores elaboraram um método que permite que a representação de um fonema /f/, por exemplo, seja, no modelo acústico, diretamente mapeada nos estados HMM de suas variantes [f1] e [f2], criando assim um modelo misto. Tal técnica é capaz de gerar variantes de pronúncia automaticamente, mas pressupõe a utilização de dados anotados de forma manual para bootstrap do modelo. O state level pronunciation model (SLPM) foi testado com dados do inglês americano, em uma porção do corpus Switchboard (~4 horas, ~100k fones). O incremento em WER reportado foi de 1,7% (valor absoluto), tal valor corresponde à melhoria no reconhecedor dos valores de WER sem um modelo de pronúncia (39,4%) e com um modelo de pronúncia do tipo state level pronunciation model (SLPM) (37,7%).

Matsunaga et al. (2003) utilizam dicionários multipronúncia e modelos

acústicos combinados para tratar o inglês falado por japoneses. Os autores conduziram testes utilizando cinco métodos: (i) léxico do inglês + modelo acústico nativo; (ii) léxico com influência do japonês + modelo acústico japonês; (iii) comparação de ambos os métodos; (iv) léxico japonês e inglês + modelo acústico combinado; (v) léxico combinado + modelo acústico combinado + penalidade para alternância de palavras entrelínguas.

Kim et al. (2007) propuseram um método automático de criação de um

dicionário multipronúncia, através de uma abordagem indireta baseada em dados. De modo a criar um sistema de RAF não-nativo para coreanos aprendizes de inglês, os autores expandiram as formas canônicas do reconhecedor e, então, utilizaram uma medida de confusão (CM), baseada na distância de Levenshtein, para atribuir um valor a cada variante de pronúncia e excluir aquelas que apresentavam baixa confusão. As variantes foram geradas através do seguinte procedimento: 1º) as sentenças não-nativas foram reconhecidas através de um reconhecedor de fones; 2º) a saída do reconhecedor foi alinhada

com a forma de pronúncia canônica esperada através de um algoritmo de programação dinâmica (algoritmo de Viterbi); 3<sup>º</sup>) padrões de pronúncia variantes foram obtidos a partir dos dados alinhados; 4<sup>º</sup>) regras de variação de pronúncia são derivadas dos padrões de variação, por meio de árvores de decisão (algoritmo C4.5); 5<sup>º</sup>) as regras de variação são aplicadas ao restante do léxico, de modo a gerar possíveis candidatas a variantes de pronúncia. A medida de confusão (CM) é então utilizada, de modo a excluir do modelo de pronúncia as variantes que apresentam baixa confusão. O corpus utilizado no experimento foi uma porção do Wall Street Journal Database (WSJ0) (~7.138 sentenças). A melhoria na taxa de WER reportada foi de 1,34% (valor absoluto), que corresponde a uma variação de 19,92% a 18,58%. O baseline utilizado foi uma porção de 340 palavras do CMU Pronouncing Dictionary.

### 5 Adaptação no Modelo de Língua (ML)

[Esta seção do trabalho será realizada posteriormente, após elaborados os modelos acústico e de pronúncia.]

## 6.2 ADAPTATION METHODS FOR THE ACOUSTIC MODEL

Lorem ipsum quod dolor sit amet.

## 6.3 ADAPTATION METHODS FOR THE PRONUNCIATION MODEL

Lorem ipsum quod dolor sit amet.

## 6.4 ADAPTATION METHODS FOR THE LANGUAGE MODEL

Lorem ipsum quod dolor sit amet.

## Part III

# THE DESIGN OF LISTENER

Results and discussion.



# 7

## METHODS

---

### 7.1 PB

O reconhecedor de pronúncia ora proposto será implementado a partir do motor de reconhecimento de fala Julius (Lee & Kawahara, 2009). Nove erros de pronúncia foram selecionados para serem tratados pelo Listener, assumindo-se, como pronúncia padrão, o General American (GA). O modelo acústico será compilado a partir de três corpora. Um de falantes nativos de inglês: TIMIT Acoustic-Phonetic Continuous Speech Corpus[16]; e outros dois de aprendizes: COBAI - Corpus Oral Brasileiro de Aprendizes de Inglês[17] e um corpus coletado especialmente para este trabalho, composto por leitura de sentenças foneticamente balanceadas. O dicionário a ser empregado é o CMU Pronouncing Dictionary, ao qual serão acrescentaremos as hipóteses de pronúncia dos aprendizes, por meio de regras. O modelo de língua será gerado a partir da Simple English Wikipedia em conjunto com um corpus de textos escritos por aprendizes de inglês, o COMAprend, um dos três corpus do projeto COMET da Faculdade de Filosofia, Letras e Ciências Humanas da Universidade de São Paulo. A eficiência do reconhecedor será avaliada por meio de medidas de Word Error Rate (WER), Character Error Rate (CER) e matrizes de confusão, aplicadas por meio de ten-fold cross validation sobre os dados dos corpora coligidos. De modo a verificar a viabilidade do método ora proposto, um protótipo do sistema foi elaborado e avaliado, detalhes são apresentados na Seção .

### 4 MATERIAIS E MÉTODOS

#### 1 Levantamento dos Desvios de Pronúncia

Na classificação dos erros de pronúncia, deu-se prioridade, especialmente, aos erros de pronúncia que afetam a compreensão e que são apresentados em trabalhos que consideram, no ensino da pronúncia do inglês, a transferência de padrões sonoros de L1 para L2.

A listagem dos erros de pronúncia a serem considerados pelo Listener foi obtida a partir da consulta aos trabalhos de Zimmer (2004), Godoy (2005), Zimmer et al. (2009) e Cristófar-Silva (2012). Tais trabalhos analisam aspectos de transferência de L1 para L2 e estabelecem um método de ensino de pronúncia que leva em conta essa transferência, a fim de otimizar o aprendizado pelo aluno. De tal maneira, centra-se o estudo no ensino dos padrões de pronúncia que devem ser enfatizados para o falante do PB, a fim de melhor garantir a compreensão de sua pronúncia e sua eficiência comunicativa. No reconhecedor, optou-se por utilizar os nove tipos de erros elencados em

Zimmer et al. (2009), por se tratar da investigação mais abrangente sobre o assunto. Os desvios de pronúncia selecionados estão sintetizados no Quadro 5.

Quadro 5: Desvios de pronúncias a ser analisados pelo Listener.

[pic]

## 2 Simplificação silábica

Um conjunto de 30 regras foi definido para gerar as variantes de pronúncia envolvendo casos de simplificação silábica. As regras se baseiam nos exemplos citados por Rauber e Baptista (2004), Rebello e Baptista (2007), Zimmer (2009) e Silveira (2012). A discussão dos contextos consta na Seção 2.1.1.4.1. O pseudocódigo com a implementação das regras está descrito na Figura 13.

Figura 13: Pseudocódigo com regras para geração das variantes de pronúncia envolvendo simplificação silábica.

Como se observa, as regras de simplificação silábica buscam cobrir, majoritariamente, quatro situações: (i) oclusivas em posição final de palavra; (ii) palavras foneticamente terminadas em consoantes, mas com <-e> final na forma escrita; (iii) clusters consonantais em início de palavra do tipo /sC(C)/; (iv) palavras iniciadas por /s ao/, com na forma ortográfica.

## 3 O Motor de Reconhecimento de Fala Julius

Neste trabalho, propomos a utilização do motor de reconhecimento de fala Julius (Lee & Kawahara, 2009), como a base do reconhecedor de pronúncia a ser desenvolvido. Julius é uma engine de alto desempenho e de código aberto para a construção de sistemas de reconhecimento de fala. Ele incorpora grande parte das técnicas do estado da arte em reconhecimento de fala e executa Reconhecimento de Fala Contínuo com Grande Vocabulário (LVCSR). Sua arquitetura está sintetizada na Figura 14.

[pic]

Figura 14: Arquitetura do motor de reconhecimento de fala Julius (Lee & Kawahara, 2009).

Como se observa, ele suporta a entrada de dados de áudio vindo de microfone, de arquivos já gravados, ou de streaming via internet. A saída é composta ou por dados de textos, a exemplo de ditado, ou por uma determinada ação solicitada ao Julius. No caso do reconhecedor de pronúncia, a saída será constituída pela transcrição da fala e da avaliação de sua pronúncia.

Para se construir um reconhecedor fala através do Julius, são necessários: um modelo acústico, um dicionário de pronúncia e um modelo de língua. Mais detalhes sobre a elaboração desses modelos, de maneira a possibilitar o desenvolvimento do reconhecedor de pronúncia, são fornecidos a seguir.

## 4 Elaboração do Modelo Acústico

O modelo acústico proposto será elaborado através de HMM e definido para trifones. Julius provê suporte a modelos acústicos de

HMM obtidos a partir do HTK Hidden Markov Model Toolkit[18], disponibilizado pelo Speech Vision and Robotics Group, da Universidade de Cambridge. A abordagem utilizada na elaboração do modelo acústico é a de interlíngua. Portanto, ele será estimado a partir de dois tipos de corpora de fala: um de falante nativos do inglês: TIMIT Acoustic-Phonetic Continuous Speech Corpus[19]; outros dois de falantes nativos do PB, aprendizes de inglês como L2: COBAI - Corpus Oral Brasileiro de Aprendizes de Inglês[20] - e um corpus coletado especificamente para o Listener, composto por leitura de sentenças foneticamente balanceadas, isto é, sentenças contendo fones de acordo com sua frequência de ocorrência em uma dada língua. A construção de um modelo acústico interlingual busca contornar a dificuldade de reconhecer a fala de não-nativos, através da inserção de informação da pronúncia não-nativa no processo de treinamento do modelo acústico, por meio de dados com a pronúncia dos aprendizes (Wang, Schultz, & Waibel, 2003).

#### **5 Corpus de Nativos: TIMIT Acoustic-Phonetic Continuous Speech Corpus**

Optou-se pela utilização do TIMIT (Garofolo, et al., 1993) como o corpus de falantes nativos inglês por se tratar de: um corpus bem modelado, robusto, foneticamente rico, amplamente utilizado e testado na área de reconhecimento de fala, em cerca de duas décadas de pesquisa, além de cobrir os dialetos majoritários do inglês americano (Lopes & Perdigão, 2011). O corpus TIMIT foi elaborado, conjuntamente, pelo Instituto de Tecnologia de Massachusetts (MIT), SRI International e Texas Instruments Inc. (TI) com o propósito fornecer dados para a realização de estudos de fonética acústica do inglês, bem como para o desenvolvimento de sistemas automáticos de reconhecimento de fala. Ele contém gravações de cerca de 630 falantes, dos oito principais dialetos do inglês americano. As gravações foram elaboradas a partir da leitura de dez sentenças criadas artificialmente, de modo a capturar ambientes fonéticos relevantes. O TIMIT foi verificado manualmente e está transscrito ortográfica e foneticamente, adicionadamente, foi feito o alinhamento temporal entre o arquivo de áudio e as transcrições. Os arquivos estão separados em sentença, amostrados a 16kHz com 16 bits por amostra. O TIMIT está disponível para venda no Linguistic Data Consortium (LDC) e será adquirido pelo Núcleo Interinstitucional de Linguística Computacional (NILC).

#### **6 Corpus de Não-nativos: Corpus Oral Brasileiro de Aprendizes de Inglês (COBAI)**

O COBAI (Mello, Avila, Neder-Neto, & Orfano, 2012) constitui a primeira iniciativa brasileira que busca compilar e distribuir, de forma aberta, um corpus de fala anotado de aprendizes de inglês, falantes nativos do PB. O COBAI integra o Louvain International Database of Spoken English Interlanguage (LINDSEI) e vem sendo organizado pelo Laboratório de Estudos Empíricos e Experimentais

da Linguagem (LEEL), da Faculdade de Letras, da Universidade Federal de Minas Gerais (UFMG). O propósito do LINDSEI é a disponibilização de corpora de fala de aprendizes de inglês, com diferentes backgrounds de língua nativa. O COBAI segue as diretrizes de transcrição do LINDSEI, que utiliza padrões XML na anotação. A transcrição é do tipo ortográfica e agrupa informações de: troca de turno, sobreposição de fala, pausas, hesitações, formas reduzidas e algumas indicações fonéticas e prosódicas. Atualmente, cerca de 60% do corpus está anotado. O corpus consiste em 50 gravações de 15 minutos, que incorporam uma narrativa, uma entrevista e uma descrição. Os arquivos estão separados e amostrados a 44kHz com 16 bits por amostra. Todas as gravações foram feitas com falantes nativos do PB, aprendizes de inglês. O grau de conhecimento da língua inglesa dos participantes é variado, havendo desde aprendizes com baixa proficiência até indivíduos proficientes.

Uma contribuição colateral deste projeto será a finalização da transcrição ortográfica do COBAI e a anotação, no corpus, dos nove tipos de erros que serão analisados pelo Listener. De modo a finalizar a transcrição ortográfica do COBAI, pretende-se utilizar um reconhecedor de fala, no caso, o Dragon Naturally Speaking v.12 Premium, de modo a obter uma transcrição ortográfica inicial. A partir disso, realizaremos a revisão da transcrição, no intuito de corrigir os erros e adequar o formato ao que é proposto pelo LINDSEI. Para a transcrição dos desvios de pronúncia, propõe-se o seguinte método: após ter-se obtido a transcrição ortográfica de todo o corpus, será criado um script em Python para percorrer cada palavra transcrita ortograficamente, conferi-la no CMUdict e extrair a transcrição fonética que lá está registrada. De tal forma, obteremos uma versão do COBAI transcrita com a pronúncia canônica do General American (GA), que está registrada no CMUdict. A seguir, será realizada a revisão das transcrições fonéticas, corrigindo-as quando os aprendizes cometerem algum dos nove tipos de erros que o Listener avaliará.

#### 7 Corpus de Não-nativos: Corpus de Leitura de Sentenças Foneticamente Balanceadas por Aprendizes

A intenção inicial do projeto era utilizar apenas o COBAI como corpus fala de não-nativos. Porém, após ter-se desenvolvido o protótipo do reconhecedor, conforme será descrito na Seção , foi possível observar que muitos dados do COBAI terão de ser desconsiderados e, de tal forma, somente o COBAI não será suficiente para fornecer o número de horas necessário para a estimativa de um bom modelo acústico. Por isso, decidiu-se criar um corpus específico para o desenvolvimento deste trabalho.

O propósito é compilar um corpus de aprendizes, em situação de leitura de frases pré-definidas, foneticamente balanceadas, o qual seja gravado em um ambiente com isolamento acústico. Os objetivos, com isso, são três: i) assegurar a boa qualidade do áudio, mantendo baixa

a relação sinal-ruído; ii) garantir que todas as combinações de trifones estejam presentes na base de dados do modelo acústico, uma vez que as sentenças serão foneticamente balanceadas; e iii) facilitar a tarefa de transcrição, já que a duração da pesquisa de mestrado é curta. Propõe-se seguir as diretrizes de compilação e anotação de corpora, tal como descrito por Hovy e Lavid (2010).

Pretende-se que os detalhes do método de compilação e anotação do corpus sejam definidos em visita técnica a ser realizada na Universidade de Coimbra, sob supervisão da Profa. Sara Candeias, no período de 28 de janeiro a 28 de fevereiro de 2014. O plano de tarefas proposto para a visita inclui:

- a definição do tamanho do corpus a ser compilado;
- a definição do nível de detalhe da transcrição fonética (qual o inventário de fones e xenofones utilizar);
- a definição do tipo de hesitação ou disfluência a ser anotada;
- a discussão de uma métrica de riqueza fonética (?), proposta para a extração de sentenças foneticamente balanceadas;
- o teste e a avaliação da métrica, a partir de um corpus de textos de aprendizes de inglês, o COMAprend.

No que diz respeito às sentenças foneticamente balanceadas, há, para o inglês, diversas listas disponíveis, como as Harvard Sentences (IEEE, 1969), os TIMIT Sentence Prompts (Garofolo, et al., 1993), as MOCHA-TIMIT Sentences (Wrench, 1999), além de diversas listas fornecidas pela Carnegie Mellon University para o motor de reconhecimento Sphinx (Lee, Hon, & Reddy, 1990). No entanto, dado que essas listas foram elaboradas para falantes nativos de inglês, há diversas palavras de baixa frequência, bem como sentenças cuja estrutura sintática é pouco usual. Em um contexto de aprendizes, isso é problemático, pois pode ocasionar disfluências na fala do aprendiz, causando problemas na utilização dos dados, além de padrões de pronúncia altamente irregulares, quando o aprendiz desconhecer a palavra que está lendo.

Para contornar o problema, objetivamos criar um conjunto de sentenças foneticamente balanceadas, a partir de um corpus de texto de brasileiros aprendizes de inglês, como o COMAprend (Tagnin & Fromm, 2009). O COMAprend possui textos em formato ortográfico. A fim de se obter a transcrição fonética dos textos, será elaborado um script semelhante ao descrito, anteriormente, na Seção 3.1.3.2.

#### 8 Elaboração do Dicionário de Pronúncia

O dicionário de pronúncia será formado com base no CMU Pronouncing Dictionary, o qual será acrescido de transcrições das possíveis pronúncias desviantes dos aprendizes, por meio de regras transformacionais. Dicionários contendo tais características são também chamados na literatura como dicionários multipronúncia (Strik & Cucchiarini, 1999).

#### 9 CMU Pronouncing Dictionary

A base do dicionário provirá do CMU Pronouncing Dictionary (também conhecido por CMUDict), disponibilizado no motor de reconhecimento de fala Sphinx, pela Universidade Carnegie Mellon. O CMUDict constitui um dicionário de pronúncia machine readable de referência na área de reconhecimento de fala. Atualmente, nele estão registradas 131.411 entradas, transcritas foneticamente em formato ARPAbet (Zue & Seneff, 1988). O Quadro 6 ilustra a entrada de algumas palavras no dicionário.

Quadro 6: Exemplo de entradas no dicionário de pronúncia do CMU Pronouncing Dictionary.

[pic]

Como se observa, o dicionário possui três campos: (i) um interno, para identificação da palavra, (ii) um com a palavra em sua forma ortográfica, convencionalizada em letras maiúsculas, (iii) e um último campo com a transcrição fonética da palavra, em formato ARPAbet.

#### 10 Adição das Formas Variantes de Pronúncia do Aprendiz

Serão utilizadas regras transformacionais para acrescentar ao dicionário as possíveis hipóteses de pronúncia do aprendiz. A utilização de regras transformacionais é de fácil implementação computacional, correspondendo a simples estruturas de seleção, ou construções condicionais. Contexto para aplicação de regras, como os elencados no Quadro 7, serão levantadas, de acordo com a literatura linguística de ASL, e utilizados para as variantes de pronúncias do aprendizes, a partir das palavras do CMUDict. Casos marginais, de contexto muito restrito ou que não se adaptem às regras criadas, serão adicionados, manualmente, em formato de dicionário de exceções.

Quadro 7: Contextos para aplicação de regras de simplificação silábica.

[pic]

#### 11 Elaboração do Modelo de Língua

Um modelo de língua será fornecido ao Listener, de modo a possibilitar seu uso em um contexto de ditado. Há diversos modelos de língua para o inglês (como o Gigaword[21], CSR LM-1[22], HUB4[23]). Porém a grande maioria desses modelos foi gerada a partir de corpora de artigos de jornal e é sabido que textos jornalísticos de jornais tradicionais, para públicos A, B e C tendem a possuir estrutura sintática e vocabulário complexos, dado que as primeiras orações de uma notícia tendem a compactar muita informação e podem trazer jargão não dominado por aprendizes (Canning, 2002). Como a intenção é lidar com a fala de aprendizes, propomos a criação de um modelo de língua que seja mais simplificado e condizente com a sintaxe dos aprendizes. Será elaborado um modelo de língua estatístico, que considera trigramas na análise e se baseia em HMMs.

#### 12 Simple English Wikipedia

Como corpus para criação do modelo de língua, utilizaremos a Simple English Wikipedia, cuja proposta é desenvolver uma Wikipedia em inglês de nível básico, com vocabulário e construções sintáticas

mais simples, de modo a prover acesso a crianças, estudantes, adultos com baixo nível de letramento e aprendizes de inglês como L2. A versão disponível da Simple English Wikipedia, referente ao dia 16 de janeiro de 2014, possui 108.665[24]. Todos os arquivos estão codificados em XML. A ferramenta SRILM (The SRI Language Modeling Toolkit)[25] será utilizada para auxiliar na criação do modelo de língua.

#### 13 Elaboração da Interface Web

A interface web desenvolvida para o Listener emprega conceitos de gamificação, com o propósito de estimular a participação dos usuários e de tornar o processo de aprendizagem mais aprazível.

#### 14 Gamificação

Segundo o historiador Huizinga (1938), um jogo constitui:

"uma atividade ou ocupação voluntária, exercida dentro de certos e determinados limites de tempo e de espaço, segundo regras livremente consentidas, mas absolutamente obrigatórias, dotado de um fim em si mesmo, acompanhado de um sentimento de tensão e de alegria e de uma consciência de ser diferente da 'vida cotidiana'" (Huiziga 1938).

Jogos têm, desde sempre, fascinado as pessoas. Milhões de pessoas vibram e se emocionam ao assistir a uma partida de futebol de seu time preferido. Mestres do xadrez, como Garry Kasparov, chegam a dedicar cerca de seis horas diárias para dominar o jogo (ICC, 1998). Massive Multiplayer Online Role Playing Games mobilizam milhões de pessoas online a um mesmo tempo. Há, também, casos trágicos, como o do taiwanês que teve problemas vasculares e faleceu, logo após jogar Diablo 3 em uma lan-house por 40 horas ininterruptas (Daily Mail, 2012).

De acordo com Lazzaro (2004), as pessoas jogam, basicamente, por um dentre os quatro motivos a seguir: (i) pelo divertimento que o jogo proporciona, (ii) pela competitividade que ele incita, (iii) pelas sensações diversas que ele pode gerar - surpresa, alegria, temor, etc.; e (iv) pelo pretexto para socializar com os amigos. Jogos bem desenhados tendem sempre a explorar esses pontos, a fim de fidelizar jogadores.

Deburr (2013) define a gamificação a aplicação de estratégias e técnicas usadas no design de jogos em outros contextos, que não jogos. Zicherman e Cunningham (2013) trazem uma definição análoga, para os autores a gamificação é "o processo de utilizar a mecânica dos jogos no intuito de motivar usuários a resolver problemas", sendo que a mecânica comporta sete aspectos: (i) sistema de pontos, (ii) níveis, (iii) rankings, (iv) atribuição de títulos, (v) desafios/missões, (vi) busca de jogadores e (vii) um loop de estímulo social constante. Explicar cada um desses aspectos

A gamificação tem sido aplicada com sucesso a uma gama de contextos. Há, por exemplo, comunidades de perguntas e respostas,

como Stackoverflow e Yahoo! Respostas, que a empregam a fim de motivar seus usuários a participarem da comunidade e a cooperarem entre si. Os usuários que fornecem as melhores respostas recebem pontos no site, sobem níveis, melhoram nos rankings, tornando-se cada vez mais influentes na comunidade. Aplicativos para celulares que incitam a prática de corrida, como o Runstatic e o Nike+, também têm utilizado a gamificação com êxito. Tais aplicativos extraem dados do percurso do usuário via GPS e lhes fornece estatísticas de sua corrida, de maneira que os usuários podem monitorar suas corridas para vencer metas, bater recordes pessoais e, também, competir com os amigos. É possível também desafiar outros usuários, para ver quem corre mais rápido, quem faz um mesmo percurso maior em menor tempo, etc.

No âmbito da educação, a gamificação tem sido explorada no chamado edutainment - palavra amálgama formada a partir de education e entertainment (XXX:XX). Segundo Zicherman e Cunningham (2013), a indústria tem falhado em utilizar a gamificação para aplicações educacionais. Muitas vezes, o aspecto instrucional é ressaltado de maneira exagerada, de modo que os jogos se tornam chatos e as pessoas se sentem desmotivadas para jogá-los. Para os autores, o jogo educacional que melhor explorou os aspectos da gamificação foi "Where in the World Is Carmen Sandiego?", cujo propósito é ensinar Geografia, mais especificamente, o nome e a localização dos países e de suas capitais. Em "Where in the World Is Carmen Sandiego?", o jogador encarna um detetive que deve juntar pistas para encontrar a criminosa Carmen Sandiego. Ao longo da jornada, o jogador visita vários países e encontra pessoas que lhe dão pistas sobre onde Carmen Sandiego pode estar escondida. As pistas contêm informações gerais sobre os países, como "Uma pessoa suspeita veio aqui e disse que iria viajar à terra dos Vikings" ou "Eu a vi embarcando em um avião cuja bandeira era vermelha e azul". A Figura 15 apresenta uma tela do jogo.

Figura 15: Captura de tela do jogo "Where in the World Is Carmen Sandiego?"

"Where in the World Is Carmen Sandiego?" foi lançado em 1985 e, desde então, diversas empresas de edutainment têm tentado repetir o sucesso do jogo, mas sem muito êxito. Merece destaque o lançamento, em 2012, da plataforma para ensino de idiomas Duolingo (XXX:XX), que emprega gamificação e, só no Brasil, já consta com cerca 6,8 milhões de alunos[26]. Como se trata de uma aplicação de ensino de línguas que possui também um módulo de ensino de pronúncia, o Duolingo será tratado em mais detalhes na Seção XXX.

The leaderboard of today has seen some radical redesign since the heyday of pinball machines and quarter arcades. In the era of Facebook and the social graph, leaderboards are mostly tools for creating social incentive

In many instances, such as losing weight or even writing a book, it's difficult for a player to understand where he is at the outset or during early interactions. Moreover, the length and complexity of the overall journey is such that sometimes players can be paralyzed by the seeming lack of progress. Especially in health, education, and other "epic journey" contexts, feedback forms the most important overarching game mechanic, intricately tied to score and progress.

#### LER Jon Radoff's Game On

#### LER Jesse Schell's The Art of Game Design: A Book of Lenses

Segundo Zicherman e Cunningham (2013), como modelo de negócios, a gamificação transforma a relação empresa-usuário em uma relação simbiótica, cujo benefício para o usuário é o prazer obtido com o jogo e para a empresa é a fidelização do usuário com o produto oferecido.

#### O corpus de erros induzidos

Para este protótipo, reduziu-se a criação do corpus de leitura de sentenças foneticamente balanceadas a uma tarefa mais simples. Um informante do sexo masculino foi gravado, lendo palavras em isolamento e, propositalmente, enunciando-as com erros de transferência de L1 para L2, a fim de simular variantes de pronúncia que ocorrerão no corpus. As palavras foram selecionadas a partir da lista das 5.000 palavras mais frequentes da língua inglesa, segundo o Corpus of Contemporary American English (COCA)[29]. Cerca de 2h20min de fala foram compiladas. A gravação ocorreu em uma sala fechada, com baixo ruído externo, não isolada acusticamente.

O COCA é o maior corpus de inglês disponível atualmente, tendo sido compilado a partir de cerca de 160.000 textos escritos e transcritos, de vários gêneros, os quais totalizam 450 milhões de tokens. O projeto é coordenado por Mark Davies, professor de Linguística de Corpus da Brigham Young University (BYU). O corpus é gratuito, mas as listas de frequência são pagas, a exceção da menor delas, contendo as 5.000 palavras mais frequentes do inglês, a qual foi utilizada no protótipo.

Um script em Python foi elaborado para aplicar à lista as regras de simplificação silábica elencadas na Figura 18. Quando havia contexto para aplicação de qualquer uma das regras, a palavra era selecionada e adicionada a um banco de palavras. Figura 18 sintetiza o funcionamento do script. Das 5.000 palavras mais frequentes no COCA, 1.855 apresentaram contexto em que é possível haver simplificação silábica, tais palavras, portanto, foram selecionadas para leitura.

[pic]

Figura 18. Fluxograma de funcionamento do script seletor de palavras.

Um microfone condensador de diafragma pequeno (1/2"), com padrão polar cardióide, do tipo Superlux S241/U3 foi utilizado nas gravações. O microfone foi ligado a uma mesa de som analógica Yamaha MG102, através de cabos平衡ados XLR, e alimentado por

corrente fantasma (48V). A captação do áudio se deu por um laptop LG A51, via cabos RCA. O software Audacity (Mazzoni & Dannenberg, 2000) foi usado na captação, tendo-se ativado o filtro supressor de ruído. O ambiente de gravação consistiu de uma sala fechada, sem isolamento acústico, em situação de baixo ruído externo.

Os dados foram segmentados através do Adintool, de forma similar ao método descrito na Seção 3.4.1.1. O Appendix II reúne os parâmetros utilizados na segmentação. Os arquivos foram alinhados com sua transcrição ortográfica, manualmente. A seguir, procedeu-se à transcrição fonética das palavras, de forma também manual. Detalhes sobre a transcrição constam, a seguir, na Seção 3.4.2.

O software Praat (Boersma & Weenink, 2014) foi utilizado na transcrição, para visualizar o espectrograma e, também, tocar os arquivos de áudio. O LibreOffice Calc (The Document Foundation, 2014) foi empregado para facilitar a organização das transcrições. Atenção especial foi dedicada à análise da ocorrência ou não do fenômeno de simplificação silábica, erro alvo do protótipo.

[pic]

Figure 1: Workspace utilizado na transcrição fonética do corpus.

#### 4 Elaboração do modelo dicionário de pronúncia

O modelo de pronúncia foi elaborado com base no CMU Pronouncing dictionary, versão 0.7a, de 01 de abril de 2008[30], a qual conta com 133.315 entradas. De modo a manter a compatibilidade com o Julius, 16 palavras com símbolos especiais ("&", "/", ";", etc.) foram retiradas, restando-se 133.304 entradas. O dicionário foi, então, reordenado para manter a ordem esperada pelo motor de reconhecimento.

A seguir, foram selecionadas do dicionário apenas as 1.855 palavras que apresentaram contexto possível de haver simplificação silábica (cf. Quadro 8). A intenção de restringir o modelo de pronúncia à s palavras selecionadas para gravação deu-se de maneira a diminuir a confusão do reconhecedor. Como se trata de um protótipo, treinado a partir de poucas horas de áudio, o modelo acústico não é suficientemente robusto para percorrer um espaço de busca de 133.304 palavras e obter boa acurácia no reconhecimento.

A ferramenta HDMan, do HTK Toolkit, foi empregada na elaboração do dicionário de pronúncia contendo as 1.855 palavras. Tal ferramenta visa a criar novos dicionários a partir de dicionários fontes. Seu funcionamento dá-se da seguintes forma: listas de palavras são fornecidas como entrada, em conjunto com dicionários fontes e um script de edição, os dados dos dicionários-fontes são processados de acordo com as opções especificadas no script e tem-se como saída um novo dicionário, o qual contém as palavras fornecidas na lista, juntamente com as respectivas pronúncias.

Tendo-se obtido o dicionário com as 1.855 palavras utilizadas na gravação, procedeu-se à inserção das variantes de pronúncia. Para

esse fim, um script em Python, com 21 regras de transcrição, foi elaborado e aplicado ao dicionário. O script percorreu cada uma das palavras, analisando a sequência de grafemas e de fones, de modo a verificar se havia contexto propenso à simplificação silábica. As regras foram compostas por estruturas condicionais do tipo if... then e seus contextos de aplicação estão descritos no Quadro 7. O conjunto de fones utilizado na elaboração das variantes é constituído pela união do inventário fonético do PB segundo Cristófaro-Silva (2005), e o do AmE segundo Ogden (2012).

Certas regras criam contexto fonético para que outras se apliquem.

Por exemplo, após se aplicar regra 15, [Vm#] > [VNASALbi#] / , é possível se aplicar também a regra 7, [b#] > [bi#], de forma a gerar uma nova variante a partir de outra já gerada. Aplicando-se a regra 15 à palavra “bomb” [bom], seria possível obter [bomb], com isso, haveria contexto para a aplicação da regra 7, gerando-se também a variante [bombi]. De tal maneira, as regras têm de ser aplicadas iterativamente, até esgotar todas as possibilidades de criar novas variantes.

No caso do dicionário de pronúncia do protótipo, as 21 regras foram

aplicadas cinco vezes, até o número de palavras do dicionário se estabilizar, isto é, até a aplicação das regras não adicionar nenhuma palavra nova ao dicionário. O Gráfico 1 descreve o crescimento do número de palavras.

Gráfico 1: Crescimento do número de palavras do dicionário de pronúncia.

[pic]

Como se observa, houve um aumento considerável no número de palavras. Para 1.855 palavras-base, foram geradas 5.742 variantes, de maneira que o dicionário final contabilizava 7.597 possibilidades de pronúncia. O valor médio de pronúncias por palavras foi de 4,1. Certas palavras chegaram a apresentar até 24 possibilidades de pronúncia, como “employment”, “entertainment”, “independent” e “unemployment”. A Tabela 4 resume as estatísticas do número de variantes por palavra.

Tabela 4: Variantes de pronúncia por palavra.

[pic]

O grande número de possibilidades geradas para algumas palavras não era esperado e pode trazer prejuízos para o reconhecedor. Uma palavra aparentemente simples, como “combined”, apresentou 12 variantes de pronúncia apenas no que diz respeito à simplificação silábica. Considerando- se a influência da escrita na fala, seria possível que o aprendiz pronunciasse [ka] como [ko] e inserisse um [e] em razão de haver na forma escrita, de tal forma, “combined” apresentaria 48 variantes de pronúncia (= 4 x 12). Tendo em vista que objetivo é tratar nove tipos de erros de pronúncia (cf. Seção 3.1.1), é possível que, ao

se obter todas as regras, o número de variantes de pronúncia geradas seja tão grande que o reconhecimento seja prejudicado. Caso isso ocorra, uma saída viável seria a criação de dicionários separados para cada tipo de erro ou, mesmo, a utilização de um especialista para cercear as variantes geradas.

## 7.2 EVALUATION

Since we are proposing a method to build a pronunciation training system, we could evaluate our method in two ways: extrinsic or intrinsically.

The extrinsic evaluation is the one which considers the purpose of the system, that is, it assess if users are appropriately learning with the system, by improving their pronunciation perception and production. Therefore, the extrinsic evaluation of the system would require the development of a longitudinal study, in which a significant portion of individuals would be analyzed for a large amount of time, with regular interviews and tests to check their pronunciation skills. Given time limitations and also the scope of this Master's thesis, an extrinsic evaluation of the system is not feasible. Instead, we are going to evaluate the method solely in an intrinsic way, which consists of assessing the pronunciation training system itself, regardless of its practical purpose.

To put another way, our evaluation

### 7.2.1 Evaluation Metrics

The Word Error Rate (WER) measures the performance of an ASR system in terms of how much its output (i.e. the words it recognized) diverges from a given reference. The metric is defined as follows:

$$WER = \frac{S_w + D_w + I_w}{N_w} \quad (13)$$

where  $S_w$  corresponds to the number of word substitutions,  $D_w$  is the number of deletions,  $I_w$  is the number of insertions, and  $N_w$  is the number of words in the sentence used as reference, that is to say, the expected output.

The Phone Error Rate (PER) analyses the system's performance in recognizing phones. It is calculated exactly like the WER, but considering phones as units. It is defined as:

$$PER = \frac{S_p + D_p + I_p}{N_p} \quad (14)$$

where  $S_p$  corresponds to the number of phone substitutions,  $D_p$  is the phone deletions,  $I_p$  is the phone insertions, and  $N_p$  is the total number of reference phones in the transcription.

Differently from The Real Time Factor (Real Time Factor (RTF)) is a metric used to measure the computational performance of an ASR system. It is defined as:

$$RTF = \frac{P_i}{T_i} \quad (15)$$

where  $P_i$  is the time it takes to process an input  $i$ , and  $T_i$  is the duration of  $i$ .

The RTF is a metric used to measure the computational performance of an ASR system. It is defined as:

$$RTF = \frac{P_i}{T_i} \quad (16)$$

where  $P_i$  is the time it takes to process an input  $i$ , and  $T_i$  is the duration of  $i$ .

Um reconhecedor de pronúncia pode ser avaliado de dois modos: intrínseca ou extrinsecamente. A avaliação intrínseca (também chamada *in vitro*) é aquela que se atém à avaliação do reconhecedor *em si*, isolado de seu fim prático. Em outras palavras, na avaliação intrínseca, o foco de avaliação é a tarefa de reconhecimento, avalia-se a eficiência do reconhecedor em obter, dado um sinal acústico, sua contraparte textual.

Para isso, usam-se, comumente, métricas como Word Error Rate (WER), Character Error Rate e Matrizes de Confusão (Chen, Beeferman, & Rosenfeld, 1998; Goronzy, 2002). Já a avaliação extrínseca (também chama *in vivo*) é aquela se volta à avaliação do propósito para o qual o reconhecedor foi construído, no caso de um reconhecedor de pronúncia, o objetivo final é o aprendizado de pronúncia pelos seus usuários. Métricas utilizadas para nesse tipo de avaliação são a Goodness of Pronunciation (GOP) e a Weighted Goodness of Pronunciation (wGOP), além da verificação do desempenho dos aprendizes em testes de proficiência de língua inglesa (Witt, 1999).

Neste projeto, será realizada apenas a avaliação intrínseca do reconhecedor de pronúncia, através das métricas Word Error Rate (WER), Character Error Rate e Matrizes de Confusão, aplicadas sobre os dados de ambos os corpora coletados, por meio de ten-fold cross validation. A escolha por este tipo de avaliação se deveu à natureza do projeto: como se trata de um trabalho de mestrado, não haveria tempo hábil para realizar um estudo longitudinal com aprendizes de inglês, de modo a avaliar a eficiência do Listener no ensino de pronúncia.

### 7.3 TOOLS AND LIBRARIES

*Lorem ipsum quod dolor sit amet.*

### 7.3.1 HTK

*Lorem ipsum quod dolor sit amet.*

### 7.3.2 Julius

*Lorem ipsum quod dolor sit amet.*

### 7.3.3 Aeiouadô's dictionary and G2P converter

<sup>1</sup> Aeiouadô is a product and an original contribution of this Master's research. It was developed by Mendonça and Aluísio [50], after noticing that no prior work applied machine learning algorithms to grapheme to phoneme conversion in BP.

To the best of our knowledge, all previous efforts to solve the G2P problem in BP used only a rule-based approach, and as such, they require complex linguistic knowledge to code rules and are difficult to evaluate. Unfortunately, it is a common practice in rule-based G2P (and a wrong one!) to develop the transcription rules based on a corpus and to evaluate them on the same corpus. This usually leads to overfitting, so that the results which are reported (some of them which approach 100%) are hardly those which are found when such systems are applied to other data or tested in a different context. In addition to this, most of the G2P systems for BP are proprietary or licensed under commercial terms, therefore their use is restricted.

We tried to overcome this gap by developing a hybrid G2P converter, which makes use of both rules and machine learning algorithms. The converter was evaluated with traditional machine learning metrics, such as precision, recall and F1-measure; therefore, its reported metrics are trustworthy. This converter was used to build a wide pronunciation dictionary, based on wordlist extracted from Wikipedia articles. Both the dictionary and the G2P converter are distributed under permissive licenses, respectively Creative Commons (CC) and Berkeley Software Distribution (BSD). Therefore, these resources aim at promoting the development of novel speech technologies for Brazilian Portuguese. It is interesting to notice that, despite being 6<sup>th</sup> most spoken language in the world [44], with about 200 million speakers, speech recognition and speech synthesis for Brazilian Portuguese are far from the current state of the art, specially what regard to open tools and resources [55].

Aeiouadô's dictionary and G2P converter are based on the dialect of the city of São Paulo. They were designed primarily for Speech Technologies, such as ASR and Text To Speech (TTS); but might also be used by linguists, speech therapists, lexicographers, students of

---

<sup>1</sup> This section contains an extended version of the paper

Brazilian Portuguese as a second language, and whoever is interested in the sound structure of BP.

The G2P converter makes use of a hybrid approach for grapheme to phoneme conversion, based on both manual transcription rules and machine learning algorithms. Hybrid approaches in grapheme to phoneme conversion have been applied successfully to other languages [16, 59, 79, 86]. They have the benefit of taking advantage from both knowledge-based and data-driven methods. We proposed a method in which the phonetic transcription of a given word is obtained through a two-step procedure. Its primary word list derives from the Portuguese Wikipedia dump of 23<sup>rd</sup> January 2014. We decided to use Wikipedia as the primary word list for the dictionary for many reasons: i) given its encyclopedia nature, it covers wide-ranging topics, providing words from both general knowledge and specialized jargon; ii) it contains around 168,8 million word tokens, being robust enough for the task; iii) it makes uses of crowdsourcing, lessening author's bias; iv) its articles are distributed through Creative Commons License. Wikipedia articles were transformed into plain text, tokenized and word types were extracted.

The dictionary makes use of a hybrid approach for grapheme to phoneme conversion, based on both manual transcription rules and machine learning algorithms, and aims at promoting the development of novel speech technologies for Brazilian Portuguese. Hybrid approaches in grapheme to phoneme conversion have been applied successfully to other languages [16][59][79][86]. They have the benefit of taking advantage from both knowledge-based and data-driven methods. We propose a method in which the phonetic transcription of a given word is obtained through a two-step procedure. Its primary word list derives from the Portuguese Wikipedia dump of 23<sup>rd</sup> January 2014. We decided to use Wikipedia as the primary word list for the dictionary for many reasons: i) given its encyclopedia nature, it covers wide-ranging topics, providing words from both general knowledge and specialized jargon; ii) it contains around 168,8 million word tokens, being robust enough for the task; iii) it makes uses of crowdsourcing, lessening author's bias; iv) its articles are distributed through Creative Commons License. Wikipedia articles were transformed into plain text, tokenized and word types were extracted.

We developed a language identifier in order to detect loanwords among data. It is a known fact that when languages interact, linguistic exchanges inevitably occur. One particular type of linguistic exchange is of great concern while building a pronunciation dictionary, namely, non-assimilated loanwords [13]. Non-assimilated loanwords stand for lexical borrowings in which the borrowed word is incorporated from one language into another straightforwardly, without any translation or orthographic adaptation. These words represent a problem to grapheme-to-phoneme (G2P) conversion since they show

orthographic patterns which are not predicted in advance by rules or which are too deviant to be captured by machine learning algorithms. Many algorithms have been proposed to address Language Identification (LID) from text [8, 9, 81, 92]. Since our goal is to detect the language of single words, we employed n-gram character models in the identifier, given its previous success in dealing with short sequences of characters.

Brazilian Portuguese Phonology can be regarded as syllable and stress-driven [73]. In fact, many phonological processes in Brazilian Portuguese are related to or conditioned by syllable structure and stress position [29]. Vowel harmony occurs in pretonic context [10], posttonic syllables show a limited vowel inventory [73], nasalization occurs when stress syllables are followed by nasal consonants [61], epenthesis' processes are triggered by the occurrence of non-allowed consonants in coda position [18] and so on and so forth. Therefore, detecting syllable boundaries and stress is of crucial importance for G2P systems, in order to achieve correct transcriptions. Several algorithms have been proposed to deal with the syllabification in Brazilian Portuguese. However most of them were not extensively evaluated nor were made publicly available [57, 85, 55, 69]. For this reason, we implemented our own syllabification algorithm, based directly on the rules of the last Portuguese Language Orthographic Agreement [11].

Word types recognized as belonging to Brazilian Portuguese by the language identifier were transcribed in a two-step process: i) words are submitted to a set of transcription rules, in which predictable graphemes (mostly consonants) are transcribed; ii) a machine learning classifier is used to predict the transcription of the remaining graphemes (mostly vowels). All the data were subsequently revised. Figure 1 summarizes the method.

We used the Portuguese Wikipedia's dump of 23<sup>rd</sup> January 2014 as the primary word list for the pronunciation dictionary. In order to obtain plain text from the articles, we employed WikiExtractor [49]; it strips all the MediaWiki markups and metadata forms. Afterwards, texts were tokenized and unique words types extracted. The Portuguese Wikipedia has about 168,8 million word tokens and 9,7 million types, distributed among 820,000 articles. With the purpose of avoiding misspellings, URLs and other spurious data, only words with frequency higher than 10, which showed neither digits nor punctuation marks were selected.

A Language Identifier module was developed in order to detect loanwords in the pronunciation dictionary. The Identifier consists of a Linear Support Vector Machine Classifier [76] and was implemented in Python, through Scikit-learn [58]. It was trained on a corpus made of the 200,000, containing 100,000 Brazilian Portuguese words and 20,000 words of each of the following languages: English, French, German, Italian and Spanish. All of these words were collected through

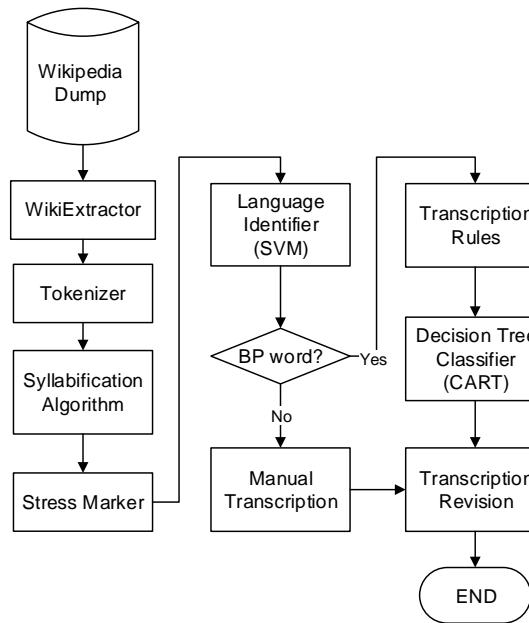


Figure 13: System architecture for building the pronunciation dictionary.

web crawling News' sites and were not revised. We selected these languages because they are the major donors of loanwords to Brazilian Portuguese [2]. From these words we extracted features such as initial and final bi- and trigraphs; number of accented graphs, vowel-consonant ratio; average mono-, bi- and trigraphs probability; and used them to estimate the classifier. Further details can be found in the website of the Project<sup>2</sup>. After training, we applied the classifier to the Wikipedia word list with the purpose of identifying loanwords among data. The identified loanwords were then separated from the rest of words for later revision, i.e. they were not submitted to automatic transcription.

Our syllabification algorithm follows a rule-approach and is based straightforwardly on the syllabification rules described in the Portuguese Language Orthographic Agreement [11]. Given space limitations, rules were omitted from this paper as they can be found in the website of the project, along with all the resources developed for the dictionary. As for the stress marker, once the syllable structure is known in Brazilian Portuguese, one can predict where stress falls. Stress falls:

1. on the antepenultimate syllable if it has an accented vowel <á,â,é,ê,i,ó,ô,ú>;
2. on the ultimate syllable if it contains the accented vowels <á,é,ó> or <i,u>; or if it ends with one of the following consonants <r,x,n,l,z>;

<sup>2</sup> <http://nilc.icmc.usp.br/listener/aeiouado>

3. on the penultimate syllable otherwise.

The transcriber is based on a hybrid approach, making use of manual transcription rules and an automatic classifier, which builds Decision Trees. Initially, transcription rules are applied to the words. The rules covers not all possible graphemes to phoneme relations, but only those which are predictable by context. The output of the rules is what we called the intermediary transcription form. After obtaining it, a machine learning classifier is applied in order to predict the transcription of the remaining graphemes. Figure 2 gives an example of the transcription process.

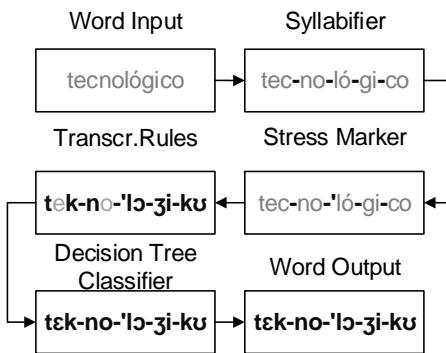


Figure 14: Example of the transcription procedure – in grey: graphemes yet to be transcribed; in black: graphemes already transcribed.

The rules' phase has two main goals: guarantee the correct transcription of certain predictable graphemes (mostly consonants) and also ensure the alignment between graphemes and phones for the classifier. They were set in order to avoid overlapping and order conflicts. Long sequences of graphemes, such as triphthongs, contextual diphthongs and general diphthongs are transcribed first (e.g. <x-ce>→[-se]). Then graphemes involving phones that undergo phonological processes are transcribed (e.g. <ti>→[tʃi], <di>→[dʒi]). After that, several contextual and general monophones are transcribed (e.g. <#x>→[ʃ], <#e-x>→[#e-z]).

On what regards to the classifier, it was developed primarily to deal with the transcription of vowels. In Brazilian Portuguese, vowels have a very irregular behavior, specially the mid ones. Therefore the relations between the vowels' graphemes and their corresponding phonemes are hard to predict beforehand through rules. Consider, for instance, the words "teto" (*roof*) and "gueto" (*ghetto*); both are nouns and share basically the same orthographic environment. However the former is pronounced with an open "e" ['te.tu] and the latter with a closed one ['ge.tu]. The classifier employs Decision Trees, through an optimised version of the CART (Classification and Regression Trees)

algorithm and was implemented in Python, by means of the Scikit-learn library [58].

The algorithm was trained over a corpus of 3,500 words phonetically transcribed and manually revised, with a total of 39,934 instances of phones. The feature extraction happened in the following way. After reviewing the data, we obtained the intermediary transcription form for each of these words and aligned them with the manual transcription. Then, we split the intermediary transcription form into its corresponding phones and, for each phone, we extracted the following information:

1. the phone itself;
2. 8 previous phones;
3. 8 following phones;
4. the distance between the phone and the tonic syllable;
5. word class – parts of speech;
6. the manually transcribed phone.

We considered a window of 8 phones in order deal with vowel harmony phenomena. By establishing a window with such length, one can assure that pretonic phones will be able to reach the transcription of the vowels in the stressed syllable. The classifier was applied to all 108,389 words categorized as BP words by the Language Identifier module, all of them were cross-checked by two linguists with experience in Phonetics and Phonology.

The Portuguese Wikipedia has about 168,8 million word tokens and 9,7 million types, distributed among 820k articles. After applying the filters to the data, i.e. words with frequency higher than 10, with no digits nor punctuation marks, we ended up with circa 238k word types, representing 151,9 million tokens. Table 1 describes the data.

Table 3: Portuguese Wikipedia Summary – Dumped on 23<sup>rd</sup> January 2014.

	<b>Word Tokens</b>	<b>Word Types</b>
Wikipedia	168,823,100	9,688,039
Selected	151,911,350	238,012
<b>% Used</b>	<b>90.0</b>	<b>2.4</b>

The selected words covers 90,0% of the Wikipedia content. Although the number of selected word types seems too small at first glance, one of the reasons is that 7,901,277 of the discarded words were numbers (81,5%). The remaining discarded words contained misspellings (*dirijem-se* – it should be *dirigem-se*), used a non-Roman alphabet (λόγω),

were proper names (*Stolichno, Zé-pereira*), scientific names (*Aegyptophitecus*), abbreviations or acronyms (LCD, HDMI).

As for the language identifier, we trained and evaluated it with the 200,000 words multilingual corpus. The corpus consists of 100,000 Brazilian Portuguese words and 20,000 words from each of the following languages: English, French, German, Italian and Spanish. All of these words were collected through web crawling News' sites and were not revised. The results obtained for the identifier, through 5-fold cross validation are described in Table 2.

Table 4: *Results from the Language Identifier module – Training Phase.*

	Precision	Recall	F1-score	Support
BP words	0.85	0.89	0.87	100,000
Foreign Words	0.88	0.84	0.86	100,000
<b>Avg/Total</b>	<b>0.86</b>	<b>0.86</b>	<b>0.86</b>	<b>200,000</b>

The language identifier showed an average F1-score of 0.86. Although such result is not as good as we expected – some authors reported 99% by using similar methods with trigrams probability, the relatively low F1-score can be explained given the nature of the data. In most language identifiers, the input consists of texts or several sentences, in other words, there is much more data available for the classifier. Since we are working with single words, the confusion of the model is higher and the results are, consequently, worse. Additionally, because the word list used to train the identifier was not revised, there is noise among the data. After training and evaluating the classifier, we applied it to the selected word list derived from the Wikipedia, in order to detect loanwords. Table 3 describes the results gathered.

Table 5: *Results from the Language Identifier module – Wikipedia word list.*

	Wikipedia word list
BP words	108,370 (46%)
Foreign Words	129,642 (54%)
<b>Total</b>	<b>238,012</b>

As one can observe, although we established a frequency filter to avoid spurious words, many loanwords still remain. More than half of the word list selected from Wikipedia consists of foreign words. Notwithstanding that, the list of Brazilian Portuguese words is still of considerable size. For instance, the CMUdict [88], a reference pronunciation dictionary for the English language, has about 125,000 word types.

Concerning the syllabification algorithm and the stress marker, we did not evaluate them in isolation, but together with the transcriber since the rules for each of these modules are intertwined. That is to say the transcription rules are strictly dependent on the stress marker module and the syllable identifier. Besides, the Decision Tree Classifier is built upon the output of the transcription rules, so it is entirely dependent on it. The Decision Tree Classifier was trained over a corpus of 3,500 cross-checked transcribed words, containing 39,934 instances of phones. We analyzed its performance through 5-fold cross validation, the results for each individual phone are summarized in Table 4.

As it can be seen, the method achieved very good results, with a F1-score of 0.98. Many segments were transcribed with 100% accuracy, most of them were consonants. As it was expected, the worst results are related to mid vowels [ɛ, e, ɔ, o], specially mid-low vowels, [ɛ] showed a F1-score 0.66 and [ɔ] of 0.71. It can be the case that since the grapheme context is the same for [ɛ, e] and [ɔ, o], the DecisionTree classifier generalizes, in some cases, to the most frequent phone, that is the mid-high vowels [e,o]. The transcriber also had problems with the [k.s] (F1-score: 0.66) and [ʃ] (F1-score: 0.84). This result was also expected, both these phones are related to the grapheme <x> which, in Brazilian Portuguese, shows a very irregular behavior. In fact, <x> can be pronounced as [ʃ, s, z, k.s], depending on the word: “bruxa” (witch) [ʃ], “próximo” (near) [s]; “exame” (test) [z] and “axila” (armpit) [k.s].

We presented the method we employed in building a pronunciation dictionary for Brazilian Portuguese. High F1-score values were achieved while transcribing most of the graphemes in Brazilian Portuguese and the dictionary can be considered robust enough for Large Vocabulary Continuous Speech Recognition (LVCSR) and Speech Synthesis. Although the rules we developed are language-specific, the architecture we used for compiling the dictionary, by using transcription rules and machine learning classifiers, can be successfully replicated in other languages. In addition, the entire dictionary, all scripts, algorithms and corpora were made publicly available.<sup>34</sup>

**FURTHER DEVELOPMENTS** Since the publishing date of our paper (Mendonça and Aluísio [50]), Aeiouadô G2P has been improved. Recently, we increased the training database to XXX words (XXX phone tokens). Moreover we are now using extra morphological information in order to determine the grapheme’s transcription, mostly to solve the problems with the mid vowels [ɛ, e, ɔ, o].

Previously we were using only the parts of speech as the source of morphological information. We assumed that by just providing the

---

<sup>3</sup> <http://nilc.icmc.usp.br/aeiouado>

<sup>4</sup> [https://github.com/gustavoautma/aeiouado\\_g2p](https://github.com/gustavoautma/aeiouado_g2p)

words' parts of speech, the Decision Tree Classifier would be able to learn and differ pairs of heterophonic homographs, such as "jogo" NOUN (*game*) and "jogo" VERB (*I play*), or "governo" NOUN (*government*) and "governo" VERB (*I rule*). However, given the poor performance of the conversor in discerning between [ɛ] vs. [e], and [ɔ] vs. [o]; we decided to refine the morphological features.

We adapted the training database to the Unitex-PB dictionary [? ], which follows formalismo DELA (Dictionnaire Electronique du LADL)

There is a huge lexicon with,

This type of alternation is very productive in BP. reported to have collected 1,812 pairs of heterophonic homographs in dictionaries and , although only 226 occurred in corpus).

, Pandu , although in a corpus analysis, only 226 [72].

However this is not the case. Previously, only the word class information was used to determine. We thought that would be enough to

#### 7.4 SPEECH CORPORA

Lorem ipsum quod dolor sit amet.

##### 7.4.1 TIMIT

Lorem ipsum quod dolor sit amet.

##### 7.4.2 WSJo

The CSR-I WSJo corpus was compiled by Garofolo et al. [28], within the DARPA Spoken Language Program in order to support research on large-vocabulary Continuous Speech Recognition (CSR) systems.

It focuses on American English and contains read speech of texts drawn from a corpus with Wall Street Journal articles. The texts to be read were selected to fall within either a 5,000-word or a 20,000-word subset of the WSJ text corpus. All verbal punctuation is read out aloud and the prompting texts have been pre-filtered to insure unambiguous pronunciations of words. The corpus comprises spontaneous dictation by journalists with varying degrees of experience in dictation, the precise number of speakers is informed in the documentation. As for the recording environment, a Sennheiser close-talking head-mounted microphone was used together with a secondary microphone of varying types.

Table 7 describes a summary of the WSJo corpus.

For building the acoustic model, we decided to use only a portion of the WSJo. This decision was made since a considerable number of files in the WSJ recordings had:

1. disfluencies phenomena, such as mispronunciations, verbal deletions, false starts and spoken word fragments;
2. emphatic stress in words which would normally not be stressed due to lexical or syntactic factors;
3. non-speech events (chair squeak, cross talk, door slams, paper rustle, phone ring, etc.)
4. truncated audio files.

All these recordings would degrade the estimation of the acoustic model, giving rise to poor phone or triphone HMMs. On account of this problem, we excluded all these files from the training process.

After that, to check the consistency of the transcription, we used forced alignment with an acoustic monophone model trained over all other English corpora. Forced alignment was performed through a general-purpose Viterbi recognizer, which employed beam search to find the most likely HMM states for an utterance. The beam-width was set to 250. That is, for each audio file, if the transcription provided did not correspond to any alignment found by expanding each node over the best 250 hypotheses, the file was pruned and not considered for training.

The portion of the WSJo that we used is detailed in Table 8

#### 7.4.3 *SpeechDat*

*Lorem ipsum quod dolor sit amet.*

#### 7.4.4 *Listener's Corpus*

*Lorem ipsum quod dolor sit amet.*

#### 7.4.5 *Oxford Dictionary AmE Corpus*

The Oxford Dictionary American English (AmE) corpus was compiled by web crawling specially to this project. Oxford University Press has been making dictionaries for the English language for more than 150 years. Their dictionaries are very traditional and widely known whether in lexicographers' or laymen's circles. Recently, they made the dictionaries publicly available on the web<sup>5</sup>. For the AmE version, one can browse 350,000 words, definitions, and entries, together with over 600,000synonyms<sup>6</sup>. A word example can be found in Figure 15.

As one may notice in Figure 15, the entry has many information: (i) the word itself, in orthographic form; (ii) word syllabification; (iii)

---

<sup>5</sup> <http://www.oxforddictionaries.com/>

<sup>6</sup> <http://www.oxforddictionaries.com/words/content-help>

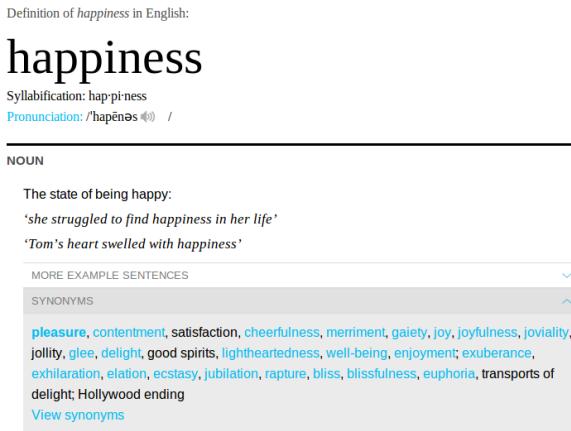


Figure 15: Entry example in the Oxford Dictionary online.

its pronunciation; (iv) the word audio file; (v) Part of Speech (POS) data; (vi) definition; (vii) some example sentences; (viii) and a list of synonyms. The pronunciation follows Oxford's own transcription convention, which can be mapped on the International Phonetic Alphabet (IPA) as in Table 10.

For compiling the corpus, we built a spider through Scrapy [20], a web crawling framework for Python specially designed to crawl websites and extract structured data from their pages. In total, 49,263 entries were crawled. This number was defined in order to be consonant with the dictionary's legal aspects, which defines that only a fraction of its content might be downloaded either personal or institutional use. For each word, we crawled three fields: the word, its transcription and the audio file. According to Oxford University Press' legal notice, we may not display or distribute any of the crawled content in any media, nor we may use commercially. Therefore, we used the data only for estimating the parameters of the acoustic model.

Some xenophones, i.e. phones from other languages, might be seen in Table 10. This happens because Oxford Dictionary also register some loanwords (specially those coming from French) with their original pronunciation, like "Utrecht" and "bon". Since our goal is to deal only with Brazilian-accented English, words such as these were excluded, so no word among the 49,263 entries contain xenophones.

Oxford Dictionary's were recorded by many speakers (both male and female), with high-quality microphones, in sound-isolation rooms. The audios are saved in MP3 format with Variable Bit Rate (VBR), for this reason we had convert each file into WAV and downsample them to 16 kHz. The quality of the audio is excellent with a very high Signal-to-Noise Ratio (SNR), as can be seen in the spectrogram for the word "happiness" in Figure 16.

As one may observe in the regions of silence at the beginning and at the end of the utterance, the background noise approaches to zero. A summary of the corpus can be seen in Figure 16.



Figure 16: Spectrogram of the word “happiness”, present in the Oxford Dictionary AmE Corpus.

#### 7.4.6 *Cambridge Dictionary*

Lorem ipsum quod dolor sit amet.

#### 7.4.7 *OGI-22*

Lorem ipsum quod dolor sit amet.

#### 7.4.8 *Westpoint*

Lorem ipsum quod dolor sit amet.

#### 7.4.9 *LapsBM*

Lorem ipsum quod dolor sit amet.

#### 7.4.10 *Youtube*

Lorem ipsum quod dolor sit amet.

### 7.5 BUILDING THE ACOUSTIC MODEL

#### 7.5.1 *The Phoneset*

Since our goal is to build an ASR system capable of recognizing non-native speech, we propose to use an interlingual phoneset as the basis

of the pronunciation model. By doing this, we can define HMM models for estimating phones which are part of both the speaker's native language (BP) and the target language (AmE).

A straightforward approach would be to look up the literature in phonetics and phonology in order to find a BP-AmE interlingual phoneset. However, to the best of our knowledge, no previous works were carried out in this regard. There are papers addressing specific mispronunciations, such as those discussed in Section 3.3, which list some occurring interlingual phones, but there is not a wide-ranging study available about this matter.

Therein we had to develop our own interlingual phoneset. For simplicity, we decided to adapt the union set formed by the phones contained in two machine-readable dictionaries, one for AmE: Carnegie Mellon University Pronouncing Dictionary (CMUdict) [89], and another for BP: Aeiouadô [50]. By doing this, we can cover most of the phone productions that brazilian ESL learners are likely to make. Advanced students will tend to use more properly the English phones, whereas beginners will have a stronger accent, thus producing more phones from the BP phoneset. A brief description of each of these dictionaries is given below, before we go into further details of our interlingual set.

CMUdict [89] is a machine-readable pronunciation dictionary for AmE which has about 125,000 words and their transcriptions. It was designed primarily for speech applications, such as speech recognition and synthesis, and it has been widely tested in both Academia and industry.

Words in CMUdict are transcribed using ARPAbet, a phonetic transcription code developed by the Advanced Research Projects Agency in 1971. It represents each AmE phone with a distinct sequence of American Standard Code for Information Interchange (ASCII) characters. In the dictionary, there are in total 39 phones plus stress marks. The phone convention is described on Table 13.

As for Aeiouadô, as described in Section ??, its transcriptions are based on the dialect of São Paulo city and contains 39 different phones. The dictionary makes use of a hybrid approach for converting graphemes into phonemes, which employs both manual transcription rules and machine learning algorithms. Its phone convention is presented in Table Table 14.

In what concerns to our interlingual phoneset, we kept all CMUdict phones, since that is the target language's phoneset the learners are trying to achieve. Then we compared each phone in CMUdict with those contained in Aeiouadô, in order to check for missing phones and to analyze whether the overlapping ones really correspond to the same sound.

At a first glance, it seems that BP and AmE share a pool of 24 common phones, comprising fifteen consonantes [b, d, dʒ, f, g, k, l, m, n,

p, s, ʃ, t, tʃ, v, z]; seven vowels [ɛ, i, ɪ, ɔ, u, ʊ, ə]; together with two glides [y, w]. However it is worth noticing that this first impression does not hold true.

Despite the fact that both dictionaries present IPA correspondences, such correspondences should not be taken for granted, without previous analysis. In theory, IPA is capable of describing any sound produced by the human vocal tract with exactness. Still IPA transcriptions are biased by the level of detail one wishes to express and by the assumptions of the transcriber. This is the case for some of these overlapping phones. Several of these consonants and vowels, although marked with the same IPA symbol by CMUDict and Aeiouadô, in fact, can not be regarded as being the same sound, since they show a very different distribution in English and BP.

For instance, the production of /p, t, k/, in BP and AmE can be quite different. In English, such consonants are generally produced as [p, t, k]. However it is known that when they occur in certain contexts, for example, in word initial position or onset of a stressed syllable, they become aspirated; whence [p<sup>h</sup>, t<sup>h</sup>, k<sup>h</sup>] [45]. On the other hand, this process is not found in BP, where, disregard of the context, [p, t, k] show no relevant levels of aspiration [36].

For that reason, in order to properly estimate the HMM states for the interlingual phones, it is mandatory to create aspirated phone models for these consonants that are different from the non-aspirated ones. In our interlingual phoneset, we decided to keep the distinction between aspirated and non-aspirated phones. Therefore, according to our convention, the /p/ that occurs in a stressed syllable of an English word like "pie" is transcribed as [p<sup>h</sup>], while the /p/ of an unstressed syllable or a BP word is transcribed as [p].

Additionally, some vowels that are described by both dictionaries with the same IPA symbol are not exactly equal. Although English and BP both possess the vowels [ɪ, ə, ʊ], the distribution of these phones between both languages is fairly different. In AmE such vowels hold phonological status, i.e. they are phonemes, so that one could find minimal pairs differing only by [ɪ, ə, ʊ], such as "sheep" ['ʃɪp] vs. "ship" ['ʃɪp]; "cut" ['kʰæt] vs. "cat" ['kʰæt]; and "pull" ['pʰʊl] vs. pool ['pʰʊl]. As for BP, these vowels exist solely as part of a phonological process. When the tense vowels [i, a, u] occur in unstressed word-final position, they undergo a lenition process and are produced as the lax vowels [ɪ, ə, ʊ], respectively. Hence the BP [ɪ, ə, ʊ] have different formant values [25] and all the typical characteristics of lax vowels, that is, they are short, they have less energy and, consequently, less clear-cut formants [56].

With regard to the missing phones, there were 15 phones which are only present in the BP inventory, these include eight vowels [a, ă, e, ē, ī, o, ă, ū]; five consonants [y, n, ɻ, x, r]; and two nasal glides [ŷ, ū].

All eight vowels were added to the interlingual phoneset, for they encompass negative transfer problems. For instance, [ã, ē, ï, õ, û] are related to vocalization of final nasals (*vide* 3.3.6) and [a, e, o] to vowel assimilation (*vide* 3.3.8).

The BP rhotic consonants [r, γ, x], were merged onto the same sound, [h] owing to the fact they represent BP dialectal variants not relevant to L1-L2 interphonology.

Furthermore, the BP palatal consonants [ɲ, ʎ] were not considered in the final interlingual phoneset, since we could not find, in the literature, any negative transfer process in which they occur.

The nasal glides were excluded from the interlingual phoneset, instead we preferred to combine them with their accompanying vowels, in order to create nasal diphthongs, such as [ãɪ, ãʊ, ēɪ, õɪ]. This decision was made in accordance with [19], which found that BP nasal diphthongs have a very particular behavior, with articulatory, acoustic and aerodynamic patterns different from the non-nasalized ones. We believe that a single HMM model for each diphthong will be able to better gauge this behavior.

The final phoneset, which we used as the basis for our ASR system, can be found in Table 15.

### 7.5.2 Speech Data

Many of the

### 7.5.3 HMM topology

### 7.5.4 Tree-Based State Tying

Data-driven approaches also show limitations. Since such approaches are generally based on the positive examples which occur in a corpus, rare or non-occurring phenomena are often poorly estimated or even neglected. This is the case for triphone HMM models.

Natural languages have, on average, 30 different phones. The language believed to have the smallest phonetic inventory is Rotokas (East Papuan, New Guinea), with 11 phones, and the one with largest is !Xóö (Khoisan, Botswana/Namibia), with 160 [32]. English is usually assumed to have 37 to 41 phones, depending on the dialect.

In the CMUdict [89], 39 phones are used to describe the words of AmE. When it comes to triphones, in theory, this number might grow by three orders of magnitude, that is  $39^3$  or 59,319. It is true that due to phonotactic constraints many of the virtually possible triphones never take place in practice. For instance, the triphone sequence [ŋ-s+p] does not exist in English, although it is made of valid and existing monophones [ŋ], [s] and [p].

Kuperman et al. [40] examined the monophone, diphone and triphone frequencies in speech corpora for many languages. In what concerns to English, they analysed the Buckeye Corpus and reported that it contains 29,804 different occurring triphones (or types), distributed among 431,000 tokens. Although the actual number of triphones for English is almost half the number of possible permutations, it is still a huge number of triphones to model over a corpus. Therefore, in order to build an ASR system, one always has to deal with data scarcity and try to overcome its limitations.

Within HMM ASR, tree-based state tying is a technique to improve the modelling of rare triphones and allow the estimation of non-occurring ones. It was initially proposed by Young et al. [91] and since then has become a standard procedure in HMM ASR systems. The aim of tree-based state tying is to maintain the balance between the model complexity and the available training data by tying the HMM states of acoustically similar triphones.

In contrast to the majority of methods in ASR, tree-based state tying is carried out in a top-down, knowledge-based way. A specialist (generally a speech scientist, phonologist or phoneticist) uses his/her knowledge to build a phonetic decision tree which will organize the phones into sets with similar acoustic parameters.

In most cases, the criteria used to organize phones into a decision tree are the so-called natural classes. Natural classes were proposed within the generative phonology framework. In this framework, phones and phonemes are no longer considered the basic units of analysis, instead it is assumed that they can be broken down into smaller components, which describe aspects of articulation and perception, such as [+nasal], [-continuant], [+strident], etc. For instance, the phone [s] would not be represented in generative phonology as a single phonetic symbol [s], but as a bundle of distinctive features [35]:

[a] →	<table border="0"> <tr><td>+consonantal</td></tr> <tr><td>-syllabic</td></tr> <tr><td>-sonorant</td></tr> <tr><td>+continuant</td></tr> <tr><td>+anterior</td></tr> <tr><td>+coronal</td></tr> <tr><td>+strident</td></tr> <tr><td>-voiced</td></tr> </table>	+consonantal	-syllabic	-sonorant	+continuant	+anterior	+coronal	+strident	-voiced
+consonantal									
-syllabic									
-sonorant									
+continuant									
+anterior									
+coronal									
+strident									
-voiced									

Distinctive features were probably the most important contribution of generative phonology. They became popular as a model specially because they were able of simplify phonological processes by grouping segments. Consider the case of final-obstruent devoicing. In many pronunciations of Standard German, voiced obstruent consonants be-

come devoiced when they occur in word final position. This is the case for a large number of german nouns which make their plural by the addition of the suffix {-e}. Table 16 contains a few examples extracted from Grijzenhout [31].

As one can observe at the provided examples, the plural forms contain only voiced obstruents whilst the singular forms contain their devoiced counterparts. To express this phonological process within structural phonology, one would have to introduce at least four rules:

$$[b] \rightarrow [p]/_{\#}$$

$$[d] \rightarrow [t]/_{\#}$$

$$[g] \rightarrow [k]/_{\#}$$

$$[d] \rightarrow [s]/_{\#}$$

Whereas using distinctive features, all cases of german final-obstruent devoicing can be explained by a single rule:

$$\begin{bmatrix} +\text{consonantal} \\ -\text{syllabic} \\ -\text{sonorant} \\ +\text{voiced} \end{bmatrix} \rightarrow [-\text{voiced}] /_{\#}$$

The main benefits of distinctive features lie in their capability of making generalizations, that is to say of grouping phones together in a meaningful way. Phonologists have long known that sounds that share the same manner, place of articulation, or voicing level behave similarly. Distinctive features provide a way to express this in an elegant way, by establishing that feature matrices which are not fully specified do form a natural class. Therefore a distinctive features matrix

$$\begin{bmatrix} +\text{consonantal} \\ -\text{syllabic} \end{bmatrix}$$

represents all consonants, whereas

$$\begin{bmatrix} +\text{consonantal} \\ -\text{syllabic} \\ +\text{continuant} \\ +\text{voiced} \end{bmatrix}$$

represents all voiced fricatives, etc. For developing the phonetic decision tree, the specialist employs his/her knowledge of phonetics and phonology in order to define questions about the phonetic environment of a given phone. This phonetic environment is defined by using natural classes, such that an example question would be "is the

phone preceded by an obstruent?" or "is there a fricative after the phone?" Technically, the tree is a binary one, i.e a connected acyclic graph such that the degree of each vertex is no more than three. Each internal node of the tree represents a question about the phonetic context a triphone, each branch represents the answer in a yes-no form and leaf nodes define HMM states. Once the tree is built, its structure is used to decide how HMM states will be tied among triphone models. Figure 17 presents an example of a phonetic decision tree.

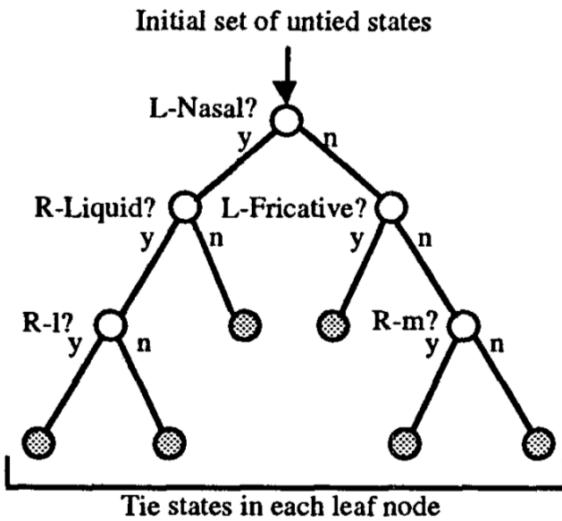


Figure 17: Phonetic decision tree for HMM state tying [91].

The tree input is each triphone being analysed.

The clustering procedures begins by placing all observations in a single root node. All questions are analised and the one which maximise the likelihood of a single diagonal covariance Gaussian is chosen, then the node is split and child nodes generated. The splitting goes on until it falls below a threshold. Commonly, a minimum threshold is also set, the usual approach is to consider the frequency of occurrence of the phones in a corpus. That it, if a given phone  $p$  has  $m$  samples and the minimum threshold is  $n$ , such that  $m > n$ , the phone  $p$  is mapped unto a more general and robust phone. Consider that the triphone  $[i-\eta]+g$  appeared 30 times on corpus, and the minimum threshold for splitting the node was 45, then  $[i-\eta]+g$  would be modeled into a more general phone, say, for instance,  $[i-\eta+g]$  or  $[i-\eta]$ .

In the example shown in Figure 17, the first node (the root of the tree) checks if the left part of the triphone contains a nasal consonant. If positive, the tree examines the right side of the triphone, by questioning whether it is a liquid consonant. If negative, a leaf is reached and the HMM state to be tied is outputted, e.g. "tie the 1<sup>st</sup> emitting HMM state of the analysed triphone A to [Nasal-A+\*]". Figure 18 summarizes the state tying procedure.

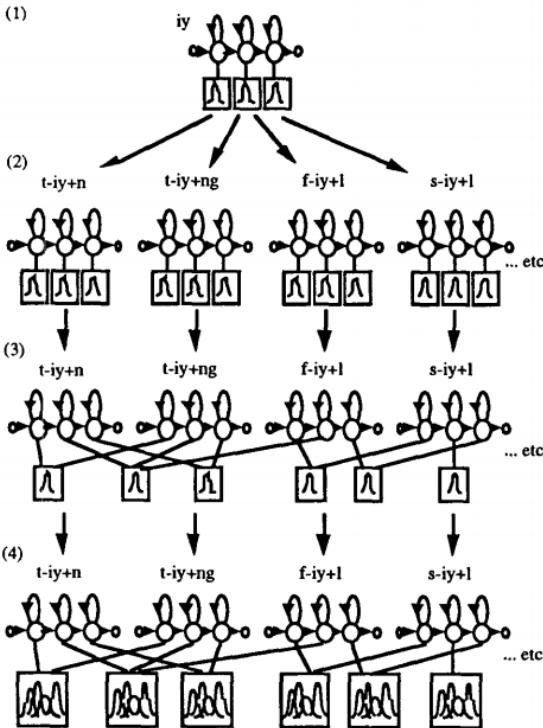


Figure 18: Tied-state HMM system build procedure [91].

For building the phonetic decision tree for Listener, we based ourselves on the distinctive feature set proposed by Jensen [35], which follows the main guidelines of generative phonology by dividing the features into four central classes: i) major class features, ii) manner features; iii) place features; and iv) laryngeal features.

In practice, classes work as following. Major class features distinguish among the most general classes of sound, i.e. vowels, consonants and glides (or semi-vowels). Manner features determine how sounds are articulated, that is do they consist of a stop, a nasal, a fricative, a liquid, a trill or a flap? Place features describe where in the mouth sounds are produced, whether in the labial region, the alveolar region, the velar region, etc. Finally, laryngeal features represent the glottal states of sounds, their basic purpose is to differ voiced sounds from unvoiced ones.

Jensen [35] proposes a set of 17 features to describe most of the world languages.

1. *Major class features*: syllabic, consonantal and sonorant;
2. *Manner features*: continuant, nasal, lateral, strident and delayed release;
3. *Place features*: anterior, coronal, distributed, high, low, back, round and Advanced Tongue Root (ATR).

4. *Laryngeal features*: voice and Heightened Subglottal Pressure (HSP);

The somewhat reduced set for place features is capable of representing a large amount of places of articulation since features which are regularly restricted to vowels (such as high, low, back and round) are also shared with consonants. Besides, once features have a binary nature, therefore, in theory, a number  $n$  of features is able to distinguish up to  $2^n$  phones. In Figure 19, a comparison is shown between place features and their corresponding regions of articulation. For a full explanation of each feature, please see Jensen [35].

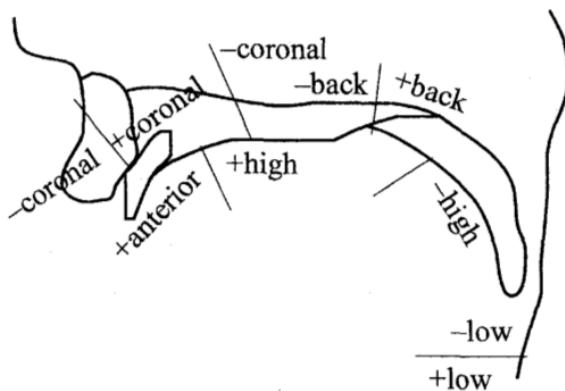


Figure 19: Distinctive features for places of places of articulation [35].

According to this set of distinctive features, we can arrange the entire phonetic inventory of AmE as in Table 17 and that of BP as in Table 18.

## 7.6 BUILDING THE PRONUNCIATION MODEL

To the best of our knowledge, no previous research has addressed the problem of generating brazilian-accented transcriptions for ASR purposes or has described the mispronunciations phenomena from a computational perspective. Therefore we had to develop our own pronunciation model<sup>7</sup>. There are basically three main approaches we could use to build such model: rule-based methods (XXX CITATION), machine learning methods (XXX CITATION) and hybrid ones (XXX CITATION). For achieving good performance through machine learning or hybrid approaches, one necessary needs a large annotated corpus. That is not the case though. The only Brazilian-accented transcribed corpus we have access is the Listener Corpus, but we carried out some pilot experiments that showed it was not robust enough for the task.

That being so, we decided to make use of a rule-based approach for building the pronunciation model. We reviewed all papers de-

<sup>7</sup> "Pronunciation models" are also called "pronunciation dictionaries". In this thesis, we are going to use both terms interchangeably, without any distinction.

scribed in Chapter 3, that deal with the mispronunciation of English phones by brazilians, in order to find interlingual allophones, such as the English [θ] usually becomes [t], [t<sup>h</sup>] or [f] in beginners' speech [67].

By knowing the allophones, we developed rules in order to generate the mispronunciations in the dictionary. The mispronunciation contexts specified through rewrite rules are thus a contribution of this thesis. It is worth mentioning that, for creating the rules, we took into account the frequency of occurrence of each mispronunciation (when this information was available on the papers). On that account mispronunciations which were reported as being very rare or with no significant probability were excluded.

We implemented the rules through a Python script which made a large usage of the Regular Expression (regex) library. As one familiar with regex knows, regex rules might get too clumsy and hard to understand. For instance, one of the rules in our Python script is:

Listing 1: Example of a fully-specified regex rule.

```
re.sub('(ih|iy) (m|n|ng) (#|[aeiouyw])', r'i~ \3', pron)
```

To one not familiar with how the dictionary is structured, this rule, in our opinion, could be somewhat meaningless. Therefore, to render the text easier to read, we are going to describe the rules in a pseudocode with a rather flexible notation<sup>8</sup>. Whenever possible, we try to simplify the rules' contexts, so anyone not acquainted with the dictionary format or the regex syntax might understand their content.

The pseudocode for each mispronunciation pattern is described in the following subsections. The conventions below apply to all examples:

1. phonetic transcriptions are placed between brackets and follow the Listener phoneset convention ] (see Section 7.5.1), therefore [helow] becomes [hh eh l ow];
2. ortographic forms are placed between angle brackets, like <hello>;
3. the dollar sign “\$” represents word final boundary, whether in phonetic or ortographic transcription, thus [ih d\$] means that the transcription ends in [ih d];
4. the caret symbol “^” denotes word initial boundary, whether in phonetic or ortographic transcription, thus <^st> means that word begins with <^st>.

---

<sup>8</sup> For those who are insterested in checking the code itself, it can be downloaded on the site of the project: <http://nilc.icmc.usp.br/listener>

5. the pipe symbol “|” inside parentheses describes alternatives among a group of phones or graphemes, e.g. [ah (m|n|g)] means that [ah] is immediately followed by [m], [n] or [ng].

### 7.6.1 Syllable Simplification

Rules for syllable simplification were created upon production data reported on the following works: Cardoso [14], Silveira [75] Rauber and Baptista [63], and Rebello and Baptista [65]. The rules encompass three major cases of syllable simplification.

The first one refers to stop consonants in word final position, such as the final [p] in “pop” which is likely to be produced by learners together with an epenthetic vowel [i], whence ['p<sup>h</sup>api].

The second case regards written language influencing the learner’s pronunciation, e.g. brazilian ESL learners tend to pronounce the word “name” with a final [i], although such vowel does not occur in the English form: ['neɪm]. This happens influenced by written language, in BP orthography, a final “e” means that the word should end with the phone [i], thus the ESL student transfer put this knowledge into practice in his/her interlanguage.

The third and last case of syllable simplification concerns initial clusters formed by [s] and another consonant, hence initial [sC] clusters. In this case, an epenthetic vowel [i] is appended to the beginning of the word and the consonantal cluster is broken into two syllables, so that [sC] becomes [is.C].

The pseudocode containing rules for all these contexts is defined in Listing 2.

Listing 2: Pronunciation rules for generating syllable simplification cases.

```
%%% Definitions
word -- string with the orthographic form of the word
pron -- string with the phonetic transcription of the word
new_pron -- string with the modified pronunciation
dict -- dictionary with all CMU words as keys and pron as values

for word, pron in dict:

    %% Rules after Cardoso (2011)
    %% Stop consonants in word final position
    if pron has [p$]: % e.g. pop
        replace [p$] by [p ih$] and append new_pron to dict
    elif pron has [b$]: % e.g. tab
        replace [b$] by [b ih$] and append new_pron to dict
    elif pron has [t$]: % e.g. tit
        replace [t$] by [t ih$] and append new_pron to dict
    elif pron has [d$]: % e.g. and
        replace [d$] by [d ih$] and append new_pron to dict
    elif pron has [k$]: % e.g. book
```

```

    replace [k$] by [k ih$] and append new_pron to dict
    elif pron has [g$]: % e.g. dog
        replace [g$] by [g ih$] and append new_pron to dict

    %% Rules after Silveira (2012)
    %% Written language influencing pronunciation
    elif word has <me$> and pron has [m$]: % e.g. time
        replace [m$] by [m ih$] and append new_pron to dict
    elif word has <ne$> and pron has [n$]: % e.g. dine
        replace [n$] by [n ih$] and append new_pron to dict
    elif word has <[AEIOU]le$> and pron has [l$]: % e.g. whale
        replace [l$] by [l ih$] and append new_pron to dict
    elif word has <re$> and pron has [r$]: % e.g. care
        replace [r$] by [r ih$] and append new_pron to dict
    elif word has <se$> and pron has [s$]: % e.g. house
        replace [s$] by [s ih$] and append new_pron to dict
    elif word has <ce$> and pron has [s$]: % e.g. nice
        replace [s$] by [s ih$] and append new_pron to dict
    elif word has <ze$> and pron has [z$]: % e.g. americanize
        replace [z$] by [z ih$] and append new_pron to dict
    elif word has <te$> and pron has [t$]: % e.g. animate
        replace [t$] by [t ih$] and append new_pron to dict
    elif word has <de$> and pron has [d$]: % e.g. amplitude
        replace [d$] by [d ih$] and append new_pron to dict
    elif word has <ke$> and pron has [k$]: % e.g. make
        replace [k$] by [k ih$] and append new_pron to dict
    elif word has <gue$> and pron has [g$]: % e.g. league
        replace [g$] by [g ih$] and append new_pron to dict
    elif word has <fe$> and pron has [f$]: % e.g. life
        replace [f$] by [f ih$] and append new_pron to dict
    elif word has <ve$> and pron has [v$]: % e.g. love
        replace [v$] by [v ih$] and append new_pron to dict
    elif word has <pe$> and pron has [p$]: % e.g. microscope
        replace [p$] by [p ih$] and append new_pron to dict
    elif word has <be$> and pron has [b$]: % e.g. subscribe
        replace [b$] by [b ih$] and append new_pron to dict
    elif word has <xe$> and pron has [k s$]: % e.g. axe
        replace [k s$] by [k s ih$] and append new_pron to dict

    %% Rules after Rauber & Baptista (2004) and Rebello & Baptista
    %% (2006)
    %% Initial /sC/ clusters
    elif pron has [^s p]: % e.g. sport
        replace [^s p] by [^i s p] and append new_pron to dict
    elif pron has [^s t]: % e.g. stop
        replace [^s t] by [^i s t] and append new_pron to dict
    elif pron has [^s k]: % e.g. school
        replace [^s k] by [^i s k] and append new_pron to dict
    elif pron has [^s l]: % e.g. slide
        replace [^s l] by [^i s l] and append new_pron to dict
    elif pron has [^s m]: % e.g. small
        replace [^s m] by [^i s m] and append new_pron to dict

```

```

    elif pron has [^s n]: % e.g. snail
        replace [^s n] by [^i s n] and append new_pron to dict
    elif word has <^sw> and pron has [^s w]: % e.g. swim
        replace [^s w] by [^i s w] and append new_pron to dict
    elif word has <^sw> and pron has [^s ao]: % e.g. sword
        replace [^s ao] by [^i s w ao] and append new_pron to dict

end for

```

### 7.6.2 Consonant Change

The rules for consonantal change were defined based on the results of Reis [67] and Trevisol [80]. Listing 3 describes the pseudocode for generating the mispronunciations regarding consonant changes.

Listing 3: Pronunciation rules for generating consonant change cases.

```

%%% Definitions
word -- string with the orthographic form of the word
pron -- string with the phonetic transcription of the word
new_pron -- string with the modified pronunciation
dict -- dictionary with all CMU words as keys and pron as values

for word, pron in dict:

%%% Rules after Reis (2006)
%%% General cases
if pron has [th]: % e.g. think
    replace [th] by [f] and append new_pron to dict
    replace [th] by [s] and append new_pron to dict
    replace [th] by [t] and append new_pron to dict
    replace [th] by [tt] and append new_pron to dict
elif pron has [dh]: % e.g. there
    replace [dh] by [d] and append new_pron to dict

%%% Rules after Trevisol (2010)
%%% Devoicing in word final position
elif [dh$]: % e.g. bathe
    replace [dh] by [th] and append new_pron to dict

end for

```

### 7.6.3 Deaspiration of Voiceless Plosives in Initial or Stressed Positions

With regard to the deaspiration of voiceless plosives, we considered the analyses of the phenomenon as described in following papers: Alves and Seara [3], Prestes [60], Schwartzhaupt and Alves [70] and

Zimmer [93]. These analyses establish fundamentally the same, brazilian ESL learners tend to replace the aspirated phones in English [ $p^h$ ,  $t^h$ ,  $k^h$ ] by their corresponding deaspirated ones [p, t, k], since the latter ones are part of BP phonetic inventory, whereas the former ones are not.

Therefore, for generating the deaspiration cases, it would simple mean to transform all occurrences of [ $p^h$ ,  $t^h$ ,  $k^h$ ] into [p, t, k]. However, in CMUdict, the difference aspirated voiceless plosives and the deaspirated ones is not pointed out. Both aspirated and non-aspirated plosives are annotated with the same symbol, for instance, “pit” is transcribed as [p ih t] and “spit” as [s p ih t], despite the fact that the former [p] is aspirated and the latter is not. This is also true for aspirated and non-aspirated [t] and [k]. “Top” and “stop” are transcribed both with a [t] although they correspond to different sounds, the same happens with the [k] in “cat” and “scat”.

For solving this problem, we chose to transform all [p, t, k] in the corpus into non-aspirated ones, thus [pp, tt, kk] according to Listener’s phoneset convention (see Section 7.5.1). After replacing all [p, t, k] in the dictionary by [pp, tt, kk], we generated their aspirated counterparts, given that their contexts is predictable. In AmE, there basically two contexts in which voiceless plosives become aspirated: i) when they occur in a stressed syllable, not after an [s]; ii) and when they occur in word initial position, irrespective of the stress [45]. We rewrote these contexts into rules, then producing all voiceless aspirated in the corpus.<sup>9</sup> The pseudocode for the rules is described in Listing 4.

#### 7.6.4 Devoicing in Word-Final Obstruents

For terminal devoicing cases, we based our rules on the contexts presented by Castilho [15]. These rules explicit a phonetic process in which the final [z] becomes devoiced, being produced as [s], in words such as “Charles” or “rose”. That is to say these words pronounced as ['rous] and ['tʃarls], instead of ['rouz] and ['tʃarlz].

Albuquerque and Silva [1] studied cases of terminal devoicing in plosives, as in ['dag] turning into ['dak], however their results are inconclusive given the limited sample. Besides the study of Zimmer and Alves contradicts Albuquerque and Silva [1], for they found no statistical significance, in what regards to voicing quality, among the realizations of word final obstruents between native speakers of English and brazilian ESL learners.

---

<sup>9</sup> Since deaspiration is also conditioned by the stress of the syllable, we had to move back to the original version of CMUdict, where lexical stress is annotated. In spite of this, for simplicity we are going to leave this workaround out of the pseudocode and assume that the dictionary has the stress information.

Listing 4: Pronunciation rules for generating plosive deaspiration cases.

```

%%% Definitions
word -- string with the orthographic form of the word
pron -- string with the phonetic transcription of the word
new_pron -- string with the modified pronunciation
dict -- dictionary with all CMU words as keys and pron as values

%%% Transform all plosives into their non-aspirated counterparts
replace all [p] in the corpus by [pp]
replace all [t] in the corpus by [tt]
replace all [k] in the corpus by [kk]

%%% Now generate the aspirated pronunciations
for word, pron in dict:

   %%% Rules after Cardoso (2011)
   %%% Stops in stressed syllables are aspirated
    if pron has [pp] in a stressed syllable and not [s pp ..1]: % e.
        g. pop
        replace [pp] by [p ..1] and append new_pron to dict
    elif pron has [tt] in a stressed syllable and not [s tt ..1]: %
        e.g. pop
        replace [tt] by [t ..1] and append new_pron to dict
    elif pron has [kk ..1] in a stressed syllable and not [s kk
        ..1]: % e.g. pop
        replace [kk ..1] by [k ..1] and append new_pron to dict

   %%% Stops in stressed word initial positions are aspirated
    elif pron has [$pp]: % e.g. tab
        replace [$pp] by [$p] and append new_pron to dict
    elif pron has [$tt]: % e.g. tab
        replace [$tt] by [$t] and append new_pron to dict
    elif pron has [$k]: % e.g. tab
        replace [$kk] by [$k] and append new_pron to dict

end for

```

For this reason, we decided to discard such phenomenon and deal only with the terminal devoicing of fricatives. Thereby a more accurate title for this section would be “devoicing in word-final fricatives”, yet we preferred to keep the broader natural class “obstruents”, since that is how the process is commonly referred to in the literature. Listing 5 contains the pseudocode for the rewrite rules.<sup>10</sup>

---

<sup>10</sup> It is worth mentioning that the process described in Section 7.6.2, when [ð] is realized as [θ] in word-final position is also a case of terminal obstruent devoicing. In spite of this, we did not find any paper in the literature classifying this phenomenon in such way.

Listing 5: Pronunciation rules for generating terminal devoicing cases.

```

%%% Definitions
word -- string with the orthographic form of the word
pron -- string with the phonetic transcription of the word
new_pron -- string with the modified pronunciation
dict -- dictionary with all CMU words as keys and pron as values

for word, pron in dict:

%%% Rule after Castilho (2004)
if pron has [z$]: % e.g. rose
    replace [z$] by [s$] and append new_pron to dict

end for

```

### 7.6.5 Delateralization and rounding of lateral liquids in final position

In what concerns to the delateralization and rounding of lateral liquids in final position (also known as vocalization of lateral), we based our rules in the findings of Baratieri [5] and Moore [53]. Both these authors describe the same phonetic contexts in which the phenomenon takes place. According to them the English lateral [l] is pronounced as a vowel [ʊ] by many brazilian ESL learners, when such consonant occurs in syllable final position before a consonant, or in word final position. For instance, learners will tend to say “salt” as [kɪʊ] instead of [kɪl]. The pseudocode with the rules for generating lateral vocalization mispronunciations is found in Listing 6.

Listing 6: Pronunciation rules for generating lateral vocalization cases.

```

%%% Definitions
word -- string with the orthographic form of the word
pron -- string with the phonetic transcription of the word
new_pron -- string with the modified pronunciation
dict -- dictionary with all CMU words as keys and pron as values

for word, pron in dict:

%%% Rules after Baratieri (2006) and Moore (2008)
if pron has [l] followed by a consonant: % e.g. salt
    replace that [l] by [w] and append new_pron to dict
elif pron has [l$]: % e.g. tall
    replace that [l] by [w] and append new_pron to dict

end for

```

### 7.6.6 *Vocalization of final nasals*

Rules for the vocalization of final nasals were grounded on the phonological processes described in the following works: Kluge et al. [39], Kluge and Baptista [38], Kluge [37], Silveira [74] and Silveira [75]. The rules comprise two main cases with respect to the vocalization of final nasals.

In the first one, the final nasal is deleted, the previous vowel is nasalized and, if the vowel does not exist in BP, it is produced as its most acoustically similar vowel in BP. For instance, in the word “sandwich” ['sænd.wɪtʃ], the [æn] is likely to become [ã] in the production of brazilian ESL learners, with the nasal [n] being deleted, the [æ] vowel being replaced by the BP vowel [a] and then becoming nasalized; hence ['sãnd.wɪtʃ].

The second case addresses L1 spelling patterns interfering in the pronunciation of the brazilian ESL learners. This process is similar to the one described above, the nasal is deleted and the previous vowel also nasalized, however the vowel quality is influenced not by perceptual traits, but by the orthographic form of the word. The word “opium”, for example, although ending with a schwa [ə], ['ou.pri.əm], is usually produced with a [ũ] by the brazilian ESL learner, given that an “u” appears in the spelling, so ['ou.pri.ũ].

Listing 7 contains the pseudocode for generating both cases of final nasal vocalization.

### 7.6.7 *Velar consonantal paragoge*

### 7.6.8 *Vowel assimilation*

The rules for vowel assimilation were determined based on the results of Battistela [6], Rauber et al. [64] and Rauber [62]. Listing 9 contains the pseudocode for generating pronunciations with vowel assimilations from L1 to L2.

### 7.6.9 *Interconsonantal epenthesis (-ed and -s morphemes)*

Table 6: Results from the Transcriber – Performance per phone.

	Precision	Recall	F1-score	Support
<i>syl. boundary</i>	1.00	1.00	1.00	9099
<i>stress</i>	1.00	1.00	1.00	3507
p	1.00	1.00	1.00	760
b	1.00	1.00	1.00	357
t	0.99	0.99	0.99	1135
d	0.99	0.99	0.99	1148
k	0.99	0.99	0.99	978
g	1.00	1.00	1.00	298
tʃ	0.98	0.98	0.97	450
dʒ	0.96	0.96	0.96	243
m	1.00	1.00	1.00	668
n	1.00	1.00	1.00	556
j̄	1.00	1.00	1.00	69
f	1.00	1.00	1.00	311
v	1.00	1.00	1.00	531
s	0.98	0.98	0.98	2309
z	0.93	0.94	0.93	416
ʃ	0.84	0.84	0.84	138
k.s	0.72	0.64	0.66	41
ʒ	1.00	1.00	1.00	196
l̄	1.00	1.00	1.00	682
ʌ	1.00	1.00	1.00	58
r̄	1.00	1.00	1.00	1388
h̄	0.98	0.99	0.99	737
fī	0.97	0.92	0.94	169
w̄	0.97	0.98	0.97	441
~w̄	0.98	0.99	0.99	309
j̄	0.97	0.95	0.96	223
~j̄	0.95	1.00	0.98	110
ā	1.00	1.00	0.99	2316
ə̄	0.99	0.99	0.99	1093
ɛ̄	0.65	0.68	0.66	275
ē	0.93	0.91	0.92	1779
ī	0.98	0.99	0.98	2073
ɪ̄	0.97	0.97	0.97	365
ɔ̄	0.69	0.75	0.71	220
ō	0.93	0.92	0.93	1112
ū	0.96	0.96	0.96	488
ʊ̄	1.00	1.00	1.00	1033
[ March 28, 2015 at 23:19 – 1.00 classicthesis 1.00 version 0.1.00 ]				719
~ē	0.96	0.97	0.97	497
~ī	0.99	0.99	0.99	274

Table 7: Summary of the entire WSJo Corpus.

Recorded files	X
Total speech time	X
Average time per file	X
Original format	X
Number of different speakers	X

Table 8: Summary of WSJo Part We Used.

Recorded files	X
Total speech time	X
Average time per file	X
Original format	X
Number of different speakers	X

Table 9: Summary of the Listener's Corpus.

Recorded files	6,892
Total speech time	6.8 hours
Average time per file	1.02 seconds
Original format	WAV 16kHz
Number of different speakers	53

Table 10: Oxford Dictionary phone convention.

#	OXFORD PHONE	IPA PHONE	EXAMPLE	TRANSCRIPTION
1	(h)w	aaaaa	when	trans
2	ä	ɔ	hot	trans
3	ô	ɔ	saw	trans
4	ōo	u	too	trans
5	ā	ei	day	trans
6	ē	i	see	trans
7	ī	ai	my	trans
8	ō	ou	no	trans
9	ə	ə	ago	trans
10	œ (foreign)	œ	Goethe (German)	trans
11	öö	ʊ	put	trans
12	γ (foreign)	ɣ	Utrecht (French)	trans
13	a	æ	cat	trans
14	b	b	bad	trans
15	CH	tʃ	chipÂ	trans
16	d	d	day	trans
17	e	ɛ	bed	trans
18	e(ə)r	ɛr	hair	trans
19	f	f	fight	trans
20	g	g	get	trans
21	h	h	hi	trans
22	i	i	sit	trans
23	i(ə)r	ir	near	trans
24	j	dʒ	jar	trans
25	k	k	kick	trans
26	KH	x	loch	trans
27	l	l	lie	trans
28	m	m	man	trans
29	N (foreign)	˜	bon (French)	trans
30	n	n	no	trans
31	NG	n	ring	trans
32	oi	ɔɪ	boy	trans
33	ou	au	how	trans
34	p	p	pie	trans
35	r	r	run	trans
36	s	s	save	trans
37	SH	ʃ	she	trans
38	t	t	time	trans
39	TH	ð	this	trans
40	TH	θ	thin	trans
41	v	v	vow	trans
42	y	y	yes	trans
43	z	z	zoo	trans
44	ZH	ʒ	decision	trans

Table 11: Summary of the Oxford Dictionary AmE Corpus.

Recorded files	49,263
Total speech time	4 hours
Average time per file	1.02 seconds
Original format	MP3 (VBR)
Number of different speakers	Unknown

Table 12: Summary of the Listener's Corpus.

Recorded files	6,892
Total speech time	6.8 hours
Average time per file	1.02 seconds
Original format	WAV 16kHz
Number of different speakers	53

Table 13: CMUdict phone convention.

#	CMU PHONE	IPA PHONE	EXAMPLE	TRANSCRIPTION
1	AA	[ɑ]	odd	AA D
2	AE	[æ]	at	AE T
3	AH	[ə]	hut	HH AH T
4	AO	[ɔ]	ought	AO T
5	AW	[aʊ]	cow	K AW
6	AY	[aɪ]	hide	HH AY D
7	B	[b]	be	B IY
8	CH	[tʃ]	cheese	CH IY Z
9	D	[d]	dee	D IY
10	DH	[ð]	thee	DH IY
11	EH	[ɛ]	Ed	EH D
12	ER	[ər]	hurt	HH ER T
13	EY	[aɪ]	ate	EY T
14	F	[f]	fee	F IY
15	G	[g]	green	G R IY N
16	HH	[h]	he	HH IY
17	IH	[ɪ]	it	IH T
18	IY	[i]	eat	IY T
19	JH	[dʒ]	gee	JH IY
20	K	[k]	key	K IY
21	L	[l]	lee	L IY
22	M	[m]	me	M IY
23	N	[n]	knee	N IY
24	NG	[ŋ]	ping	P IH NG
25	OW	[oʊ]	oat	OW T
26	OY	[ɔɪ]	toy	T OY
27	P	[p]	pee	P IY
28	R	[ɹ]	read	R IY D
29	S	[s]	sea	S IY
30	SH	[ʃ]	she	SH IY
31	T	[t]	tea	T IY
32	TH	[θ]	theta	TH EY T AH
33	UH	[ʊ]	hood	HH UH D
34	UW	[u]	two	T UW
35	V	[v]	vee	V IY
36	W	[w]	we	W IY
37	Y	[y]	yield	Y IY L D
38	Z	[z]	zee	Z IY
39	ZH	[ʒ]	seizure	S IY ZH ER

Table 14: Aeiouadô phone convention.

#	AEIOWADÔ PHONE	IPA PHONE	EXAMPLE	TRANSCRIPTION
1	a	[a]	amor	a m o x
2	a~	[ã]	canto	k a~ t U
3	b	[b]	besta	b e s t @
4	d	[d]	da	d a
5	dZ	[dʒ]	dia	dZ i @
6	E	[ɛ]	é	E
7	e	[e]	dedo	d e d U
8	e~	[ẽ]	venda	v e~ d @
9	f	[f]	frio	f 4 i U
10	g	[g]	gula	g u l @
11	G	[ɣ]	carga	carga
12	i	[i]	aí	a i
13	I	[i]	come	k o~ m I
14	i~	[ĩ]	sim	s i~
15	J	[ɲ]	ganho	g a~ J U
16	j	[y]	pai	p a j
17	j~	[ŷ]	parem	p a 4 e~ j~
18	k	[k]	compra	k o~ p 4 @
19	l	[l]	lá	l a
20	L	[ʎ]	palha	p a L @
21	m	[m]	mãe	m a~ j~
22	n	[n]	não	n a~ w~
23	O	[ɔ]	pó	p O
24	o	[o]	gorro	g o x U
25	o~	[õ]	com	k o~
26	p	[p]	pessoa	p e s o @
27	s	[s]	susto	s u s t U
28	s	[ʃ]	chato	S a t U
29	t	[t]	tato	t a t U
30	tS	[tʃ]	noite	n o j tS I
31	u	[u]	durmo	d u G m U
32	U	[ʊ]	cúmulo	k u m u l U
33	u~	[ũ]	um	u~
34	v	[v]	vida	v i d @
35	w	[w]	aula	a w l @
36	w~	[ŵ]	canhão	k a~ J a~ w~
37	x	[x]	rato	x a t U
38	z	[z]	zebra	z e b 4 @
39	4	[ɾ]	arara	a 4 a 4 @
40	@	[ə]	bola	b O l @

Table 15: Interlingual dictionary phone convention. BP word examples are shown in *italics*.

#	INTERL. PHONE	IPA PHONE	EXAMPLE	TRANSCRIPTION
1	a	[ə]	<i>da</i>	d a
2	aa	[ɑ]	<i>odd</i>	aa d
3	aaa	[a]	<i>dá</i>	d aaa
4	ae	[æ]	<i>cat</i>	k ae t
5	ah	[ə]	<i>but</i>	b ah t
6	ahw	[əv]	<i>xxx</i>	xx xx
7	am	[ã]	<i>xxx</i>	xx xx
8	ao	[ɔ]	<i>for</i>	f ao r
9	aow	[ɔv]	<i>xxx</i>	xx xx
10	aw	[au]	<i>cow</i>	k aw
11	awm	[ãv]	<i>não</i>	n awm
12	ay	[ai]	<i>I</i>	ay
13	aym	[aɪ̯]	<i>mäe</i>	m aym
14	b	[b]	<i>boot</i>	b uw tt
15	ch	[tʃ]	<i>cheek</i>	ch iy kk
16	d	[d]	<i>do</i>	d uw
17	dh	[ð]	<i>that</i>	dh ae tt
18	e	[e]	<i>eu</i>	e w
19	eh	[ɛ]	<i>merry</i>	m eh r iy
20	em	[ẽ]	<i>entendi</i>	em tt em jh i
21	ey	[eɪ̯]	<i>April</i>	ey pp r iy ll
22	eym	[eɪ̯̯]	<i>hein</i>	eym
23	f	[f]	<i>fat</i>	f ae tt
24	g	[g]	<i>guy</i>	g ay
25	hh	[h]	<i>heat</i>	hh iy tt
26	ih	[i]	<i>bit</i>	b ih tt
27	i	[i]	<i>comi</i>	k o m i
28	im	[i̯]	<i>sim</i>	s im
29	iy	[i̯̯]	<i>eat</i>	iy tt
30	jh	[dʒ]	<i>judge</i>	jh ah jh
31	k	[k <sup>h</sup> ]	<i>cool</i>	k uw ll
32	kk	[k]	<i>cai</i>	kk ay
33	l	[l]	<i>lounge</i>	l aa uh n jh
34	ll	[l̯]	<i>fall</i>	f ao ll
35	m	[m]	<i>mother</i>	m ah dh ah r
36	n	[n]	<i>neat</i>	n iy tt
37	ng	[ŋ]	<i>king</i>	k ih ng
38	o	[o]	<i>sô</i>	s o
39	om	[õ̯]	<i>conto</i>	kk om tt u
40	ow	[o̯v]	<i>no</i>	n ow
41	ohy	[ɔ̯i̯]	<i>boys</i>	b oy z
42	oym	[ɔ̯i̯̯]	<i>doações</i>	d o a s oym s
43	p	[p <sup>h</sup> ]	<i>pity</i>	p ih rd iy
44	pp	[p̯]	<i>pai</i>	pp ay
45	r	[r]	<i>run</i>	r ah n
46	rd	[r̯]	<i>city</i>	s ih rd iy
47	s	[s]	<i>six</i>	s ih k s
48	sh	[ʃ]	<i>shoes</i>	sh uw z
49	t	[t <sup>h</sup> ]	<i>time</i>	t ay m
50	th	[θ̯]	<i>three</i>	th r iy
51	tt	[t̯]	<i>tudo</i>	tt uw d u
52	u	[ʊ̯]	<i>como</i>	kk om m u
53	uh	[ʊ̯̯]	<i>could</i>	k uw d
54	um	[ũ̯̯]	<i>rum</i>	hh um
55	uw	[u̯̯]	<i>wood</i>	w uw d
56	v	[v̯̯]	<i>van</i>	v ae n
57	w	[w̯̯]	<i>what</i>	w aa tt
58	y	[y̯̯]	<i>union</i>	y uw n y ah n
59	z	[z̯̯]	<i>zoo</i>	z uw
60	zh	[ʒ̯̯]	<i>leisure</i>	l eh zh ah r

Table 16: Examples of final-obstruent devoicing in German.

PLURAL FORM	SINGULAR FORM	GLOSS
Hun[d]e	Hun[t]	dog
Die[b]e	Die[p]	thief
Ber[g]e	Ber[k]	mountain
Mäu[z]	Mau[s]	mouse

Table 17: Distinctive features chart for AmE phones [35].

CMU SYMBOL	IPA SYMBOL	DISTINCTIVE FEATURES																
		SYLLABIC	CONSONANTAL	SONORANT	VOICE	HSP	CONTINUANT	NASAL	LATERAL	STRIDENT	DEL. RELEASE	ANTERIOR	CORONAL	DISTRIBUTED	HIGH	LOW	BACK	ATR
AA [ɑ]	[ɑ]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	+	+	-
AE [ae]	[ae]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	-	-	-
AH [ə]	[ə]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	+	-	-
AO [ɔ]	[ɔ]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	+	-	+
AW [aʊ]	[aʊ]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	-	-	-
AY [aɪ]	[aɪ]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	-	-	-
B [b]	[b]	-	+	-	+	-	-	-	-	-	+	-	-	-	-	-	-	-
CH [tʃ]	[tʃ]	-	+	-	-	-	-	-	+	+	-	-	-	-	-	-	-	-
D [d]	[d]	-	+	-	+	-	-	-	-	-	+	+	-	-	-	-	-	-
DH [ð]	[ð]	-	+	-	+	-	+	-	-	-	+	+	-	-	-	-	-	-
EH [ɛ]	[ɛ]	+	-	-	+	-	+	-	-	-	-	-	-	-	-	-	-	-
EY [aɪ]	[aɪ]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	+	-	-
F [f]	[f]	-	+	-	-	-	+	-	-	-	+	-	-	-	-	-	-	-
G [g]	[g]	-	+	-	+	-	-	-	-	-	-	-	-	-	-	-	-	-
HH [h]	[h]	-	+	-	-	-	+	-	-	-	-	+	-	-	-	-	-	-
IH [ɪ]	[ɪ]	+	-	+	+	-	+	-	-	-	-	-	-	+	-	-	-	-
IY [i]	[i]	+	-	+	+	-	+	-	-	-	-	-	-	+	-	-	+	-
JH [dʒ]	[dʒ]	-	+	-	+	-	-	-	+	+	-	-	-	-	-	-	-	-
K [k]	[k]	-	+	-	-	+	-	-	-	-	-	-	-	-	-	-	-	-
L [l]	[l]	-	+	+	+	-	+	-	+	-	+	+	-	-	-	-	-	-
M [m]	[m]	-	+	+	+	-	-	+	-	-	+	-	-	-	-	-	-	-
N [n]	[n]	-	+	+	+	-	-	+	-	-	+	+	-	-	-	-	-	-
NG [ŋ]	[ŋ]	-	+	+	+	-	-	+	-	-	-	-	-	-	-	-	-	-
OW [oʊ]	[oʊ]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	+	+	+
OY [ɔɪ]	[ɔɪ]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	+	-	+
P [p]	[p]	-	+	-	-	+	-	-	-	-	+	-	-	-	-	-	-	-
R [ɹ]	[ɹ]	-	+	+	+	-	+	-	-	-	+	-	-	-	-	-	-	-
S [s]	[s]	-	+	-	-	-	+	-	-	+	-	+	-	-	-	-	-	-
SH [ʃ]	[ʃ]	-	+	-	-	-	+	-	-	+	-	-	+	-	-	-	-	-
T [t]	[t]	-	+	-	-	+	-	-	-	-	+	+	-	-	-	-	-	-
TH [θ]	[θ]	-	+	-	-	-	+	-	-	-	+	+	-	-	-	-	-	-
UH [ʊ]	[ʊ]	+	-	+	+	-	+	-	-	-	-	-	-	+	-	+	-	+
UW [u]	[u]	+	-	+	+	-	+	-	-	-	-	-	-	+	-	+	+	+
V [v]	[v]	-	+	-	+	-	+	-	-	-	+	-	-	-	-	-	-	-
W [w]	[w]	-	-	+	+	-	+	-	-	-	-	-	-	-	-	-	-	-
Y [y]	[y]	-	-	+	+	-	+	-	-	-	-	-	-	-	-	-	-	-
Z [z]	[z]	-	+	-	+	-	+	-	-	+	-	+	+	-	-	-	-	-
ZH [ʒ]	[ʒ]	-	+	-	+	-	-	-	+	-	-	-	-	-	-	-	-	-

Table 18: Distinctive features chart for BP phones [35].

CMU SYMBOL	IPA SYMBOL	DISTINCTIVE FEATURES																	
		SYLLABIC	CONSONANTAL	SONORANT	VOICE	HSP	CONTINUANT	NASAL	LATERAL	STRIDENT	DEL. RELEASE	ANTERIOR	CORONAL	DISTRIBUTED	HIGH	LOW	BACK	ATR	ROUND
a	[a]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	+	+	+	-
a~	[ã]	+	-	+	+	-	+	+	-	-	-	-	-	-	+	+	+	+	-
b	[b]	-	+	-	+	-	-	-	-	-	-	+	-	-	-	-	-	-	-
d	[d]	-	+	-	+	-	-	-	-	-	-	+	+	-	-	-	-	-	-
dZ	[dʒ]	-	+	-	+	-	-	-	-	+	+	-	-	-	-	-	-	-	-
E	[ɛ]	+	-	-	+	-	+	-	-	-	-	-	-	-	-	-	-	-	-
e	[e]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	-	+	-	-
e~	[ẽ]	+	-	+	+	-	+	+	-	-	-	-	-	-	-	-	+	-	-
f	[f]	-	+	-	-	+	-	-	-	-	+	-	-	-	-	-	-	-	-
g	[g]	-	+	-	+	-	-	-	-	-	-	-	-	-	-	-	-	-	-
G	[ɣ]	-	+	-	+	-	+	-	-	-	-	+	-	-	-	+	-	-	-
i	[i]	+	-	+	+	-	+	-	-	-	-	-	+	-	-	+	-	+	-
I	[ɪ]	+	-	+	+	-	+	-	-	-	-	-	+	-	-	-	-	-	-
i~	[ĩ]	+	-	+	+	-	+	+	-	-	-	-	+	-	-	+	-	+	-
J	[ɲ]	-	+	+	+	-	+	-	-	-	-	+	-	-	-	-	-	-	-
j	[y]	-	-	+	+	-	+	-	-	-	-	-	-	-	-	-	-	-	-
j~	[ŷ]	-	-	+	+	-	+	+	-	-	-	-	-	-	-	-	-	-	-
k	[k]	-	+	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
l	[l]	-	+	+	+	-	+	-	+	-	+	+	-	-	-	-	-	-	-
L	[ɿ]	-	+	+	+	-	+	-	+	-	+	+	+	-	-	-	-	-	-
m	[m]	-	+	+	+	-	-	+	-	-	-	+	-	-	-	-	-	-	-
n	[n]	-	+	+	+	-	-	+	-	-	-	+	+	-	-	-	-	-	-
O	[ɔ]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	+	-	+	-
o	[o]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	+	+	+	+
o~	[õ]	+	-	+	+	-	+	+	-	-	-	-	-	-	-	+	+	+	+
p	[p]	-	+	-	-	-	-	-	-	-	-	+	-	-	-	-	-	-	-
s	[s]	-	+	-	-	-	+	-	-	+	-	+	+	-	-	-	-	-	-
S	[s̪]	-	+	-	-	-	+	-	-	+	-	-	-	+	-	-	-	-	-
t	[t]	-	+	-	-	-	-	-	-	-	+	+	-	-	-	-	-	-	-
tS	[tʃ]	-	+	-	-	-	-	-	+	+	-	-	-	-	-	-	-	-	-
u	[u]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	-	+	+	+
U	[v̄]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	-	+	-	+
u~	[ũ]	+	-	+	+	-	+	+	-	-	-	-	-	-	+	-	+	+	+
v	[v̄]	-	+	-	+	-	+	-	-	-	+	-	-	-	-	-	-	-	-
w	[w̄]	-	-	+	+	-	+	-	-	-	-	-	-	-	-	-	-	-	-
w~	[w̄]	-	-	+	+	-	+	+	-	-	-	-	-	-	-	-	-	-	-
x	[x̄]	-	+	-	-	-	+	-	-	-	-	-	+	-	-	-	-	+	-
z	[z̄]	-	+	-	+	-	+	-	-	+	-	+	+	-	-	-	-	-	-
Z	[z̄]	-	+	-	+	-	-	-	-	+	-	-	-	-	-	-	-	-	-
4	[r̄]	-	+	+	+	+	+	-	-	-	-	+	-	-	-	-	-	-	-
@	[ə̄]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	+	-	-	-

Table 19: Distinctive features chart for Listener phones.

#	LISTENER SYMBOL	IPA SYMBOL	DISTINCTIVE FEATURES																
			SYLLABIC	CONSONANTAL	SONORANT	VOICE	HSP	CONTINUANT	NASAL	LATERAL	STRIDENT	DEL. RELEASE	ANTERIOR	CORONAL	DISTRIBUTED	HIGH	LOW	BACK	ATR
1	a	[ə]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	+	-	-
2	aa	[ɑ]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	+	+	-
3	aaa	[a]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	+	+	-
4	ae	[æ]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	-	-	-
5	ah	[ə]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	-	-	-
6	am	[ã]	+	-	+	+	-	+	+	-	-	-	-	-	-	+	+	+	-
7	ao	[ɔ]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	+	-	+
8	aw	[au]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	-	-	-
9	awm	[w̚]	-	-	+	+	-	+	+	-	-	-	-	-	-	-	-	-	-
10	ay	[aɪ]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	-	-	-
11	aym	[ÿ]	-	-	+	+	-	+	+	-	-	-	-	-	-	-	-	-	-
12	b	[b]	-	+	-	+	-	-	-	-	-	-	+	-	-	-	-	-	-
13	ch	[tʃ]	-	+	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
15	d	[d]	-	+	-	+	-	-	-	-	-	-	+	+	-	-	-	-	-
16	dh	[ð]	-	+	-	+	-	+	-	-	-	-	+	+	-	-	-	-	-
17	e	[e]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	+	-	-
18	eh	[ɛ]	+	-	-	+	-	+	-	-	-	-	-	-	-	-	-	-	-
19	em	[ē]	+	-	+	+	-	+	+	-	-	-	-	-	-	-	+	-	-
20	ey	[aɪ]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	+	-	-
21	eym	[ÿ]	-	-	+	+	-	+	+	-	-	-	-	-	-	-	-	-	-
22	f	[f]	-	+	-	-	-	+	-	-	-	-	+	-	-	-	-	-	-
23	g	[g]	-	+	-	+	-	-	-	-	-	-	-	-	-	-	-	-	-
24	hh	[h]	-	+	-	-	-	+	-	-	-	-	-	+	-	-	-	-	-
25	i	[i]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	-	-	+
26	ih	[ɪ]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	-	-	-
27	im	[i]	+	-	+	+	-	+	+	-	-	-	-	-	-	+	-	-	+
28	iy	[i]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	-	-	+
29	jh	[dʒ]	-	+	-	+	-	-	-	-	-	+	+	-	-	-	-	-	-
30	k	[k]	-	+	-	-	+	-	-	-	-	-	-	-	-	-	-	-	-
31	kk	[k]	-	+	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
32	l	[l]	-	+	+	+	-	+	-	-	-	-	+	+	-	-	-	-	-
33	lh	[ɿ]	-	+	+	+	-	+	-	-	-	-	+	+	-	-	-	-	-
34	m	[m]	-	+	+	+	-	+	-	-	-	-	+	-	-	-	-	-	-
35	n	[n]	-	+	+	+	-	+	-	-	-	-	+	+	-	-	-	-	-
36	ng	[ŋ]	-	+	+	+	-	+	-	-	-	-	-	-	-	-	-	-	-
37	nh	[ɲ]	-	+	+	+	-	+	-	-	-	-	-	+	-	-	-	-	-
38	o	[o]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	+	+	+
39	om	[õ]	+	-	+	+	-	+	+	-	-	-	-	-	-	+	+	+	+
40	ow	[oʊ]	+	-	+	+	-	+	-	-	-	-	-	-	-	+	+	+	+
41	oy	[ɔɪ]	+	-	+	+	-	+	-	-	-	-	-	-	-	-	+	-	+
42	oym	[ÿ]	-	-	+	+	-	+	+	-	-	-	-	-	-	-	-	-	-
43	p	[p]	-	+	-	-	+	-	-	-	-	-	+	-	-	-	-	-	-
44	pp	[p̚]	-	+	-	-	-	-	-	-	-	-	+	-	-	-	-	-	-
45	r	[ɹ]	-	+	+	+	-	+	-	-	-	-	+	-	-	-	-	-	-
46	rd	[ɾ]	-	+	+	+	+	+	-	-	-	-	+	-	-	-	-	-	-
47	s	[s]	-	+	-	-	-	+	-	-	-	-	+	+	-	-	-	-	-
48	sh	[ʃ]	-	+	-	-	-	+	-	-	-	-	-	+	+	-	-	-	-
49	t	[t]	-	+	-	-	+	-	-	-	-	-	+	+	-	-	-	-	-
50	th	[θ]	-	+	-	-	+	-	-	-	-	-	+	+	-	-	-	-	-
51	tt	[t̚]	-	+	-	-	-	-	-	-	-	-	+	+	-	-	-	-	-
52	u	[u]	+	-	+	+	-	+	-	-	-	-	-	-	+	-	+	+	+
53	uh	[œ̚]	+	-	+	+	-	+	-	-	-	-	-	-	+	-	+	-	+
54	um	[ü̚]	+	-	+	+	-	+	+	-	-	-	-	-	+	-	+	+	+
55	uw	[u̚]	+	-	+	+	-	+	-	-	-	-	-	-	+	-	+	+	+
56	v	[v̚]	-	+	-	+	-	+	-	-	-	-	+	-	-	-	-	-	-
57	w	[w̚]	-	-	+	+	-	+	-	-	-	-	-	-	-	-	-	-	-
58	y	[y̚]	-	-	+	+	-	+	-	-	-	-	-	-	-	-	-	-	-
59	z	[z̚]	-	+	-	+	-	+	-	-	-	-	+	+	-	-	-	-	-
60	zh	[ʒ̚]	-	+	-	+	-	-	-	-	-	-	+	-	-	-	-	-	-

Listing 7: Pronunciation rules for generating nasal vocalization cases.

```

%%% Definitions
word -- string with the orthographic form of the word
pron -- string with the phonetic transcription of the word
new_pron -- string with the modified pronunciation
dict -- dictionary with all CMU words as keys and pron as values

for word, pron in dict:

    %% Rules after Kluge (2007), Kluge & Baptista (2008) and Kluge
    et al. (2012)
    %% The final nasal is deleted and the previous vowel is mapped
    on the most
    %% acoustically similar BP vowel
    if pron has [(aa|ae|ah) (m|n|g) Cons]: % e.g. rose
        replace nasal and prev. vowel by [a~] and append new_pron to
        dict
    if pron has [eh (m|n|g) Cons]: % e.g. rose
        replace nasal and prev. vowel by [e~] and append new_pron to
        dict
    if pron has [(ih|iy) (m|n|g) Cons]: % e.g. rose
        replace nasal and prev. vowel by [i~] and append new_pron to
        dict
    if pron has [ao (m|n|g) Cons]: % e.g. rose
        replace nasal and prev. vowel by [o~] and append new_pron to
        dict
    if pron has [(uh|uw) (m|n|g) Cons]: % e.g. rose
        replace nasal and prev. vowel by [u~] and append new_pron to
        dict

    %% Rules inspired by Silveira (2007) and Silveira (2012)
    %% The final nasal is deleted and the previous vowel is
    nasalized, however
    %% the vowel produced is influenced by the orthographic form of
    the word
    for each [(m|n|ng)] in pron:
        if the next phone is a consonant and the previous is a vowel:
            if words has <A(M|N)>: % e.g.
                replace nasal and prev. vowel by [a~] and append new_pron
                to dict
            elif words has <E(M|N)>: % e.g.
                replace nasal and prev. vowel by [e~] and append new_pron
                to dict
            elif words has <I(M|N)>: % e.g.
                replace nasal and prev. vowel by [i~] and append new_pron
                to dict
            elif words has <O(M|N)>: % e.g.
                replace nasal and prev. vowel by [o~] and append new_pron
                to dict
            elif words has <U(M|N)>: % e.g.
                replace nasal and prev. vowel by [u~] and append new_pron
                to dict

    end for

```

Listing 8: Pronunciation rules for generating velar paragoge cases.

```

%%% Definitions
word -- string with the orthographic form of the word
pron -- string with the phonetic transcription of the word
new_pron -- string with the modified pronunciation
dict -- dictionary with all CMU words as keys and pron as values

for word, pron in dict:

%%% Rule after xxxx
if pron has [ng$]: % e.g. working
    replace [ng$] by [ng g$] and append new_pron to dict

end for

```

Listing 9: Pronunciation rules for generating vowel assimilation cases.

```

%%% Definitions
word -- string with the orthographic form of the word
pron -- string with the phonetic transcription of the word
new_pron -- string with the modified pronunciation
dict -- dictionary with all CMU words as keys and pron as values

for word, pron in dict:

%%% Rules after Rauber et al. (2005), Rauber (2006) and
    Battistela (2010)
if pron has [ae]: % e.g. hat
    replace [ae] by [eh] and append new_pron to dict
if pron has [ih]: % e.g. bit
    replace [ih] by [iy] and append new_pron to dict
if pron has [uh]: % e.g. book
    replace [uh] by [uw] and append new_pron to dict

%%% Rules after Rauber et al. (2005)
if pron has [aa]: % e.g. pot
    replace [aa] by [ao] and append new_pron to dict
if pron has [ow]: % e.g. know
    replace [ow] by [o] and append new_pron to dict

end for

```

# 8

## RESULTS AND DISCUSSION

---

This is just to test whether this template is working



## FINAL REMARKS

---

Resultados em reconhecimento de fala, em muitas vezes, são exploratórios. As línguas são sistemas dinâmicos, variando dado o espaço, o tempo, os grupos sociais, as situações comunicativas e o próprio falante. Tendo em vista que cada língua possui aspectos particulares, não se pode assegurar, no PLN, que métodos já testados para outros idiomas, sejam diretamente transplantados para o PB e tenham funcionamento e desempenho similar. Esta dissertação busca propor um método de elaboração de um sistema de reconhecimento de pronúncia para aprendizes de inglês, falantes nativos do PB. Um sistema desse tipo ainda não foi elaborado para o PB e os resultados, portanto, são tentativos. Como se discutiu, tal sistema é de utilidade, tendo em vista a baixa proficiência em inglês dos brasileiros, demonstrada recentemente nos índices da GlobalEnglish (2012) e da Education First (2013).

A literatura pertinente da área foi revisada e métodos que se mostraram promissores foram selecionados para integrar o projeto. Pretende-se elaborador um reconhecedor de pronúncia que seja capaz de tratar nove erros de pronúncia, provendo feedback ao usuário sobre a qualidade de sua pronúncia. Os erros foram selecionados com base nos trabalhos de Zimmer (2004), Godoy (2005), Zimmer et al. (2009) e Cristófaro-Silva (2012), assumindo-se, como pronúncia padrão, o General American (GA). A abordagem de interlíngua foi selecionada para a arquitetura do reconhecedor. O modelo acústico é, assim, alimentado com dados de fala tanto de nativos, quanto de não-nativos, aprendizes de inglês. No caso, para os dados de nativos, será utilizado o TIMIT; e para os de não-nativos, o COBAI e um corpus de leitura de sentenças foneticamente balanceadas, ainda a ser compilado. As sentenças serão extraídas de um corpus de aprendizes, o COMAprend. Um script em Python será utilizado para realizar a conversão grafema-fone das sentenças, tendo por base a pronúncia canônica das palavras registrada no CMU Pronouncing Dictionary. Na abordagem interlingual, também, o modelo de pronúncia deve ser alimentado com as variantes de pronúncia do aprendiz, de modo a compor os chamados dicionários multipronúncia. Para isso, pretende-se utilizar o CMU Pronouncing Dictionary como base e adicionar as hipóteses de pronúncia dos aprendizes por meio de regras transformacionais. O modelo de língua será constituído por trigrama e gerado a partir da Simple English Wikipedia., de modo a apresentar um sintaxe próxima à produção do aprendiz.

Um protótipo foi elaborado de modo a avaliar a viabilidade do método ora proposto. O cronograma de execução do projeto está dentro do prazo, e as bibliotecas e os softwares necessários para sua execução (HTK, Julius, Adintool, Audacity, Praat, SoX) já foram testados na elaboração do protótipo. Uma porção do COBAI (~3h40min) foi segmentada, alinhada e analisada e utilizada para estimar o modelo acústico. Tendo em vista o grande de número de arquivos do COBAI que teve de ser desconsiderado (apenas ~1h30min do que foi segmentado pode ser utilizado), optou-se por se realizar a coleta de um corpus de leitura de sentenças foneticamente balanceadas especificamente para o desenvolvimento do projeto. De modo a simular, no protótipo, os dados que se obterão com esse corpus, um corpus de erros induzidos (~2h20min) foi gravado, segmentado, transscrito e analisado. Tal corpus também foi utilizado na estimação do modelo acústico do protótipo, juntamente com os dados do COBAI. O método de coleta e anotação do corpus real, de leitura de sentenças foneticamente balanceadas, será definido em visita técnica à Universidade de Coimbra, sob supervisão da Profa. Sara Candeias, no período de 28 de janeiro a 28 de fevereiro de 2014. O dicionário-base do modelo de pronúncia, o CMU Pronouncing Dictionary, já foi testado no protótipo, tendo sido adicionadas variantes de pronúncia para um dos erros selecionados: a simplificação silábica. Foi observado que houve um grande aumento no número de entradas no modelo de pronúncia com a adição das variantes de pronúncia: o dicionário cresceu de 1.855 palavras para 7.597. Sendo assim, é possível, ao se coligir todas as regras para os nove tipos de erros, que o dicionário cresça fortemente, tornando o reconhecimento confuso, bem como consumindo tempo e recursos computacionais. Caso isso ocorra, uma solução possível seria criar dicionários específicos para cada tipo de erro, ou solicitar a um especialista que cerceie o dicionário, eliminando as variantes que ocorrem com menor frequência. Os resultados iniciais obtidos com o protótipo no reconhecimento mostraram-se promissores.

O conteúdo do projeto tem sido publicado na web[31] de modo a dar-lhe visibilidade e angariar possíveis colaboradores. Pretende-se, também, ao final do projeto, disponibilizar um pequeno sistema de treino de pronúncia, como a prova de conceito para uso do reconhecedor de pronúncia. Uma interface vem sendo desenvolvida para disponibilizar o protótipo na web, as Figura 19 e Figura 20 trazem algumas telas de exemplo dessa interface.

[pic]

Figura 19: Interface do protótipo na web - visão geral do site e tela de captura do áudio com espectro de frequência.

| [i] | [ii] | |[pic] |[pic] |

Figura 20: Interface do protótipo na web - [i] palavra reconhecida com transcrição em formato IPA e em alfabeto adaptado; [ii] tela com

texto de feedback sobre a pronúncia do aprendiz, após ele reiterar no erro.

Há também a possibilidade de se realizar visita técnica ao Laboratório de Processamento de Sinais (LaPS) da Universidade Federal do Pará (UFPA), na época de avaliação dos resultados finais da dissertação, sob supervisão do Prof. Aldebaro Klautau, co-orientador da pesquisa.



Part IV  
APPENDIX



LABITUR BONORUM PRI NO	QUE VISTA	HUMAN
fastidii ea ius	germano	demonstratea
suscipit instructior	titulo	personas
quaestio philosophia	facto	demonstrated

Table 20: Autem usu id.

Listing 10: A floating example

```
for i:=maxint to 0 do
begin
{ do nothing }
end;
```

  Lorem ipsum at nusquam appellantur his, ut eos erant homero concludaturque. Albucius appellantur deterruisset id eam, vivendum partiendo dissentiet ei ius. Vis melius facilisis ea, sea id convenire referrentur, takimata adolescens ex duo. Ei harum argumentum per. Eam vedit exerci appetere ad, ut vel zzril intellegam interpretaris.

  Errem omnium ea per, pro congue populo ornatus cu, ex qui dicant nemore melius. No pri diam iriure euismod. Graecis eleifend appellantur quo id. Id corpora inimicus nam, facer nonummy ne pro, kasd repudiandae ei mei. Mea menandi mediocrem dissentiet cu, ex nominati imperdiet nec, sea odio duis vocent ei. Tempor everti appareat cu ius, ridens audiam an qui, aliquid admodum conceptam ne qui. Vis ea melius nostrum, mel alienum euripidis eu.

  Ei choro aeterno antiopam mea, labitur bonorum pri no. His no decore nemore graecis. In eos meis nominavi, liber soluta vim cu. Sea commune suavitate interpretaris eu, vix eu libris efficiantur.

*More dummy text.*

  Nulla fastidii ea ius, exerci suscipit instructior te nam, in ullum postulant quo. Congue quaestio philosophia his at, sea odio autem vulputate ex. Cu usu mucius iisque voluptua. Sit maiorum propriae at, ea cum primis intellegat. Hinc cotidieque reprehendunt eu nec. Autem timeam deleniti usu id, in nec nibh altera.

  Equidem detraxit cu nam, vix eu delenit periculis. Eos ut vero constituto, no vedit propriae complectitur sea. Diceret nonummy in has, no qui eligendi recteque consetetur. Mel eu dictas suscipiantur, et sed placeraut oporteat. At ipsum electram mei, ad aeque atomorum mea.

  Ei solet nemore consecuetuer nam. Ad eam porro impetus, te choro omnes evertitur mel. Molestie conclusionemque vel at, no qui omittam expetenda efficiendi. Eu quo nobis offendit, verterem scriptorem ne vix.



## BIBLIOGRAPHY

---

- [1] Jeniffer Albuquerque and Adelaide Silva. Um olhar dinâmico para questões de produção de fala em l2: Estudo preliminar sobre a dessonorização terminal (dt). *Revista Intercâmbio*, XXIII: 106–127, 2011.
- [2] I.M. Alves. *Neologismo: Criação lexical. Princípios* (São Paulo). Editora Atica, 2001. URL <http://books.google.com.br/books?id=7fIuAAAAYAAJ>.
- [3] Mariane Alves and Izabel Seara. Produção de plosivas surdas em inglês e português por falantes brasileiros de inglês como língua estrangeira. In *Anais do CELSUL 2008*. EDUCAT, 2008.
- [4] Pierre Badin, A Ben Youssef, Gérard Bailly, Frédéric Elisei, and Thomas Hueber. Visual articulatory feedback for phonetic correction in second language learning. *Actes de SLATE*, pages 1–10, 2010.
- [5] Jacir Baratieri. *Production of /l/ in the English coda by brazilian EFL learners: An acoustic-articulatory analysis*. Universidade Federal de Santa Catarina (Unpublished Master's Thesis), Florianópolis, SC, 2006.
- [6] Tarsila Battistela. *A relação entre a percepção, a produção e a consciência fonológica na aprendizagem do Inglês como língua estrangeira*. Pontifícia Universidade Católica do Rio Grande do Sul (Unpublished Master's Thesis), Porto Alegre, RS, 2010.
- [7] M. Benzeghiba, R. De Mori, O. Derou, S. Dupont, T. Erbes, D. Jouvet, L. Fissore, P. Laface, A. Mertins, C. Ris, R. Rose, V. Tyagi, and C. Wellekens. Automatic speech recognition and speech variability: A review. *Speech Communication*, 49(10-11):763–786, 2007. ISSN 0167-6393. Intrinsic Speech Variations.
- [8] Shane Bergsma, Paul McNamee, Mossaab Bagdouri, Clayton Fink, and Theresa Wilson. Language identification for creating language-specific twitter collections. In *Proceedings of the Second Workshop on Language in Social Media*, LSM '12, pages 65–74, Stroudsburg, PA, USA, 2012. Association for Computational Linguistics. URL <http://dl.acm.org/citation.cfm?id=2390374.2390382>.
- [9] Eniko Beatrice Bilcu and Jaakko Astola. A hybrid neural network for language identification from text. In *Machine Learning for*

- Signal Processing, 2006. Proceedings of the 2006 16th IEEE Signal Processing Society Workshop on*, pages 253–258. IEEE, 2006.
- [10] L. Bisol. Vowel harmony: a variable rule in brazilian portuguese. *Language Variation and change*, 1:185–198, 1989.
  - [11] Brasil. *Acordo ortográfico da Língua portuguesa, de 14, 15 e 16 de dezembro de 1990*. Diário do Congresso Nacional da República Federativa do Brasil, Poder Executivo, Brasília, Brazil, 2009.
  - [12] WS Brown Jr, Richard J Morris, Harry Hollien, and Elizabeth Howell. Speaking fundamental frequency characteristics as a function of age and professional singing. *Journal of Voice*, 5(4):310–315, 1991.
  - [13] Hadumod. Bussmann, Gregory. Trauth, Kerstin. Kazzazi, and Hadumod. Bussmann. *Routledge dictionary of language and linguistics / Hadumod Bussmann ; translated and edited by Gregory Trauth and Kerstin Kazzazi*. Routledge, London ; New York :, 1996. ISBN 0415022258 0415203198 0415203198 0415022258.
  - [14] Walcir Cardoso. The development of coda perception in second language phonology: A variationist perspective. *Second Language Research*, Online edition:1–33, 2011.
  - [15] Fabíola Castilho. *Questões de pronúncia em Língua Inglesa: Fatores desencadeantes da percepção do sotaque do falante brasileiro de língua inglesa em relação à produção dos sons fricativos alveolares*. Pontifícia Universidade Católica de São Paulo (Unpublished Master's Thesis), São Paulo, SP, 2004.
  - [16] Robert I Damper, Y Marchand, MJ Adamson, and Kjell Gustafson. Comparative evaluation of letter-to-sound conversion techniques for english text-to-speech synthesis. In *The Third ESCA/COCOSDA Workshop (ETRW) on Speech Synthesis*, 1998.
  - [17] Steven Davis and Paul Mermelstein. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *Acoustics, Speech and Signal Processing, IEEE Transactions on*, 28(4):357–366, 1980.
  - [18] F. Delatorre and R. Koerich. Production of epenthesis in endings by brazilian efl learners. *Proceedings of the II Academic Forum*, page 8, 2005.
  - [19] Rita Demasi. *A ditongação nasal no Português Brasileiro: uma análise acústico-aerodinâmica da fala*. University of São Paulo (Unpublished Master's Thesis), São Paulo, SP, 2010.
  - [20] Scrapy developers. *Scrapy – A fast high-level screen scraping and web crawling framework*. Scrapinghub, 2014. <http://scrapy.org/>.

- [21] EducationFirst. *EF English Proficiency Index 2011*. Education First Ltd., 2011.
- [22] EducationFirst. *EF English Proficiency Index 2012*. Education First Ltd., 2012.
- [23] EducationFirst. *EF English Proficiency Index 2013*. Education First Ltd., 2013.
- [24] EducationFirst. *EF English Proficiency Index 2014*. Education First Ltd., 2014.
- [25] Willis C Fails and J Halvor Clegg. A spectrographic analysis of portuguese stressed and unstressed vowels. *Romance Linguistics: The Portuguese Context*. Bergin and Garvey, Westport, pages 31–42, 1992.
- [26] W Tecumseh Fitch and Jay Giedd. Morphology and development of the human vocal tract: A study using magnetic resonance imaging. *The Journal of the Acoustical Society of America*, 106(3):1511–1522, 1999.
- [27] S. Furui. *Digital Speech Processing, Synthesis, and Recognition*. Marcel Dekker, New York, USA, 2<sup>nd</sup> edition, 2001.
- [28] John Garofolo, David Graff, Doug Paul, and David Pallett. *CSR-I (WSJ0) Complete LDC93S6A. Web Download*. Linguistic Data Consortium, Philadelphia, 1993.
- [29] C.A. Girelli. *Brazilian Portuguese Syllable Structure*. UMI, 1990. URL <http://books.google.com.br/books?id=KRGMnQEACAAJ>.
- [30] GlobalEnglish. *The 2013 Business English Index & Globalization of English Report*. Pearson Always Learning, Pearson, 2013.
- [31] Janet Grijzenhout. Voicing and devoicing in english, german, and dutch; evidence for domain-specific identity constraints. *Theory des Lexikons; Arbeiten des Sonderforschungsbereichs*, 282:1–22, 2000.
- [32] Bruce Hayes. *Introductory Phonology*. Blackwell Textbooks in Linguistics. Wiley, 2011. ISBN 9781118315958.
- [33] Hynek Hermansky. Perceptual linear predictive (plp) analysis of speech. *The Journal of the Acoustical Society of America*, 87(4):1738–1752, 1990.
- [34] Xuedong Huang, Alex Acero, and Hsiao-Wuen Hon. *Spoken Language Processing: A Guide to Theory, Algorithm, and System Development*. Prentice Hall PTR, Upper Saddle River, NJ, USA, 1st edition, 2001. ISBN 0130226165.

- [35] John Jensen. *Principles of Generative Phonology: An introduction. Current Issues in Linguistic Theory*. John Benjamins Publishing Company, 2004. ISBN 9789027275172.
- [36] Simone Klein. *Estudo do VOT no Português Brasileiro*. Universidade Federal de Santa Catarina (Unpublished Master's Thesis), Florianópolis, SC, 1999.
- [37] Denise Kluge. Effects o preceding vowel in the perception of english nasal consonants /m, n/ in word-final position by brazilian efl learners. *Revista Diadorim / Revista de Estudos Linguísticos e Literários do Programa de Pós-Graduação em Letras Vernáculas da Universidade Federal do Rio de Janeiro*, 1(12):163–173, 2012.
- [38] Denise Kluge and Barbara Baptista. Production and identification of english word-final nasal consonants by brazilian efl learners. *Ilha do Desterro – UFSC*, 1(55):15–40, 2008.
- [39] Denise Kluge, Andréia Rauber, Mara Reis, and Ricardo Bion. The relationship between the perception and production of english nasal codas by brazilian learners of english. In *Proceedings of the INTERSPEECH 2007*, pages 2297–2300. ISCA, 2007.
- [40] Victor Kuperman, Mirjam Ernestus, and Harald Baayen. Frequency distributions of uniphones, diphones, and triphones in spontaneous speech. *The Journal of the Acoustical Society of America*, 124(6):3897–3908, 2008.
- [41] Peter Ladefoged. *Elements of acoustic phonetics*. University of Chicago Press, Chicago, 1995.
- [42] Robin Lakoff. Language and Woman's Place. *Language in Society*, 2(1), 1973. ISSN 00474045.
- [43] E. Lenneberg. *Biological foundations of language*. John Wiley and Sons, Biological foundations of language, 1967.
- [44] F. Lewis, M. Gary and D. Charles. *Ethnologue: Languages of the World, Seventeenth edition*. Seventeenth edition. SIL International, Dallas, Texas, 2013. URL <http://www.ethnologue.com>.
- [45] Leigh Lisker. How is the aspiration of english /p,t,k/ “predictable”? *Haskins Laboratories, Status report on speech research SR-84*, pages 141–144, 1985.
- [46] M. Long. Does second language instruction make a difference? a review of the research. *TESOL Quarterly*, 17:359–382, 1983.
- [47] R. Lyster and K. Saito. Oral feedback in classroom sla. *Studies in Second Language Acquisition*, 32:265–302, 2010.

- [48] Ian McLoughlin. *Applied Speech and Audio Processing – With Matlab Examples*. Cambridge University Press, Cambridge, 2009.
- [49] Medialab. Wikipedia extractor. [http://medialab.di.unipi.it/wiki/Wikipedia\\_Extractor](http://medialab.di.unipi.it/wiki/Wikipedia_Extractor), 2013.
- [50] Gustavo Mendonça and Sandra Aluísio. Using a hybrid approach to build a pronunciation dictionary for brazilian portuguese. *Proceedings of INTERSPEECH 2014 – 15th Annual Conference of the International Speech Communication Association*, 2014.
- [51] Gustavo Mendonça, Sara Candeias, Fernando Perdigão, Christopher Shulby, Rean Tonazzo, Aldebaro Klautau, and Sandra Aluísio. A method for the extraction of phonetically-rich triphone sentences. *Proceedings of ITS 2014 – International Telecommunications Symposium*, 2014.
- [52] Gustavo Mendonça, Lucas Avanço, Magali Duran, Erick Fonseca, Maria Volpe-Nunes, and Sandra Aluísio. Evaluating phonetic spellers for user-generated content in brazilian portuguese. *Proceedings of IJCAI 2015 – International Joint Conference on Artificial Intelligence*, 2015.
- [53] Daniel Moore. *The perception of English word-final /l/ by brazilian learners*. Universidade Federal de Santa Catarina (Unpublished Master's Thesis), Florianópolis, SC, 2008.
- [54] A. Neri, O. Mich, M. Gerosa, and D. Giuliani. The effectiveness of computer assisted pronunciation training for foreign language learning by children. *Computer Assisted Language Learning*, 21: 393–408, 2008.
- [55] N. Neto, C. Patrick, A. Klautau, and I. Trancoso. Free tools and resources for brazilian portuguese speech recognition. *Journal of the Brazilian Computer Society*, 17(1):53–68, 2011.
- [56] Maria Alzira Nobre and Frances Ingemann. Oral vowel reduction in brazilian portuguese. In *Honor of Ilse Lehiste*. Foris, Dordrecht, pages 195–206, 1987.
- [57] Catarina Oliveira, Lurdes Castro Moutinho, and António J. S. Teixeira. On european portuguese automatic syllabification. In *Proceedings of the Interspeech 2005*, pages 2933–2936. ISCA, 2005. URL [http://www.isca-speech.org/archive/interspeech\\_2005/i05\\_2933.html](http://www.isca-speech.org/archive/interspeech_2005/i05_2933.html).
- [58] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

- [59] Tatyana Polyakova and Antonio Bonafonte. Learning from errors in grapheme-to-phoneme conversion. In *INTERSPEECH*, 2006.
- [60] Susana Prestes. Análise acústica da produção de consoantes oclusivas iniciais por falantes nativos de pb. In *Anais do X Encontro do CELSUL – Círculo de Estudos Linguísticos do Sul*. UNIOESTE - Universidade Estadual do Oeste do Paraná, 2012.
- [61] A. Quicoli. Harmony, lowering and nasalization in brazilian portuguese. *LÃngua*, 80:295–331, 1990.
- [62] Andréia Rauber. *Perception and production of English vowels by brazilian EFL speakers*. Universidade Federal de Santa Catarina (Unpublished Doctoral Thesis), Florianópolis, SC, 2006.
- [63] Andréia Rauber and Barbara Baptista. The production of english initial /s/ clusters by portuguese and spanish efl speakers. *Rev. Est. Ling., Belo Horizonte*, 12(2):459–473, 2004.
- [64] Andréia Rauber, Paola Escudero, Ricardo Bion, and Barbara Baptista. The interrelation between the perception and production of english vowels by native speakers of brazilian portuguese. In *In Proceedings of the Interspeech 2005*, pages 2913–2916, 2005.
- [65] Jeanne Rebello and Barbara Baptista. The production of english initial /s/ clusters by portuguese and spanish efl speakers. In Barbara Baptista and Michael Watkins, editors, *English with a Latin Beat: Studies in Portuguese/Spanish–English Interphonology*, pages 139–154. John Benjamins, 2006.
- [66] J. Reis and V. Hazan. Speechant: a vowel notation system to teach english pronunciation. *ELTJournal*, 66:156–165, 2011.
- [67] Mara Reis. *The perception and production of English interdental fricatives by brazilian EFL learners*. Universidade Federal de Santa Catarina (Unpublished Master's Thesis), Florianópolis, SC, 2006.
- [68] Hugh Robjohns. A brief history of microphones. <http://microphone-data.com//media/filestore/articles/History-10.pdf>, June 2010. Last retrieved 11-21-2014.
- [69] W. Rocha and N. Neto. Implementação de um separador silábico gratuito baseado em regras linguísticas para o português brasileiro. In *Proceedings of the 9th Brazilian Symposium in Information and Human Language Technology*, pages 108–115, 2013.
- [70] Bruno Schwartzhaupt and Ubiratã Alves. A influência do contexto fonético-fonológico nos valores de voice onset time: verificação de dados de três sistemas linguísticos. *Fórum Linguístico*, 11(1), 2014.

- [71] Urmila Shrawankar and Vilas M. Thakare. Techniques for feature extraction in speech recognition system : A comparative study. *International Journal Of Computer Applications In Engineering, Technology and Sciences (IJCAETS)*, pages 412–418, 2010. ISSN 0974-3596.
- [72] Christopher Shulby, Gustavo Mendonça, and Vanessa MarquiafÁvel. Automatic disambiguation of homographic heterophone pairs containing open and closed mid vowels. In *9th Brazilian Symposium in Information and Human Language Technology*, pages 126–137, Fortalez, CE, Brazil, 2013.
- [73] Thaís Cristófaro Silva. *Fonética e fonologia do português: roteiro de estudos e guia de exercícios*. Contexto, 2005.
- [74] Rosane Silveira. The role of task-type and orthography in the production of word-final consonants. *Rev. Est. Ling., Belo Horizonte*, 15(1):147–180, 2007.
- [75] Rosane Silveira. Pl2 production of english word-final consonants: The role of orthography and learner profile variables. *Trab. Ling. Aplic., Campinas*, 51(1):13–34, 2012.
- [76] Ingo Steinwart and Andreas Christmann. *Support vector machines*. Springer, 2008.
- [77] S. S. Stevens, J. Volkmann, and E. B. Newman. A scale for the measurement of the psychological magnitude pitch. *The Journal of the Acoustical Society of America*, 8(3):185–190, 1937. doi: <http://dx.doi.org/10.1121/1.1915893>. URL <http://scitation.aip.org/content/asa/journal/jasa/8/3/10.1121/1.1915893>.
- [78] H. Strik, F. Cornillie, J. Colpaert, J. Doremalen, and C. Cucchiari. Developing a call system for practicing oral proficiency: How to design for speech technology, pedagogy and learners. pages 123–125., Warwickshire, England, 2009.
- [79] António Teixeira, Catarina Oliveira, and Lurdes Moutinho. On the use of machine learning and syllable information in european portuguese grapheme-phone conversion. In *Computational Processing of the Portuguese Language*, pages 212–215. Springer, 2006.
- [80] Juliana Trevisol. A produção da fricativa interdental vozeada por professores brasileiros de inglês. In *Anais do CELSUL 2010*. Editora da Unisul, 2010.
- [81] Dolf Trieschnigg, Djoerd Hiemstra, Mariët Theune, Franciska de Jong, and Theo Meder. An exploration of language identification techniques for the dutch folktale database. In P. Osenova,

- S. Piperidis, M. Slavcheva, and C. Vertan, editors, *Workshop on Adaptation of Language Resources and Tools for Processing Cultural Heritage, LREC 2012*, pages 47–51, Istanbul, Turkey, May 2012. LREC organization. URL <http://doc.utwente.nl/82013/>.
- [82] Y. Tsubota, M. Dantsuji, and T. Kawahara. An english pronunciation learning system for japanese students based on diagnosis of critical pronunciation errors. *ReCALL*, 16:173–180, 2004.
- [83] S. Umesh, L. Cohen, and D. Nelson. Fitting the mel scale. *Proc. ICASSP 1999*, pages 217–220, 1999. ISSN 0-7803-5041.
- [84] United-Nations. *2014 Human Development Report – Sustaining Human Progress: Reducing Vulnerabilities and Building Resilience*. United Nations Development Programme (UNDP), 2014.
- [85] Vera Vasilévski. Phonologic patterns of brazilian portuguese: a grapheme to phoneme converter based study. In *Proceedings of the Workshop on Computational Models of Language Acquisition and Loss*, pages 51–60, Avignon, France, April 2012. Association for Computational Linguistics. URL <http://www.aclweb.org/anthology/W12-0912>.
- [86] A. Veiga, S. Candeias, and F. Perdigão. Developing a hybrid grapheme to phoneme converter for european portuguese. *Conf. on Telecommunications - ConfTele*, 1:297–300, May 2013.
- [87] Xiaou Wang, Thomas Hueber, and Pierre Badin. On the use of an articulatory talking head for second language pronunciation training: the case of Chinese learners of French. In *Proceedings of the 10th International Seminar on Speech Production, ISSP10*, page 4, Koeln, Allemagne, 2014.
- [88] H. Weide. The cmu pronouncing dictionary, 1998. URL <http://www.speech.cs.cmu.edu/cgi-bin/cmudict>.
- [89] Robert Weide. The CMU Pronouncing Dictionary 0.7a. *Carnegie Mellon University*, 2008. <http://www.speech.cs.cmu.edu/cgi-bin/cmudict>.
- [90] J. Wells. Overcoming phonetic interference. *English Phonetics, Journal of the English Phonetic Society of Japan*, 3:9–21, 2000.
- [91] S. Young, J. Odell, and P. Woodland. Tree-based state tying for high accuracy acoustic modelling. *Cambridge University Engineering Department*, 1994.
- [92] Marcos Zampieri, Binyam Gebrekidan Gebre, and Holland Ni-jmegen. Automatic identification of language varieties: The case of portuguese. In *Proceedings of KONVENS*, pages 233–237, 2012.

- [93] Márcia Zimmer. A desaspiração de plosivas surdas iniciais na transferência do conhecimento fonético do português brasileiro (l1) para o inglês (l2). *Anais do 6º Encontro do Celsul*, page 10, 2006.
- [94] Márcia Zimmer and Ubiratã Alves. Uma visão dinâmica da produção da fala em l2. *Revista da ABRALIN*, XI(1):221–272, 2012.

## COLOPHON

This document was typeset using the typographical look-and-feel `classicthesis` developed by André Miede. The style was inspired by Robert Bringhurst's seminal book on typography "*The Elements of Typographic Style*". `classicthesis` is available for both L<sup>A</sup>T<sub>E</sub>X and LyX:

<http://code.google.com/p/classicthesis/>

Happy users of `classicthesis` usually send a real postcard to the author, a collection of postcards received so far is featured here:

<http://postcards.miede.de/>

## DECLARATION

---

Put your declaration here.

*São Carlos, SP – Brazil, July 2014*

---

Gustavo Mendonça